Fundamentos para Análise de Dados AMI e Machine Learning

Apostila de emergência · Semana 1 — Base estatística, modelagem e séries temporais

Material de estudo aplicado ao TCC de Engenharia Elétrica · UFPR

Novembro de 2026

Sumário

1 Como usar esta apostila **5**
1.1 O que você deverá saber ao terminar . . . 5
1.2 Como ler cada dia . . . 5
1.3 Bibliografia realmente utilizada nesta semana . . . 5

2 Mapa de conteúdos e fórmulas — consulta inicial **7**
2.1 Uma figura mental para o TCC . . . 7
2.2 Vocabulário mínimo: uma mesma palavra, conceitos diferentes . . . 8

3 Dia 1 — Estatística I: o que é um consumo típico? **9**
3.1 Primeiro, em palavras simples . . . 9
3.2 Visão macro: onde isso entra no pipeline . . . 9
3.3 A pergunta estatística começa pela unidade . . . 10
3.4 População, amostra e notação . . . 10
3.5 Média aritmética . . . 10
3.6 Mediana . . . 11
3.7 Quantis e percentis . . . 11
3.8 Variância e desvio-padrão . . . 11
3.9 IQR — amplitude interquartil . . . 12
3.10 MAD — desvio absoluto mediano . . . 12
3.11 Média aparada e limites das medidas robustas . . . 13
3.12 Exemplo completo: comparação de duas UCs . . . 13
3.13 Laboratório reproduzível — NumPy e Polars . . . 13
3.14 Cinco erros recorrentes . . . 14
3.15 Exercícios do Dia 1 . . . 14
3.16 Checkpoint de domínio . . . 14

4 Dia 2 — Estatística II: duas variáveis podem contar uma história enganosa **15**
4.1 Primeiro, em palavras simples . . . 15
4.2 Visão macro no TCC . . . 15
4.3 Distribuição: o desenho completo dos valores . . . 16
4.4 Histograma, densidade e boxplot . . . 16
4.5 Covariância . . . 17
4.6 Correlação de Pearson . . . 17
4.7 Correlação de Spearman . . . 18
4.8 Escala: por que 10.000 pode dominar 0,02 . . . 18
4.9 Padronização (z-score) . . . 18
4.10 Robust scaling e min-max . . . 18
4.11 Distribuição empírica e percentis de score . . . 19
4.12 Laboratório: correlação e scaling sem leakage . . . 19
4.13 Exercícios do Dia 2 . . . 19
4.14 Checkpoint de domínio . . . 20

5 Dia 3 — Machine Learning: o que significa aprender a partir dos dados? **21**
5.1 Primeiro, em palavras simples . . . 21
5.2 Visão macro para AMI . . . 21
5.3 As quatro peças de qualquer estudo . . . 21
5.4 Modelo, parâmetro, hiperparâmetro e predição . . . 21
5.5 Supervisionado, não supervisionado e semissupervisionado . . . 22
5.6 O que é uma amostra no TCC? . . . 22
5.7 Matriz de características . . . 23
5.8 Overfitting e underfitting . . . 23
5.9 Generalização: onde o modelo precisa funcionar? . . . 24

5.10 Data drift, concept drift e mudança real . . . 24
5.11 O perigo das métricas “bons números” . . . 24
5.12 Uma primeira ficha de modelo . . . 24
5.13 Laboratório: inspecionar um dataset de ML . . . 25
5.14 Exercícios do Dia 3 . . . 25
5.15 Checkpoint de domínio . . . 25

6 Dia 4 — Pipeline de Machine Learning: como impedir que a resposta contamine a pergunta? 26
6.1 Primeiro, em palavras simples . . . 26
6.2 A arquitetura que você precisa conseguir desenhar . . . 26
6.3 Etapa 1 — delimitar o problema antes do código . . . 27
6.4 Etapa 2 — contrato da observação . . . 27
6.5 Etapa 3 — UC × NIO e histórico de vigência . . . 27
6.6 Etapa 4 — data de corte e janela histórica . . . 28
6.7 Etapa 5 — a cadência é propriedade do canal . . . 28
6.8 Etapa 6 — transformação: `fit` não é `transform` . . . 28
6.9 Etapa 7 — cinco modalidades de leakage . . . 29
6.10 Etapa 8 — como validar sem prometer fraude . . . 30
6.11 Mini-contrato de uma feature . . . 30
6.12 Um pipeline também precisa de testes . . . 30
6.13 Exercícios do Dia 4 . . . 31
6.14 Checkpoint de domínio . . . 31

7 Dia 5 — Séries temporais: por que a ordem dos dados muda tudo? 32
7.1 Primeiro, em palavras simples . . . 32
7.2 Visão macro . . . 32
7.3 Formalização de uma série . . . 33
7.4 Energia, potência e duração . . . 33
7.5 Timestamp: começo, fim ou momento de chegada? . . . 33
7.6 Resampling e agregação . . . 34
7.7 Defasagem (lag) . . . 34
7.8 Tendência, sazonalidade e ciclos . . . 35
7.9 Amostragem e aliasing: não observar não significa que não aconteceu . . . 35
7.10 Como visualizar uma série para entender comportamento . . . 35
7.11 Laboratório: 15 minutos -> hora/dia . . . 35
7.12 Exercícios do Dia 5 . . . 36
7.13 Checkpoint de domínio . . . 36

8 Dia 6 — Autocorrelação e decomposição: a série tem memória? 37
8.1 Primeiro, em palavras simples . . . 37
8.2 Onde entra no TCC . . . 37
8.3 Autocorrelação: correlação de uma variável consigo mesma defasada . . . 38
8.4 Exemplo manual de lag . . . 38
8.5 ACF versus correlação entre medidores . . . 38
8.6 Estacionariedade, em nível introdutório . . . 39
8.7 Decomposição aditiva . . . 39
8.8 Decomposição multiplicativa . . . 39
8.9 STL: sazonalidade e tendência por suavização local . . . 40
8.10 Como diagnosticar resíduos . . . 40
8.11 Força da tendência e sazonalidade . . . 40
8.12 Decomposição não é causalidade . . . 40
8.13 Laboratório: decomposição semanal em dados diários . . . 41
8.14 Exercícios do Dia 6 . . . 41
8.15 Checkpoint de domínio . . . 42

9 Dia 7 — Engenharia de features temporais: converter uma trajetória em evidência 43
9.1 Primeiro, em palavras simples . . . 43
9.2 Três decisões antes de calcular uma feature . . . 43

9.3 Quadro geral de features . . . 43
9.4 Feature 1 — consumo diário típico . . . 44
9.5 Feature 2 — instabilidade habitual (MAD) . . . 44
9.6 Feature 3 — inclinação de tendência . . . 44
9.7 Feature 4 — fator de carga . . . 45
9.8 Feature 5 — razão diurna/noturna . . . 45
9.9 Feature 6 — dias úteis versus finais de semana . . . 45
9.10 Feature 7 — hora de pico em representação cíclica . . . 45
9.11 Feature 8 — autocorrelação diária e semanal . . . 46
9.12 Feature 9 — entropia de perfil, com definição explícita . . . 46
9.13 Feature 10 — por que precisamos de qualidade separada . . . 46
9.14 Regimes: por que janelas fixas têm limite . . . 47
9.15 Dicionário de features: modelo mínimo . . . 47
9.16 Laboratório: montar features por cutoff . . . 48
9.17 Exercícios do Dia 7 . . . 49
9.18 Checkpoint de domínio . . . 49

10 Estudo de caso integrado — do dado bruto a uma hipótese de investigação 50
10.1 O cenário . . . 50
10.2 Passo 1 — identificar unidades e observabilidade . . . 50
10.3 Passo 2 — descrever antes e depois . . . 50
10.4 Passo 3 — enxergar o problema da janela cega . . . 51
10.5 Passo 4 — identificar o que ainda falta . . . 51
10.6 Passo 5 — converter o caso em trabalho de pesquisa . . . 51
10.7 Perguntas para defesa oral . . . 52

11 Folha de fórmulas — versão de consulta rápida 53
11.1 Estatística descritiva . . . 53
11.2 Relações entre variáveis . . . 53
11.3 Tempo e energia . . . 53
11.4 Features AMI . . . 54
11.5 Dicionário de símbolos . . . 54

12 Gabarito comentado dos exercícios 55
12.1 Dia 1 — estatística descritiva . . . 55
12.2 Dia 2 — relações estatísticas . . . 55
12.3 Dia 3 — fundamentos de ML . . . 56
12.4 Dia 4 — pipeline e leakage . . . 56
12.5 Dia 5 — séries temporais . . . 56
12.6 Dia 6 — ACF e decomposição . . . 57
12.7 Dia 7 — features temporais . . . 57

13 Perguntas rápidas para fixação — 35 cartões 58
13.1 Teste de proficiência da Semana 1 . . . 59

14 Plano de uso e registro de progresso 60
14.1 Checklist de fim de semana . . . 60
14.2 Formato de ficha para anotações por conceito . . . 60
14.3 Leituras e limites das fontes . . . 60

1 Como usar esta apostila

O objetivo não é decorar bibliotecas. É conseguir olhar para um conjunto de medições de energia, entender quais informações são legítimas, transformá-las em variáveis estatísticas e explicar por que um modelo pode — ou não — aprender algo com elas. O foco é a **Semana 1 (dias 1–7)** do plano emergencial. Não há aqui treinamento aprofundado de PCA, K-Means, CUSUM, LOF ou Isolation Forest; esses algoritmos pertencem às etapas seguintes e aparecem somente quando ajudam a explicar um pré-requisito.

O conteúdo foi escrito como uma **síntese didática original**, tendo como referências principais as seções dos livros fornecidos. Exemplos envolvendo medidores, alarmes e unidades consumidoras são **adaptações ao TCC** e não afirmações extraídas literalmente dos livros. Os números de consumo apresentados são sintéticos, a menos que se indique explicitamente outra origem. Fórmulas estatísticas são definições matemáticas usuais; critérios operacionais propostos não equivalem a normas da ANEEL nem constituem resultados de validação.

1.1 O que você deverá saber ao terminar

1. Diferenciar observação, amostra, população, série temporal, janela e feature.
2. Calcular e interpretar média, mediana, variância, desvio-padrão, quantis, IQR, MAD, covariância, correlação e padronização.
3. Dizer quando a média e a correlação enganam.
4. Distinguir aprendizagem supervisionada, não supervisionada e regras determinísticas.
5. Construir um contrato de dados `UC × cutoff_date` com `id__`, `meta__`, `x__` e `y__`.
6. Detectar *data leakage* por tempo, identidade, preparação dos dados ou rotulagem.
7. Interpretar tendência, sazonalidade, autocorrelação e resíduos numa série de 15 minutos.
8. Produzir e documentar algumas features temporais sem confundir observação faltante com zero elétrico.

1.2 Como ler cada dia

Cada capítulo começa de forma deliberadamente simples, passa à matemática e termina com uma aplicação ao TCC. Faça a leitura nesta ordem:

> **Intuição -> visão macro -> fórmula -> exemplo resolvido -> risco de interpretação -> laboratório -> checagem de domínio.**

Estudo recomendado: **50 min de leitura, 30 min de reconstrução sem consulta, 60 min de laboratório, 25 min de explicação oral e 15 min de anotações**. Essa divisão é orientativa: uma seção com derivação pode demandar mais tempo. No tracker, marque leitura e compreensão separadamente; ler um capítulo não equivale a dominá-lo.

1.3 Bibliografia realmente utilizada nesta semana

Código	Obra e edição dos PDFs fornecidos	Seções de base
BR	Peter Bruce, Andrew Bruce, Peter Gedeck. *Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python*, 2ª ed., O'Reilly, 2020	Cap. 1: *Estimates of Location*, *Estimates of Variability*, *Exploring the Data Distribution*, *Correlation*, *Exploring Two or More Variables*; PDF aprox. pp. 25–63
GE	Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn and PyTorch*, edição fornecida, 2025	Cap. 1: *The Machine Learning Landscape*, PDF pp. 33–70; Cap. 2: *End-to-End Machine Learning Project*, pp. 71–136
HY	Rob J. Hyndman, George Athanasopoulos. *Forecasting: Principles and Practice*, **2ª ed., 2018**	Cap. 2, sobretudo §2.8; Cap. 3, §§3.2–3.4; Cap. 6, §§6.1, 6.6, 6.7
UFPR	Notebooks de *Avanços em Inteligência Artificial*, aulas 02 e 03 (2026) fornecidos no projeto	Apoio ao estudo de estatística descritiva e EDA; não substituem as definições dos livros

Atenção às edições. Géron aqui é a versão com **PyTorch**, não a edição antiga com Keras/TensorFlow; Hyndman aqui é a **segunda edição**, cuja numeração é distinta da terceira edição online. Qualquer remissão deve seguir os títulos das seções da tabela acima.

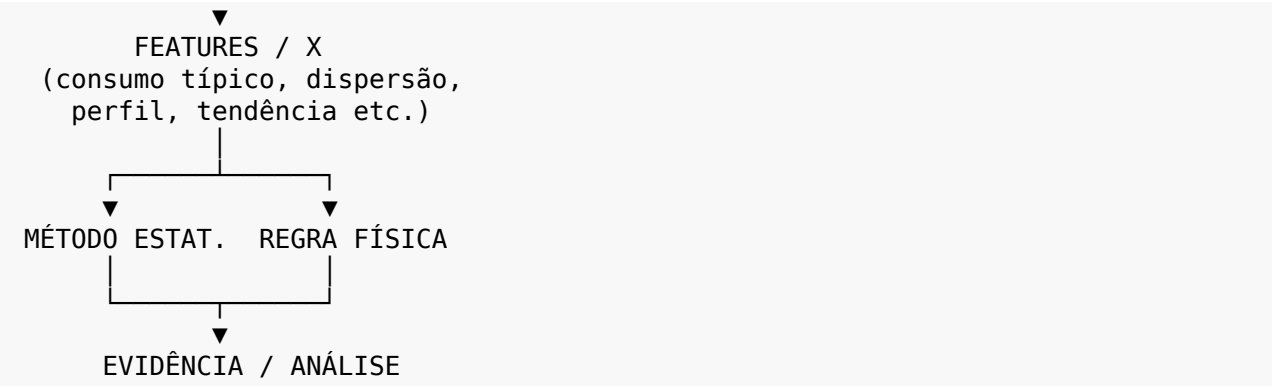
2 Mapa de conteúdos e fórmulas — consulta inicial

A intenção deste mapa é permitir uma visão do território **antes** de começar as demonstrações. Não é uma prova nem uma lista de fórmulas a decorar em um dia.

Dia	Bloco	Conceitos-chave	Fórmula ou operador que deve reconhecer
1	Descrever uma variável	média, mediana, quantil, variância, desvio padrão, IQR, MAD	$\bar{x}$, s^2, $Q_{0.75} - Q_{0.25}$, $\text{med}\,\lvert x - \text{med}(x)\rvert$
2	Relacionar variáveis	covariância, correlação, distribuição, z-score	$\text{cov}(X, Y)$, r, $z = (x - \mu)/\sigma$
3	Entender aprendizagem	X, y, amostra, modelo, generalização, under/overfitting	$\hat{y} = f_\theta(X)$; $\hat{s} = g_\theta(X)$
4	Construir pipelines	`fit`, `transform`, temporal split, feature store, leakage	$X_{\text{train}} \xrightarrow{\text{fit}} \hat{\theta}$
5	Ler o tempo	período, frequência, timestamp, lag, janela	Δt; $P = E/\Delta t$; x_{t-k}
6	Explicar a trajetória	ACF, tendência, sazonalidade, decomposição, resíduos	$\rho(k)$; $y_t = T_t + S_t + R_t$
7	Materializar features	rolling, slope, perfis, fator de carga, pico horário	$\hat{\beta}_1$, $LF = P_{\text{médio}}/P_{\text{pico}}$

2.1 Uma figura mental para o TCC

```
MEDIÇÕES / CADASTRO / ALARMES
             |
             ▼
       LIMPEZA E CONTEXTO
    (cadência, unidade, vigência)
             |
             ▼
      ESTRUTURA TEMPORAL
 (15 min -> dia -> janela histórica)
             |
```



O desenho acima não é uma implementação. A Semana 1 prepara somente a parte superior: como uma medição se transforma em informação utilizável. A interpretação causal e os detectores especializados exigirão dados e validações adicionais.

2.2 Vocabulário mínimo: uma mesma palavra, conceitos diferentes

- **UC**: unidade consumidora, entidade de negócio cuja identificação pode permanecer estável durante uma troca de medidor.
- **NIO**: identificador do medidor físico; pode mudar quando o equipamento é substituído.
- **Medição**: valor reportado por um canal em uma referência temporal (por exemplo, energia ativa de um intervalo).
- **Amostra estatística**: subconjunto de observações sobre o qual calculamos alguma medida.
- **Amostra de ML**: normalmente uma **linha** da matriz enviada ao estimador; no nosso caso, pode representar uma UC em uma data de corte e janela.
- **Feature**: variável derivada ou observada usada como entrada de um método.
- **Target / rótulo**: resposta conhecida para uma tarefa supervisionada, quando existe evidência confiável.
- **Score**: número produzido por um método; não vira automaticamente probabilidade calibrada de fraude.
- **Regime**: período durante o qual certas propriedades estatísticas/operacionais permanecem aproximadamente estáveis.
- **Data de corte**: instante até o qual as informações poderiam estar disponíveis para uma previsão ou análise retrospectiva claramente identificada.

Uma ideia acompanhará todo o material: **o significado físico do dado vem antes do tratamento matemático**.

3 Dia 1 — Estatística I: o que é um consumo típico?

Leitura-base: Bruce, Bruce & Gedeck, cap. 1, seções *Estimates of Location*, *Estimates of Variability* e *Exploring the Data Distribution*. **Pré-requisito:** aritmética. **Objetivo:** descrever uma série sem deixar que um único dia estranho determine o que é normal.

3.1 Primeiro, em palavras simples

Imagine dois medidores. Durante nove dias, ambos consumiram entre 10 e 12 kWh por dia. No décimo, um deles registrou 90 kWh. Se perguntarmos qual é o consumo **normal**, uma média pode ficar alta demais por causa desse evento. A mediana continua representando melhor o dia habitual. Se perguntarmos se o consumo é **estável**, precisamos medir o espalhamento dos valores. É para isso que servem desvio-padrão, IQR e MAD.

Estatística descritiva não descobre fraude. Ela **resume o que foi observado**. O truque consiste em escolher o resumo que responde à pergunta certa.

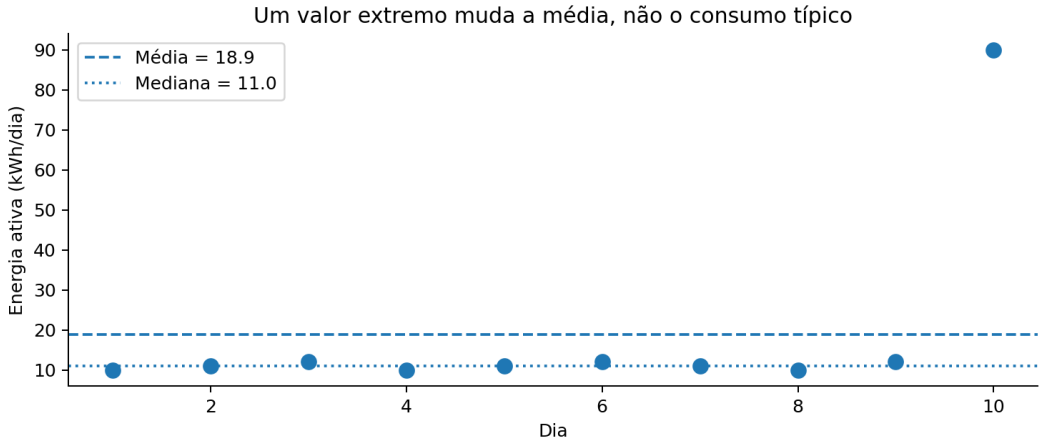
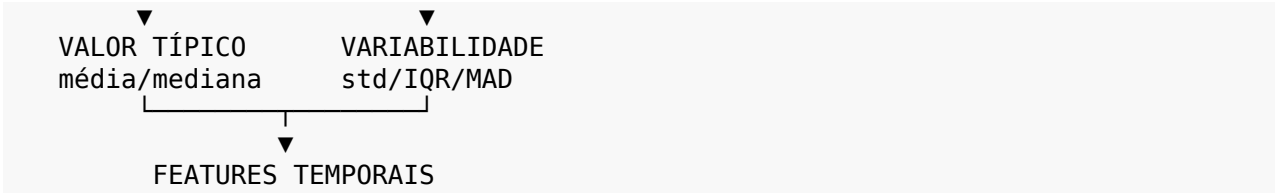


Figura 3.1: Média e mediana diante de valor extremo

3.2 Visão macro: onde isso entra no pipeline

```
SÉRIE ENERGIA ATIVA (FA)
   medidor físico + timestamp + kWh
                  |
                  ▼
      AGRUPAR POR DIA CIVIL
                  |
                  ▼
     kWh/dia: e_1, ..., e_n
                  |
        ┌─────────┴─────────┐
```



O resultado pode gerar features como `x__hist_fa_sum_median` e `x__hist_fa_sum_mad` a partir de uma janela. Entretanto, agregar **só dias observados** e ignorar lacunas pode enviesar a análise. A qualidade da observação será tratada separadamente.

3.3 A pergunta estatística começa pela unidade

Antes de calcular qualquer número, identifique a **unidade observacional**. Uma linha pode representar:

- um registro intervalar de energia ativa (kWh por 15 min);
- um ponto de potência média de intervalo (kW);
- o total de energia diária de uma UC (kWh/dia);
- uma UC em uma janela de 30 dias (feature por UC e cutoff);
- um evento de alarme (código, origem, recebimento).

Fazer a média de 96 valores de energia por intervalo **não** gera diretamente o consumo diário: o consumo diário é a **soma** dos incrementos válidos, desde que a série realmente represente energia de intervalos disjuntos e a cobertura seja adequada. A média desses incrementos tem unidade kWh/intervalo. Já a média de uma potência intervalar permanece em kW. Confundir isso torna qualquer modelo numericamente bonito e fisicamente errado.

3.4 População, amostra e notação

Chame de X a grandeza de interesse. A população poderia ser *todos os dias válidos de uma UC em determinado regime*. A amostra é o conjunto de dias que conseguimos observar. Escrevemos

$$x_1, x_2, \dots, x_n, \quad n = \text{quantidade de observações válidas.}$$

Na prática, uma série histórica costuma conter dependência temporal: dias consecutivos não são independentes. Podemos usar estatística descritiva normalmente, mas não devemos aplicar sem crítica fórmulas inferenciais que presumam amostras independentes e identicamente distribuídas.

Diferença importante: n não é necessariamente o número de linhas retornadas do banco. Duplicatas, canais com cadência distinta, dados fora da vigência do medidor e nulls podem alterar a contagem válida.

3.5 Média aritmética

$$\boxed{\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i}$$

A média responde: *se redistribuíssemos a quantidade total igualmente por observação, quanto caberia a cada uma?* No exemplo $[10, 11, 12, 10, 11, 12, 11, 10, 12, 90]$ kWh/dia,

$$\bar{x} = \frac{189}{10} = 18{,}9 \text{ kWh/dia.}$$

Ela é excelente quando precisamos conservar relações com somas e balanços de energia; é perigosa quando queremos representar o dia **típico** diante de eventos extremos. A média também pode ser expressa como média ponderada:

$$\bar{x}_w = \frac{\sum_i w_i x_i}{\sum_i w_i}, \quad w_i \geq 0.$$

Quando usar ponderação? Se valores correspondem a intervalos de duração diferente, uma média de potência ponderada por duração é apropriada. Ponderar arbitrariamente por tamanho de UC, no entanto, muda o significado da pergunta. Sempre documente os pesos.

3.6 Mediana

Ordene os valores. Para quantidade ímpar, pegue o central; para quantidade par, tire a média dos dois centrais. A mediana é também o quantil $Q_{0.5}$:

$$\boxed{\tilde{x} = Q_{0.5}(x)}.$$

No exemplo, a mediana é **11 kWh/dia**. Compare com a média de **18,9 kWh/dia**. Ambas estão matematicamente corretas, mas respondem perguntas diferentes:

- **média:** quantidade total dividida pelo número de dias;
- **mediana:** ponto central da distribuição dos dias observados.

Não conclua que o 90 kWh é erro. Ele pode ser carga legítima, duplicidade, falha de medição, mudança operacional ou outra causa. Mediana apenas impede que o extremo controle o valor típico.

3.7 Quantis e percentis

Um quantil Q_p é um valor de corte abaixo do qual se encontra aproximadamente a fração p da amostra. Exemplos:

$$Q_{0.05} = \text{percentil 5}, \quad Q_{0.50} = \text{mediana}, \quad Q_{0.95} = \text{percentil 95}.$$

São extremamente úteis para descrever perfis de consumo e tensão. Um consumidor pode ter mediana de potência baixa, mas P_{95} elevado por operar máquinas durante algumas horas. Uma propriedade central: **percentis dependem do método de interpolação para amostras pequenas**. Escolha e registre uma convenção (por exemplo, a utilizada por `numpy.quantile` ou `polars.quantile`). Não é correto comparar quantis de ferramentas com convenções distintas e atribuir a diferença aos medidores.

3.8 Variância e desvio-padrão

Variância mede quanto os valores se afastam, em média quadrática, do centro. Para população finita e para amostra, respectivamente:

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2, \qquad s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

$$\boxed{\sigma = \sqrt{\sigma^2}}, \qquad \boxed{s = \sqrt{s^2}}.$$

Por que elevar ao quadrado? Desvios positivos e negativos não se cancelam. O quadrado aumenta a penalização para valores muito distantes. **Consequência:** outliers extremos afetam fortemente o desvio-padrão.

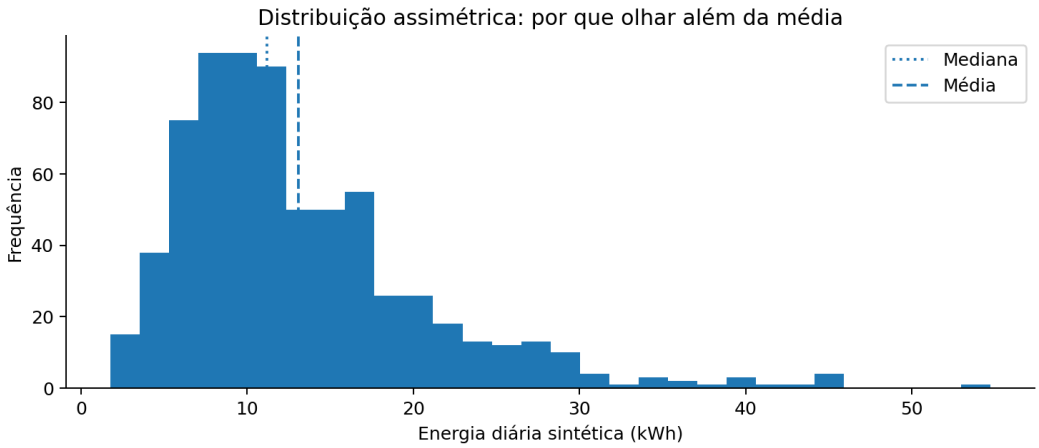


Figura 3.2: Histograma e distribuição assimétrica

Unidades: se x é kWh/dia, a variância está em $(\text{kWh/dia})^2$; o desvio-padrão volta à unidade kWh/dia. Por isso costuma ser mais intuitivo interpretar o desvio-padrão.

No exemplo dos dez dias, o desvio-padrão amostral é aproximadamente **24,995 kWh/dia**, embora nove dias estejam agrupados em 10–12 kWh. Removendo o décimo dia *apenas para ilustrar sensibilidade*, o desvio-padrão amostral dos nove dias fica aproximadamente **0,866 kWh/dia**. A diferença é enorme. Na análise real, não remova o dia sem justificativa.

Denominador n versus $n-1$. A variância populacional descreve todos os valores da população escolhida; a variância amostral usa $n-1$ como correção convencional ao estimar a variância populacional sob determinadas hipóteses. Não existe uma regra universal de que `ddof=1` é sempre superior. Para uma janela operacional cuja totalidade de dias válidos é o objeto de interesse, a medida descritiva com n pode ser natural; para estimativa amostral, $n-1$ pode ser mais apropriado.

3.9 IQR — amplitude interquartil

$$\boxed{IQR = Q_{0.75} - Q_{0.25}}.$$

O IQR é o intervalo que cobre aproximadamente a metade central da distribuição. É menos afetado por um extremo isolado do que o desvio-padrão. Para os dados do exemplo, pela interpolação linear usual do NumPy, $Q_1 = 10{,}25$, $Q_3 = 12$, então **IQR = 1,75 kWh/dia**. A fórmula de Q_1 e Q_3 pode variar entre softwares.

Uso AMI: diferenciar uma UC de carga quase constante de outra muito variável sem deixar que um único pico destrua a comparação.

3.10 MAD — desvio absoluto mediano

$$\boxed{MAD = \text{mediana}_i\left(|x_i - \tilde{x}|\right)}.$$

Passo a passo: (1) encontre mediana; (2) calcule a distância absoluta de cada valor à mediana; (3) tome a mediana dessas distâncias. Nos dez dias, $\tilde{x} = 11$ e $MAD = 1$ kWh/dia.

Duas convenções de MAD: a versão bruta acima e uma versão aproximadamente compatível com o desvio-padrão normal, multiplicada por cerca de $1{,}4826$. Se um pipeline produz `MAD=1` e outro `MAD=1.4826`, talvez a divergência seja apenas **definição**. Cadastre essa escolha no dicionário de features.

3.11 Média aparada e limites das medidas robustas

Média aparada remove uma fração simétrica de observações extremas antes do cálculo. É mais resistente que a média convencional, porém pode eliminar picos operacionais legítimos. A decisão não deve ser "usar sempre o mais robusto"; deve ser "qual informação estamos tentando preservar?".

- **Faturamento e balanço:** somas de energia importam.
- **Consumo típico:** mediana frequentemente é informativa.
- **Variabilidade habitual:** IQR e MAD oferecem resistência a extremos.
- **Picos e dimensionamento:** máximo e percentis altos também são informação física.

Se uma fraude produz justamente um pico/queda incomum, uma limpeza robusta agressiva pode ocultar o fenômeno que você gostaria de detectar.

3.12 Exemplo completo: comparação de duas UCs

Dia	UC A (kWh)	UC B (kWh)
1	10	10
2	11	10
3	12	11
4	10	11
5	11	12
6	12	12
7	11	11
8	10	11
9	12	11
10	90	11

A UC A tem média muito maior por causa do 90; ambas têm valor típico próximo de 11. Uma análise com apenas médias poderia classificá-las como cargas de patamares distintos. A análise com mediana, MAD e percentis permite formular perguntas mais úteis. **Não** conclua, entretanto, que as UCs são idênticas: o extremo da UC A pode revelar uma diferença real de operação.

3.13 Laboratório reproduzível — NumPy e Polars

Instale `numpy` e `polars`. Rode o exemplo abaixo; os dados são sintéticos.

```
import numpy as np
import polars as pl

energia = np.array([10, 11, 12, 10, 11, 12, 11, 10, 12, 90], dtype=float)
mediana = float(np.median(energia))

print("media:", energia.mean())
print("mediana:", mediana)
print("desvio padrao amostral:", energia.std(ddof=1))
print("IQR:", np.quantile(energia, 0.75) - np.quantile(energia, 0.25))
print("MAD bruto:", np.median(np.abs(energia - mediana)))

frame = pl.DataFrame({"dia": range(1, 11), "kwh": energia})
resumo = frame.select(
    pl.col("kwh").mean().alias("media"),
```

```
    pl.col("kwh").median().alias("mediana"),
    pl.col("kwh").std().alias("std_amostral"),
    pl.col("kwh").quantile(0.95).alias("p95"),
)
print(resumo)
```

Observe: o método de quantil de Polars tem escolhas de interpolação que podem diferir de `numpy.quantile` em amostras pequenas. Não use discrepância de P95 como prova de bug sem inspecionar os parâmetros.

3.14 Cinco erros recorrentes

1. Chamar de "consumo médio diário" a média de energia de intervalos de 15 minutos.
2. Comparar desvio-padrão entre UCs de escalas de carga radicalmente diferentes sem fornecer contexto.
3. Tratar valores altos como erros só porque afetam a média.
4. Calcular total diário incompleto como se fosse um dia integral válido.
5. Confundir MAD (mediana dos desvios absolutos) com *mean absolute deviation* (média dos desvios absolutos), que é outra estatística.

3.15 Exercícios do Dia 1

E1.1. Valores diários $[4, 4, 5, 6, 6]$ kWh: calcule média e mediana. Ambas representam a mesma coisa?

E1.2. Para $[1, 2, 3, 14]$ kWh, calcule a média; explique por que um método robusto pode ser preferível para "consumo típico".

E1.3. O canal entrega 72 das 96 leituras esperadas, todas com energia positiva. Você pode somar as 72 e chamar o resultado de consumo diário? Dê uma condição para aceitar e uma para rejeitar.

E1.4. Uma feature de MAD bruto e outra de MAD escalado têm valores 4,0 e 5,93. Isso exige correção do banco? Explique.

E1.5. Para uma UC industrial com um pico de demanda legítimo, você escolheria a mediana ou o P95 para dimensionar o risco de sobrecarga? Justifique a limitação de cada uma.

3.16 Checkpoint de domínio

- ☐ Consigo explicar por que média e mediana divergem diante de outliers.
- ☐ Sei escrever e interpretar s, IQR e MAD com suas unidades.
- ☐ Sei por que uma feature precisa ter janela, população e definição documentadas.
- ☐ Consigo responder: "devo apagar o extremo?" com **"primeiro descubra o que ele representa"**.

Entregável: um pequeno arquivo com 5 estatísticas aplicadas a um conjunto sintético ou real com qualidade conhecida, acompanhado de duas frases justificando a mediana e o MAD.

4 Dia 2 — Estatística II: duas variáveis podem contar uma história enganosa

Leitura-base: Bruce, cap. 1, seções *Exploring the Data Distribution*, *Correlation* e *Exploring Two or More Variables*. **Pré-requisito:** Dia 1. **Objetivo:** entender relações entre variáveis e impedir que a escala ou uma associação espúria controle as conclusões.

4.1 Primeiro, em palavras simples

Uma UC consome mais eletricidade em dias quentes. Isso é correlação: os dois números tendem a variar juntos. Mas não basta observar a correlação para afirmar que a temperatura é a **causa**: pode haver estação do ano, tipo de atividade, ocupação do imóvel ou outra variável envolvida. Da mesma forma, duas features muito correlacionadas podem repetir a mesma informação, e uma feature com números na casa dos milhares pode dominar um método baseado em distância se misturada a outra na faixa de 0 a 1.

O objetivo do dia é responder três perguntas:

1. Como a variável se distribui?
2. Como duas variáveis mudam juntas?
3. É legítimo compará-las numericamente na mesma escala?

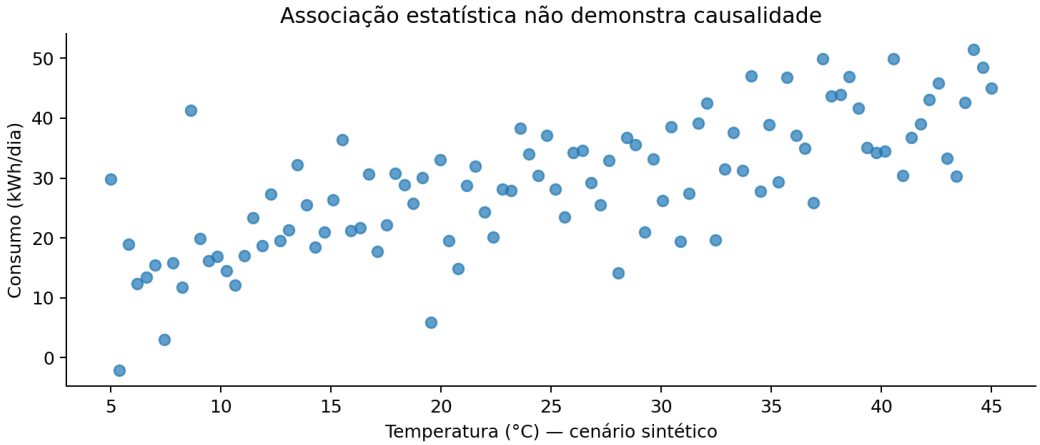
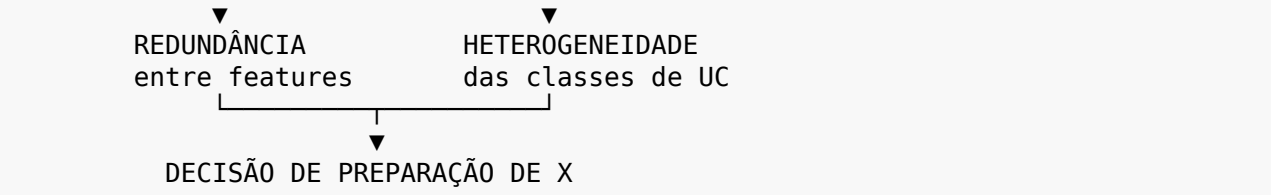


Figura 4.1: Relação sintética: correlação não prova causalidade

4.2 Visão macro no TCC

```
FEATURE A: consumo típico     FEATURE B: variabilidade
             \                  /
              \                /
               EXPLORAÇÃO MULTIVARIADA
             correlação, dispersão, escala
                        |
                        |
                        |
```



Uma matriz de correlação **não** identifica automaticamente quais features devem ser removidas. Pode revelar redundância, mas duas variáveis correlacionadas podem ter significados físicos distintos; por exemplo, consumo total e demanda máxima são relacionados, porém não equivalentes.

4.3 Distribuição: o desenho completo dos valores

Média e variância são apenas dois números. Uma distribuição informa **quais valores aparecem com qual frequência**. Para uma variável quantitativa, procure:

- **localização:** centro;
- **dispersão:** espalhamento;
- **assimetria:** cauda longa para valores altos ou baixos;
- **multimodalidade:** mais de um agrupamento aparente;
- **valores extremos:** raros no conjunto escolhido;
- **massa em zero:** zero físico, censura, desligamento ou problema de codificação?

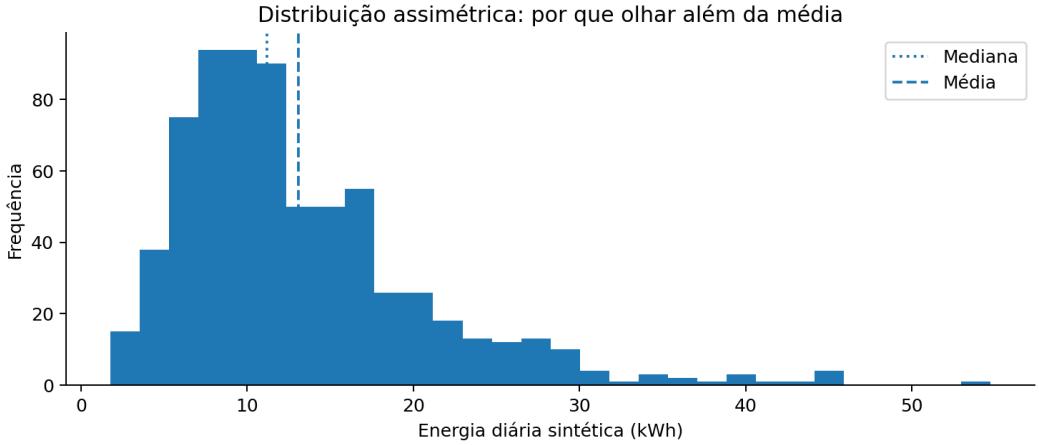


Figura 4.2: Distribuição assimétrica de consumo (dados sintéticos)

A curva de consumo de uma população de residências, comércios e indústrias misturados pode ter vários modos. Uma “distribuição média” para todos pode não representar **ninguém**. É por isso que segmentar por classe e características operacionais pode ser mais útil do que ajustar um único modelo global.

4.4 Histograma, densidade e boxplot

Histograma: divide o eixo dos valores em faixas e conta observações. A forma aparente depende da largura das faixas (*bins*). Faça mais de um histograma antes de concluir que existem clusters.

Densidade estimada: curva suavizada que representa concentração de probabilidade; depende de uma escolha de largura de suavização (*bandwidth*). Um pico de densidade não significa necessariamente uma classe física.

Boxplot: mostra mediana, quartis e uma convenção para bigodes e pontos extremos. O conhecido limite de $1{,}5IQR$ é **convenção exploratória**, não limite legal ou certificado de fraude. Para consumo, exceder esse valor significa “vale investigar”, não “está errado”.

4.5 Covariância

Quando X está acima da média, Y também tende a estar acima? A covariância amostral mede isso:

$$\boxed{\text{cov}(X,Y) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).}$$

Se os desvios costumam ter o mesmo sinal, covariância positiva; sinais opostos, negativa. Se se alternam sem associação linear aparente, próxima de zero.

Problema da covariância bruta: suas unidades são multiplicadas. Consumo (kWh) versus temperatura (°C) produz unidades de kWh·°C. Escalar X por 1.000 também multiplica sua covariância por 1.000. Isso dificulta comparar relações.

4.5.1 Exemplo

Para $X = [8, 9, 10, 11, 12]$ e $Y = [7, 9, 10, 11, 13]$:

$$\bar{X} = 10, \quad \bar{Y} = 10,$$
$$\text{cov}(X,Y) = 3{,}5.$$

O número 3,5 sozinho não diz "associação forte": para isso precisamos de uma medida sem dimensão.

4.6 Correlação de Pearson

$$\boxed{r_{XY} = \frac{\text{cov}(X,Y)}{s_X s_Y}}, \qquad -1 \le r \le 1.$$

Intuição: a covariância é dividida pela escala de cada variável. O resultado fica adimensional. Valores próximos de $+1$ indicam associação **linear** crescente; próximos de -1, decrescente; próximos de zero, ausência de associação linear clara.

No exemplo anterior, $r \approx 0{,}98995$. É uma relação linear forte **nesses cinco pares**. Não demonstra causalidade, validade em novos dados ou estabilidade ao longo do ano.

4.6.1 Seis armadilhas de correlação

1. **Causalidade:** variável omitida pode explicar ambas.
2. **Mistura de populações:** duas classes de consumidor podem produzir correlação global inexistente dentro de cada classe (efeito de agregação/Simpson).
3. **Outliers:** um ponto muito distante pode criar ou eliminar associação linear.
4. **Não linearidade:** relação em U pode ter $r \approx 0$ apesar de associação forte.
5. **Dependência temporal:** duas séries com tendência comum podem apresentar correlação espúria.
6. **Defasagem:** temperatura e consumo podem se relacionar com atraso; uma correlação instantânea pode perder isso.

Regra: olhe o gráfico de dispersão, as unidades, a classe de UC e o tempo antes de confiar no coeficiente.

4.7 Correlação de Spearman

Pearson compara intensidades lineares. Spearman compara a ordem/ranking dos valores, usando a correlação de Pearson aplicada aos postos:

$$\boxed{\rho_S = \text{corr}(\text{rank}(X), \text{rank}(Y)).}$$

Pode captar associações monotônicas não lineares e costuma ser menos sensível a alguns valores extremos, embora empates e muitos zeros exijam cuidado. Se o consumo aumenta de maneira consistentemente não linear com uma variável de contexto, Spearman pode revelar essa tendência mesmo quando Pearson não a descreve bem.

Não substitua automaticamente Pearson por Spearman. Se sua hipótese física envolve proporcionalidade/linearidade, Pearson pode ser a medida mais coerente.

4.8 Escala: por que 10.000 pode dominar 0,02

Imagine cada UC como ponto em duas coordenadas:

- $x_1 =$ consumo médio variando de 5 a 5.000 kWh;
- $x_2 =$ fator de carga variando de 0 a 1.

Se calcularmos distância euclidiana direta,

$$d(a, b) = \sqrt{(x_{1,a} - x_{1,b})^2 + (x_{2,a} - x_{2,b})^2},$$

a primeira variável quase sempre domina. Isso **não prova** que ela seja mais importante; é consequência da escolha de unidades. Métodos de distância, PCA e muitos métodos lineares exigem avaliação explícita de escala. Modelos de árvore, em geral, são menos afetados por reescalonamentos monotônicos simples, mas ainda podem ser afetados por qualidade, representação e redundância.

4.9 Padronização (z-score)

$$\boxed{z_i = \frac{x_i - \mu_{\text{train}}}{\sigma_{\text{train}}}.}$$

Em palavras: *quantos desvios-padrão esse ponto está acima ou abaixo da média da amostra usada para aprender a escala?* Com $\mu = 100$, $\sigma = 20$, $x = 140$ dá $z = 2$.

Quatro cuidados:

- $z = 2$ não significa "2% de probabilidade de fraude".
- Em distribuições muito assimétricas, interpretação por curva normal pode ser inadequada.
- Se $\sigma = 0$, a escala precisa de política explícita; um denominador zero não pode ser ignorado.
- Os parâmetros μ e σ são **aprendidos no treino**, nunca em treino+teste. Recalcular o scaler com dados futuros pode causar *leakage*.

4.10 Robust scaling e min-max

Outras transformações comuns:

$$\boxed{z_{\text{robusto}} = \frac{x - \tilde{x}_{\text{train}}}{IQR_{\text{train}}}}, \qquad \boxed{x' = \frac{x - x_{\text{min,train}}}{x_{\text{max,train}} - x_{\text{min,train}}}}.$$

Robust scaling usa mediana/IQR para reduzir influência de extremos na estimativa da escala. Min-max remapeia os valores observados de treino para aproximadamente [0,1], mas **não** garante [0,1] para valores futuros. Mais importante: uma transformação puramente estatística não substitui **normalização física**. Converter tensão V para V/V_{nominal} (per-unit) resolve um problema físico distinto de um z-score treinado.

4.11 Distribuição empírica e percentis de score

A função de distribuição empírica é

$$\boxed{\widehat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}(x_i \le x).}$$

Ela responde: "qual parcela das observações ficou em ou abaixo de x?". É útil para expressar a raridade **em uma população de referência**. Se um score foi classificado como percentil 99 de estranheza, isso pode significar que ele excede aproximadamente 99% dos scores de referência. **Não** significa automaticamente 99% de chance de fraude.

4.12 Laboratório: correlação e scaling sem leakage

```
import numpy as np
from sklearn.preprocessing import StandardScaler, RobustScaler

X_train = np.array([
    [12.0, 0.44], [14.0, 0.55], [16.0, 0.60],
    [18.0, 0.62], [21.0, 0.67], [70.0, 0.75],
])
X_test = np.array([[25.0, 0.70], [90.0, 0.80]])

print("Pearson (treino):", np.corrcoef(X_train.T)[0, 1])

standard = StandardScaler().fit(X_train)
robust = RobustScaler().fit(X_train)
print("Z standard no teste:\n", standard.transform(X_test))
print("Z robusto no teste:\n", robust.transform(X_test))

# ERRADO: scaler.fit_transform(np.vstack([X_train, X_test]))
# Isso permitiria que o conjunto futuro alterasse a escala aprendida.
```

Interpretação: compare como o valor 70 kWh altera a média e desvio-padrão do scaler, e como muda a transformação do teste. Não conclua qual é "melhor" apenas olhando as magnitudes transformadas; avalie a finalidade e o comportamento do modelo posterior.

4.13 Exercícios do Dia 2

E2.1. Se $Y = 3X + 7$, com X não constante, qual a correlação de Pearson entre X e Y? E se $Y = -3X + 7$?

E2.2. Explique por que temperatura e demanda elétrica podem apresentar correlação sem que cada kWh adicional seja provocado diretamente pela temperatura.

E2.3. Para treino $[10, 20, 30]$, calcule a média, o desvio-padrão populacional da amostra de treino e o z-score do valor de teste 40 usando esses parâmetros.

E2.4. Por que “95º percentil de anomalia” não é a mesma coisa que “95% de probabilidade de furto”? O que seria preciso para afirmar a segunda frase?

E2.5. Consumo estimado cadastral e consumo observado têm correlação elevada. Isso significa que uma dessas colunas deve ser eliminada? Responda com duas hipóteses plausíveis.

4.14 Checkpoint de domínio

- ☐ Interpreto Pearson e Spearman sem confundi-los com causalidade.
- ☐ Sei por que olhar só para o coeficiente, sem gráfico, é perigoso.
- ☐ Entendo o efeito da escala em distância e PCA.
- ☐ Sei calcular z-score com parâmetros **somente do treino**.
- ☐ Sei que um percentil de score não é uma probabilidade calibrada de fraude.

Entregável: matriz de correlação de 5 features, 2 gráficos de dispersão e comentários explicando possíveis relações causais equivocadas.

5 Dia 3 — Machine Learning: o que significa aprender a partir dos dados?

Leitura-base: Géron, cap. 1 (*The Machine Learning Landscape*), sobretudo *What Is Machine Learning?*, *Types of Machine Learning Systems*, *Main Challenges of Machine Learning* e *Testing and Validating*. **Pré-requisito:** Dias 1 e 2.

5.1 Primeiro, em palavras simples

Um programa tradicional recebe uma regra: "se a tensão estiver abaixo de certo limite, marque a leitura". Um modelo de Machine Learning recebe exemplos e tenta **ajustar uma regra a partir deles**. As duas abordagens não competem obrigatoriamente. Se existe um critério físico ou regulatório bem especificado, codificá-lo diretamente pode ser preferível. Se queremos reconhecer padrões complexos que não sabemos escrever em poucas regras, um modelo aprendido pode ajudar.

O risco é o modelo aprender **atalhos errados**: tipos de medidor, bairros, ausência de dados, data de instalação ou qualquer outra variável associada ao conjunto de treino, mas sem ligação com o fenômeno investigado.

5.2 Visão macro para AMI

```
DADOS                 PROBLEMA                    MÉTODO

FA, RA, V, I          "qual padrão é comum?"      não supervisionado
fraude confirmada     "irregular ou regular?"     supervisionado
limite regulatório    "violou a faixa?"          regra determinística
série diária          "mudou o regime?"          detecção temporal
alarme de tampa       "houve evento?"            regra / evidência
```

A pergunta vem **antes** do algoritmo. "Usar Isolation Forest" não é objetivo de pesquisa; "caracterizar comportamentos elétricos que exigem investigação" pode ser.

5.3 As quatro peças de qualquer estudo

1. **Unidade de análise:** o que uma linha representa?
2. **Entrada X:** quais números o modelo pode conhecer?
3. **Objetivo:** prever uma variável y, identificar grupos, produzir score de raridade ou detectar mudança temporal?
4. **Critério de avaliação:** como saber se o método cumpre o objetivo?

Se uma dessas quatro peças estiver ambígua, a qualidade do código não resolve o problema metodológico.

5.4 Modelo, parâmetro, hiperparâmetro e predição

Um modelo pode ser representado genericamente por

$$\boxed{\hat{y} = f_\theta(X; \lambda)},$$

onde X é entrada, θ são parâmetros aprendidos e λ são escolhas de configuração (hiperparâmetros). Para um detector não supervisionado, a saída pode ser um score s:

$$\boxed{s = g_\theta(X; \lambda).}$$

Exemplo simples: uma regressão linear aprende coeficientes θ a partir de pares entrada–resposta. O número de árvores em uma floresta é uma escolha de hiperparâmetro. Em um detector de anomalia, o valor retornado por `score_samples` não possui necessariamente o mesmo sentido ou escala do score produzido por outro algoritmo.

Palavra importante: *fit* é aprender parâmetros usando os dados de referência; *predict* ou *score* aplica o mecanismo aprendido. Sem saber em que dados `fit` foi chamado, não há como interpretar seriamente uma previsão.

5.5 Supervisionado, não supervisionado e semissupervisionado

5.5.1 Supervisionado

Temos pares (x_i, y_i) e tentamos aprender $f(x) \approx y$. Exemplo: classificação de fraude **confirmada por inspeção de campo**, desde que os rótulos sejam confiáveis e representativos. O target precisa ser independente da decisão que estamos tentando validar. Se rotulamos "fraude" com a mesma regra que a feature descreve, o modelo pode só reproduzir a regra.

5.5.2 Não supervisionado

Temos X, mas não necessariamente y. Procuramos grupos, estrutura ou observações raras. Uma UC que recebe score alto de anomalia está **atípica segundo o método e a população de referência**, não necessariamente irregular. No nosso pipeline, `S_comm` e um possível `S_elec` são análises especializadas que podem começar sem labels confiáveis.

5.5.3 Semissupervisionado / novelty detection

Existe um conjunto de referência presumidamente normal e tentamos detectar amostras diferentes. A exigência é forte: a referência deve ter qualidade suficiente e conter o comportamento que consideramos aceitável. Se o treino contiver períodos históricos já comprometidos, o "normal" aprendido pode incorporar o problema.

5.5.4 Regras determinísticas

Uma função definida por especialista/standard, sem treinamento estatístico. Exemplo genérico: verificar se um valor ultrapassa limite **aplicável a sua classe de tensão, modalidade e condição de medição**, segundo regulamento vigente. A regra detecta violação da regra; ela não prova automaticamente causa ou fraude.

5.6 O que é uma amostra no TCC?

Há uma sutileza crucial: o banco pode ter milhões de linhas de leituras, mas o modelo pode usar **uma linha por UC e data de corte**, com estatísticas de uma janela de 30 dias. A quantidade de exemplos

para o treinamento não é “número de pacotes” e sim “número de linhas efetivamente usadas como amostras”.

Representação típica:

$$\boxed{\text{amostra}_i = (\text{UC}_i, t_{\text{cutoff},i}, W_i)}.$$

Um exemplo de contrato:

Tipo	Campo	Entra em X?	Observação
ID	`id__uc_id`	Não	Chave de negócio
Metadado	`meta__cutoff_date`	Não	Referência temporal
Metadado	`meta__data_quality`	Não	Gating de confiabilidade
Feature	`x__hist_fa_sum_median`	Sim	Consumo típico
Feature	`x__hist_fa_sum_mad`	Sim	Variabilidade robusta
Feature	`x__trend_fa_slope`	Sim	Inclinação histórica
Alvo	`y__target_irregularity`	Só supervisão	Não usar como entrada

Os prefixos são uma **convenção de engenharia do projeto**, não exigência universal do scikit-learn. Eles tornam mais difícil incluir acidentalmente identificadores, rótulos ou metadados no vetor das features.

5.7 Matriz de características

Para n amostras e p features numéricas:

$$\boxed{X \in \mathbb{R}^{n \times p}}, \qquad X_{ij} = \text{valor da feature } j \text{ na amostra } i.$$

Exemplo com três UCs e duas features:

$$X = \begin{bmatrix} 12 & 1 \\ 15 & 2 \\ 45 & 4 \end{bmatrix},$$

em que a primeira coluna poderia ser mediana de kWh/dia e a segunda MAD. Se mudamos a primeira coluna de kWh para Wh sem reescalar adequadamente, muitos modelos baseados em distância passam a ver uma geometria distinta, embora **a física seja exatamente a mesma**.

Categorias: classe residencial/comercial e ligação mono/bi/trifásica são atributos categóricos, não medidas contínuas. Codificar “residencial=1, comercial=2, industrial=3” e usar distância entre números impõe uma ordem que talvez não exista. Escolha representação conforme o modelo e a hipótese.

5.8 Overfitting e underfitting

Overfitting: o método aprende detalhes/ruídos particulares do treino e perde desempenho fora dele. Exemplo: reconhecer o ID do medidor em vez de entender comportamento de consumo.

Underfitting: o método é simples demais para expressar a estrutura relevante. Exemplo: um único limiar de consumo ignora classe, horário, sazonalidade e histórico.

Nenhum dos dois pode ser diagnosticado exclusivamente pela beleza de um gráfico do treinamento. Precisamos de validação representativa e, preferencialmente, avaliação temporal independente.

5.9 Generalização: onde o modelo precisa funcionar?

Defina o cenário-alvo:

- **Mesmas UCs, datas futuras:** o teste deve ser temporal.
- **UCs nunca vistas:** segregação por entidade pode ser necessária.
- **Novas regiões/circuitos:** teste geográfico ou por grupo de rede.
- **Novos fabricantes ou gerações de medidor:** teste de generalização de domínio.

Essas tarefas são diferentes. **GroupKFold por UC não substitui split temporal** se o problema real exige prever o futuro de UCs existentes; e split temporal sozinho não mede desempenho em UCs jamais vistas. Também não se deve criar features em períodos futuros e depois aplicá-las a amostras de treino passadas.

5.10 Data drift, concept drift e mudança real

- **Data drift:** distribuição das entradas muda; por exemplo, penetração de medidores de novo fabricante.
- **Concept drift:** relação entre entradas e alvo muda; por exemplo, regime de operação relevante para classificação de irregularidades.
- **Mudança de regime de uma UC:** o próprio consumo/produção pode mudar de patamar.

São ideias relacionadas, mas não idênticas. A mesma mudança operacional pode afetar uma UC sem significar que o modelo global perdeu validade. Evite usar os três termos como sinônimos.

5.11 O perigo das métricas “bons números”

Imagine uma base onde 99% dos casos são rotulados como regulares. Um classificador que prevê “regular” para todos tem **99% de accuracy**, mas detecta zero irregularidades. Em problemas raros, examine *precision*, *recall*, matriz de confusão e custo dos falsos positivos e falsos negativos. Sem um target confiável, métricas supervisionadas não estão disponíveis da mesma forma.

Para modelos não supervisionados, uma taxa de observações marcadas pode ser produzida por uma **política de limiar**. O fato de um algoritmo marcar 5% não valida que 5% sejam irregularidades. De forma semelhante, marcar 100% não é prova de fraude generalizada: pode indicar erro de sinal, threshold, schema, scaler ou mudança de população.

5.12 Uma primeira ficha de modelo

```
Nome: detector_comunicacao
Problema: identificar medidores com comportamento de telecom atípico
Unidade de análise: NIO × janela de 30 dias
X permitido: cobertura, gaps, contagens de alarmes de comunicação
X proibido: fraude confirmada, target futuro, ID bruto sem justificativa
Modelo: definir após explorar distribuição
Saída: score de atipicidade de comunicação
Evidência externa: histórico de indisponibilidade / logs da infraestrutura
O que não significa: probabilidade calibrada de fraude
```

Essa ficha antecede qualquer escolha de Isolation Forest, ECOD ou outro algoritmo.

5.13 Laboratório: inspecionar um dataset de ML

```
import polars as pl

amostras = pl.DataFrame({
    "id__uc_id": ["UC01", "UC02", "UC03"],
    "meta__cutoff_date": ["2026-10-20"] * 3,
    "meta__data_quality": [0.99, 0.53, 0.95],
    "x__hist_fa_sum_median": [12.0, 17.0, 45.0],
    "x__hist_fa_sum_mad": [1.0, 3.5, 7.0],
    "y__target_irregularity": [None, None, None],
})

feature_cols = [c for c in amostras.columns if c.startswith("x__")]
X = amostras.select(feature_cols)
metadados = amostras.select([c for c in amostras.columns if c.startswith("meta__")])
print("X shape:", X.shape)
print("Colunas em X:", feature_cols)
print("Meta não entra em X:", metadados.columns)
```

Pergunta de laboratório: por que uma UC com `data_quality=0.53` não deveria receber um score elétrico tão confiável quanto outra com 0.99? A resposta diz respeito à **validade da inferência** e não à necessidade de injetar missingness em X_{elec}.

5.14 Exercícios do Dia 3

E3.1. Você tem 2 milhões de medidores e 12 meses de histórico. Se o dataset tem uma linha por UC por mês, o máximo teórico de linhas é quantas, antes de considerar faltantes e trocas?

E3.2. Uma coluna `y__fraud_confirmed` foi incluída em `X` por engano. O modelo atingiu desempenho excelente. O que ocorreu?

E3.3. Seu Isolation Forest marca 20% das UCs como anômalas. Cite três motivos pelos quais isso não informa diretamente quantas fraudes existem.

E3.4. Treinar com UCs de Curitiba e testar em municípios novos mede a mesma capacidade que treinar nos primeiros meses e testar nos meses futuros das mesmas UCs?

E3.5. Classifique: (a) regra de tensão; (b) clustering de perfis; (c) previsão de irregularidade confirmada; (d) score de gaps sem rótulos.

5.15 Checkpoint de domínio

- ☐ Defino exatamente a linha, coluna, entrada e target de cada tarefa.
- ☐ Diferencio regra física, aprendizado supervisionado e não supervisionado.
- ☐ Sei por que anomalia não equivale a fraude.
- ☐ Identifico duas formas diferentes de generalização.
- ☐ Consegue explicar o sentido operacional de um score sem inventar probabilidades.

Entregável: um contrato de dataset com dez colunas, marcadas entre `id__`, `meta__`, `x__` e `y__`, mais uma ficha de modelo.

6 Dia 4 — Pipeline de Machine Learning: como impedir que a resposta contamine a pergunta?

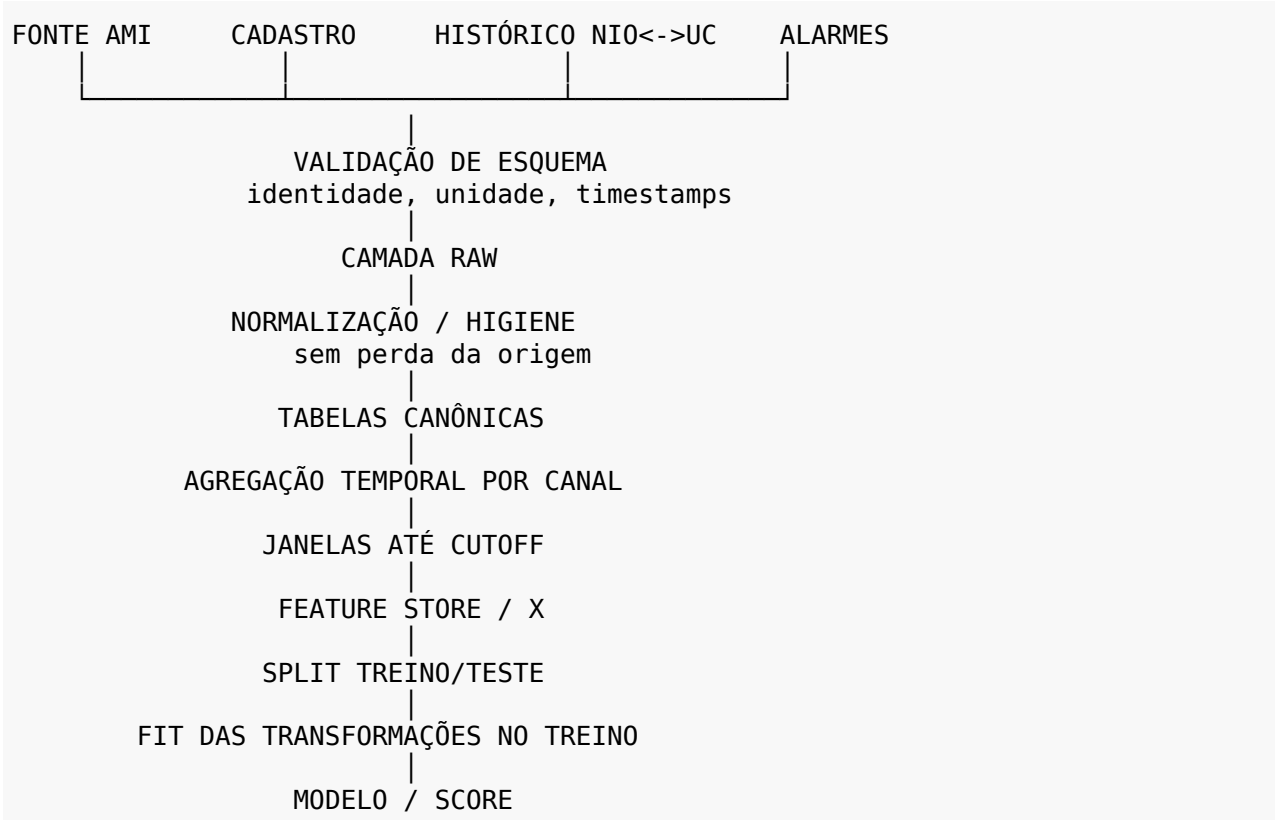
Leitura-base: Géron, cap. 2 (*End-to-End Machine Learning Project*): formulação do problema, coleta, análise exploratória, preparação, transformações, treinamento e avaliação. **Pré-requisito:** Dia 3. **Objetivo:** definir um caminho reprodutível de RAW até score, com controles explícitos de temporalidade e qualidade.

6.1 Primeiro, em palavras simples

Suponha que queremos descobrir se o consumo mudou **até 20 de outubro**. Se usamos uma leitura de **21 de outubro** para calcular uma média histórica, o sistema está "vendo o futuro". Se preenchermos uma lacuna de setembro usando medições de novembro, também estaremos usando o futuro — mesmo que esse preenchimento aconteça antes de criar o dataset de ML. Isso é *data leakage*: o modelo recebe informação que não estaria legitimamente disponível na situação que pretendemos simular.

Um pipeline não é só uma sequência de funções. É um **contrato de quando cada informação existia, como foi transformada e em que conjunto pode ser aprendida**.

6.2 A arquitetura que você precisa conseguir desenhar



```
                    |
          AVALIAÇÃO E RASTREIO
```

O fluxo acima é uma **proposta de organização do projeto**, aplicada ao conteúdo geral do Géron. Não está sendo apresentado como código já implementado ou validado em todos os sistemas da concessionária.

6.3 Etapa 1 — delimitar o problema antes do código

Escreva a pergunta em linguagem operacional:

> Em uma data de corte definida, quais unidades apresentam mudanças incomuns no comportamento de energia ativa, dada uma quantidade suficiente de observações válidas e levando em conta características de sua operação?

Essa pergunta define decisões técnicas: qual UC, qual canal, qual janela, como medir qualidade e como avaliar. Se a meta fosse diagnosticar comunicação, as features e o gating seriam outros. **Não misture objetivos só para produzir um score único.**

6.4 Etapa 2 — contrato da observação

Para cada campo bruto, documente:

Propriedade	Pergunta que deve ser respondida
`source_system`	Qual sistema produziu o dado?
`meter_id` / NIO	Qual equipamento? Houve troca?
`uc_id`	A qual UC correspondia nesse instante?
`timestamp`	Instante de medição, evento ou recebimento?
`timezone`	UTC? Brasília? Horário local sem offset?
`channel`	Energia ativa direta, reversa, tensão, corrente?
`unit`	kWh, Wh, kW, V, A, ou código?
`cadence`	Intervalo esperado do canal naquele equipamento?
`quality_flags`	Dado validado, substituído, duplicado, corrigido?
`ingested_at`	Quando ficou disponível para a análise?

Uma leitura de energia acumulada não pode ser somada como se fosse energia incremental. A semântica do canal deve ser validada antes da feature. Uma timestamp registrada em UTC e outra sem timezone precisam ser padronizadas de maneira explícita; apenas remover o timezone não é conversão.

6.5 Etapa 3 — UC × NIO e histórico de vigência

Uma UC pode manter o identificador de negócio após a substituição do medidor. Por isso, uma tabela corrente de vínculo UC–NIO é insuficiente para reconstruir o passado. O vínculo deve respeitar instalação/retirada:

$$\boxed{t_{\text{instalação}} \leq t < t_{\text{retirada}}}$$

com $t_{\text{retirada}} = +\infty$ quando não houve retirada. Os intervalos semiabertos são uma **convenção recomendada** para evitar duplicação no instante de troca; a implementação precisa respeitar a definição efetiva dos campos de origem.

6.5.1 Exemplo

- NIO-A instalado em UC-01 de 01/09 às 00h até 15/10 às 10h.
- NIO-B instalado em UC-01 desde 15/10 às 10h.

Uma medição do NIO-A às 09h pertence à UC-01. Uma medição do NIO-A às 11h deve ser investigada, não associada automaticamente por usar a UC atual. Se houver sobreposição temporal de vínculos, crie validação/alerta antes da agregação.

6.6 Etapa 4 — data de corte e janela histórica

Escolha uma convenção inequívoca. Neste material, `cutoff_ts` é o instante **exclusive** de disponibilidade para a agregação. Uma janela de 30 dias é

$$\boxed{W_{30}(t_c) = \{t : t_c - 30 \text{ dias} \leq t < t_c\}}.$$

Se t_c = 2026-10-21 00:00:00 (America/Sao_Paulo), a janela contém observações a partir de 21/09 às 00h, excluindo as de 21/10 a partir de 00h. Outra convenção de "até o fim do dia 20" é equivalente se aplicada corretamente. O nome `cutoff_date` sozinho não informa a hora, timezone ou inclusividade; registre-os no schema.

Disponibilidade vs. tempo de medição. Dados podem chegar tarde. Mesmo uma medição com `measurement_time<t_c` pode só ter sido ingerida depois de t_c. Para **backtest operacional realista**, o filtro deve considerar também o momento de disponibilidade (`ingested_at ≤ t_c`) ou explicitar que a análise é retrospectiva com dados consolidados. Isso é especialmente importante em sistemas AMI com atrasos de recepção.

6.7 Etapa 5 — a cadência é propriedade do canal

Se energia intervalar chega a cada 5 min e tensão instantânea a cada 15 min, usar uma única grade de 5 min faria parecer que dois terços da tensão está "faltando". Isso não é falha de comunicação; é erro de expectativa.

Defina por canal e por período:

$$N_{\text{esperado},c}(W) = \text{nº de instantes efetivamente programados para canal } c \text{ em } W.$$

$$\boxed{C_c(W) = \frac{N_{\text{válido},c}(W)}{N_{\text{esperado},c}(W)}}, \quad N_{\text{esperado},c} > 0.$$

Se uma UC recebeu 90 de 96 observações de energia esperadas, a completude do canal naquele dia é $90/96 = 0{,}9375$. Isso não prova que as seis ausentes representam falha de modem. A causa continua em aberto.

O mesmo cuidado vale a canais que **não existem** naquele tipo de medidor. Ausência de fase L3 em medidor monofásico não é missing elétrico; é ausência estrutural. Consulte configuração antes de contar leituras esperadas.

6.8 Etapa 6 — transformação: `fit` não é `transform`

No scikit-learn, transformações aprendidas têm dois momentos:

- `fit(X_train)`: aprende mediana para imputação, média/desvio para scaler, categorias para encoding, etc.
- `transform(X)`: aplica essas regras a qualquer conjunto compatível.

Para um pipeline correto:

$$\hat{\phi} = \text{fit}(X_{\text{train}}), \qquad X'_{\text{test}} = \text{transform}_{\hat{\phi}}(X_{\text{test}}).$$

Treino e teste não devem compartilhar **aprendizado de parâmetros** de pré-processamento. Uma transformação determinística por linha (por exemplo, $V/V_{nominal}$ usando valor cadastral conhecido naquele instante) não é o mesmo problema de aprender um scaler sobre toda a população futura.

6.8.1 Exemplo correto com pipeline

```
import numpy as np
from sklearn.pipeline import make_pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import RobustScaler
from sklearn.ensemble import IsolationForest

# Cada linha é uma amostra UC×cutoff; colunas numéricas autorizadas.
X_train = np.array([[12.0, 1.0], [13.0, 0.7], [14.0, 1.3], [11.0, 1.1]])
X_test = np.array([[40.0, 0.6], [np.nan, 1.0]])

pipeline = make_pipeline(
    SimpleImputer(strategy="median", add_indicator=False),
    RobustScaler(),
    IsolationForest(n_estimators=100, random_state=42),
)
pipeline.fit(X_train)
print(pipeline.decision_function(X_test))
```

Limitação proposital do exemplo: é didático, com dados minúsculos e sem garantias de representatividade. O uso do Isolation Forest aqui serve para mostrar `fit/transform` dentro do pipeline, **não** para validar o detector do TCC. Um tratamento de missing com imputação pode ser inválido para algumas features físicas; no projeto, amostras sem cobertura adequada devem ser tratadas antes da pontuação elétrica.

6.9 Etapa 7 — cinco modalidades de leakage

Vazamento	Exemplo	Correção
Temporal	média de 30 dias usa observações posteriores ao cutoff	filtro por intervalo e disponibilidade
De identidade	mesmo medidor/UC em treino e teste quando meta é generalizar a UCs novas	split por grupo, alinhado à tarefa
De transformação	scaler ou imputer ajustado no conjunto inteiro	`Pipeline.fit` só no treino
De rótulo	alarme “fraude confirmada” entra em X para prever fraude	excluir target e proxies indevidos
De agregação	estatística de janela atravessa período reservado para teste	controlar a data de geração de features e horizonte

Vazamento	Exemplo	Correção
De versão cadastral	classe/estado da UC consultado apenas no cadastro atual para uma janela antiga	histórico de snapshots com vigência
De publicação	evento chegou após cutoff, mas é usado como conhecido no backtest	filtrar por disponibilidade

Importante: treinamentos em janelas sucessivas da mesma UC podem compartilhar medições históricas. Isso não é sempre "vazamento" por definição, mas cria **dependência forte** entre amostras e pode invalidar estimativas ingênuas de desempenho. Registre sobreposição e use avaliação temporal com embargo/purge quando a tarefa e o horizonte exigirem.

6.10 Etapa 8 — como validar sem prometer fraude

Se houver rótulos confirmados, métricas supervisionadas fazem sentido, desde que haja proveniência e amostragem conhecida. Sem rótulos, comece por:

- estabilidade dos scores entre períodos similares;
- inspeção de casos extremos;
- ablação de features (retirar grupos para observar efeito);
- reprodutibilidade de treino;
- comparação com referências simples;
- análise por classe, fase, fabricante, região e completude;
- checagem explícita de qual fração foi sinalizada por **política de limiar**, separada do significado físico.

Ninguém deve afirmar "o modelo detectou 97% das fraudes" sem ground truth adequado. Um detector de comunicação com poucos falsos positivos contra indicadores conhecidos de telecom também não está automaticamente validado para fraude elétrica.

6.11 Mini-contrato de uma feature

```
feature_id: x__hist_fa_sum_median
entidade: UC
cutoff: timestamp local convertido para UTC, limite superior exclusivo
janela: últimos 30 dias completos
fonte: energia ativa intervalar direta, com semântica validada
agregação: soma por dia, depois mediana dos dias elegíveis
unidade: kWh/dia
requisitos: cobertura mínima por dia e janela — política versionada
outlier_handling: não eliminar extremos sem justificativa
leakage: nenhuma medição/ingestão posterior ao cutoff
versão: feature_v1
```

Ponto essencial: a política de "dia elegível" pode alterar a feature tanto quanto a fórmula matemática. Documentá-la é tão importante quanto documentar a mediana.

6.12 Um pipeline também precisa de testes

- **Teste de unidade:** converter Wh para kWh preserva energia?

- **Teste de cardinalidade:** um medidor tem no máximo um vínculo UC válido em cada timestamp, salvo exceções documentadas?
- **Teste de cobertura:** a grade esperada corresponde à configuração por canal?
- **Teste temporal:** nenhum valor posterior ao cutoff entra na janela?
- **Teste de esquema:** nenhum campo `id__`, `meta__` ou `y__` aparece em X?
- **Teste de persistência:** reexecutar a mesma versão com mesmos dados resulta em features equivalentes?

6.13 Exercícios do Dia 4

E4.1. O cutoff é 2026-10-21 00:00 no horário de Brasília e a janela dura 7 dias. Quais instantes entram? Qual não entra?

E4.2. Você ajustou `StandardScaler` em treino+teste. Por que isso é vazamento, mesmo que o scaler não veja `y`?

E4.3. Um medidor gera energia a cada 5 minutos e tensão a cada 15 minutos. Qual o total esperado para cada canal em um dia de 24 horas totalmente configurado?

E4.4. Uma leitura de 20/10 chegou ao banco em 23/10. Pode ser usada para simular decisão operacional tomada em 21/10? E numa análise retrospectiva realizada em novembro?

E4.5. O consumo `FA` foi agregado sobre NIO-A e NIO-B na mesma UC. Qual a primeira validação a fazer antes de afirmar que o total pertence a uma janela de 30 dias?

E4.6. Por que GroupKFold por UC não resolve sozinho o problema de informação futura no mesmo pipeline?

6.14 Checkpoint de domínio

- ☐ Sei definir cutoff como instante, não apenas texto de data.
- ☐ Consigo reconstruir a vigência UC–NIO no tempo.
- ☐ Distingo tempo de medição de tempo de disponibilidade.
- ☐ Sei onde `fit` pode ocorrer e onde não pode.
- ☐ Consigo citar cinco tipos de leakage com correção concreta.
- ☐ Não uso completude como feature elétrica por acidente.

Entregável: fluxograma da versão mínima do pipeline e tabela dos campos que exigem vigência ou temporalidade.

7 Dia 5 — Séries temporais: por que a ordem dos dados muda tudo?

Leitura-base: Hyndman & Athanasopoulos, 2ª ed., cap. 2 (*Time Series Graphics*): visualização, padrões e defasagens. **Pré-requisito:** Dia 4. **Objetivo:** pensar em energia elétrica como uma trajetória no tempo, e não como um saco de valores independentes.

7.1 Primeiro, em palavras simples

Um consumo de 2 kWh às 3h da manhã pode significar algo diferente de 2 kWh às 18h. Uma sequência de consumos baixos durante 30 dias pode ser mais interessante do que um único dia baixo. Por isso, **horário, ordem e duração** das medições são parte do dado.

Em um gráfico, a série de uma casa pode exibir pico noturno; a de um comércio, pico em horário de funcionamento. Se embaralharmos as linhas, os dois conjuntos podem conservar média e desvio-padrão, mas **perdem a forma do dia**, justamente o que os distingue.

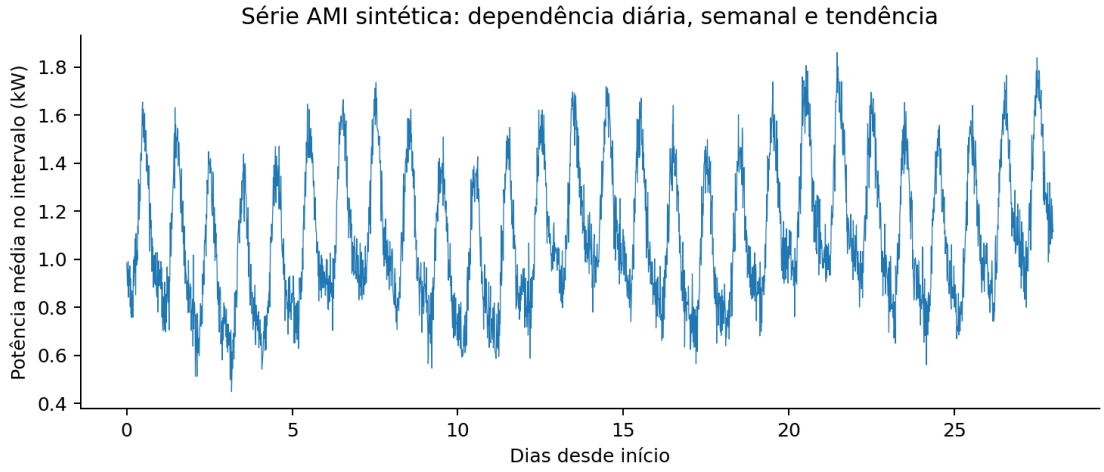


Figura 7.1: Série AMI sintética: comportamento de múltiplas escalas

7.2 Visão macro

```
MÉTRICA OBSERVADA + TIMESTAMP
                  |
         ORDEM / CADÊNCIA
                  |
                  ▼
    SEQUÊNCIA DE INTERVALOS
                  |
        ┌─────────┼─────────┐
        ▼         ▼         ▼
    NÍVEL     FORMA      MUDANÇA
```

```
            |
            ▼
      PERFIL DE CARGA
```

O tempo pode importar de pelo menos quatro maneiras: **nível absoluto**, **ciclo do dia**, **diferença entre dias úteis e fins de semana** e **mudanças persistentes**. Essas dimensões não são plenamente representadas por uma média global.

7.3 Formalização de uma série

Uma série univariada pode ser expressa por

$$\{(t_i, x_i)\}_{i=1}^{n},$$

onde t_i é o instante associado ao valor x_i. Uma série multivariada reúne vários canais:

$$\mathbf{x}_t = \begin{bmatrix} FA_t & RA_t & V_{L1,t} & I_{L1,t} & \cdots \end{bmatrix}^{\top}.$$

Cuidado: isso não garante que todos os canais foram observados no mesmo instante. Uma matriz alinhada num grid único pode conter valores não observados. Tais posições devem continuar identificadas como ausentes, não ser automaticamente preenchidas com zero.

7.4 Energia, potência e duração

Se $E_{[t,t+\Delta t)}$ é energia ativa incremental de um intervalo, a potência média associada ao mesmo intervalo é

$$\boxed{\overline{P}_{[t,t+\Delta t)} = \frac{E_{[t,t+\Delta t)}}{\Delta t}},$$

com E em kWh, Δt em horas e $\overline{P}$ em kW.

Exemplo: **0,75 kWh em 15 minutos** corresponde a $0,75/0,25 = 3,0$ kW de potência média no intervalo. Não significa que a carga ficou exatamente em 3 kW em todos os instantes internos; é apenas uma média temporal inferida da energia.

Cadência	Intervalos em 24 h	Duração (h)	Potência média de 0,75 kWh/intervalo
5 min	288	$1/12$	9 kW
10 min	144	$1/6$	4,5 kW
15 min	96	$1/4$	3 kW

Regra essencial: o valor de energia só pode ser transformado em potência quando temos certeza da janela de integração. Uma leitura de tensão instantânea ou um contador acumulado exige outras interpretações. Os valores de 288, 144 e 96 pressupõem dia de 24 horas e operação contínua conforme a cadência definida.

7.5 Timestamp: começo, fim ou momento de chegada?

A mesma coluna `timestamp` pode representar:

- começo do intervalo de energia;
- fim do intervalo;
- instante de amostragem de uma grandeza instantânea;
- origem de um alarme;
- momento em que o servidor recebeu o registro.

Isso muda qual janela recebe o valor. Se energia integrada entre 23h45 e 00h00 é etiquetada com o **fim do intervalo**, uma agregação cega por `date(timestamp)` pode colocá-la no dia errado. Defina uma convenção como **instante inicial do intervalo** ou normalize explicitamente usando a duração. Regras de agregação devem ser aderentes ao contrato do canal.

Para alarmes, `origin_time` e `acting_time` podem medir coisas distintas; a diferença entre eles não é sinônimo garantido de atraso de rede, pois o relógio do equipamento e os processos intermediários também importam.

7.6 Resampling e agregação

Resampling significa mudar a representação temporal: 15 minutos -> 1 hora -> 1 dia. O operador deve ser coerente com a grandeza:

- **Energia incremental:** normalmente soma dos intervalos válidos.
- **Potência média em janelas de duração uniforme:** média ponderada pela duração (simples se durações iguais).
- **Tensão média:** média pode ter sentido descritivo, mas critérios regulatórios exigem tratamento específico.
- **Demanda máxima:** máximo da potência/demanda definida conforme intervalo regulatório, não soma.
- **Contador acumulado:** diferença entre registros, com tratamento de reset, rollover e troca de medidor.

A decisão de somar energia não pode ignorar o **grau de completude**. Com 8 intervalos faltando, o total parcial é um **limite inferior** do total se sabemos que os incrementos omitidos são não negativos e não existem correções negativas; não é valor diário definitivo.

7.7 Defasagem (lag)

Um *lag* significa olhar para trás. Em uma série regularmente espaçada, o lag k é

$$\boxed{x_{t-k}},$$

onde k conta **passos da série**, não necessariamente dias.

Série	1 passo	1 dia	7 dias
5 min	5 min	288 passos	2016 passos
10 min	10 min	144 passos	1008 passos
15 min	15 min	96 passos	672 passos
Diária	1 dia	1 passo	7 passos

Se não há grade uniforme, **`shift(96)` não equivale necessariamente a "exatamente 24 h antes"**. Um registro faltando altera o alinhamento por posição. Faça o alinhamento temporal por timestamp/cadência antes de interpretar o lag em unidades de tempo.

7.8 Tendência, sazonalidade e ciclos

Tendência: movimento persistente de longo prazo, como consumo médio que cresce ao longo de meses.

Sazonalidade: padrão que se repete com período conhecido, como consumo mais alto à noite ou em dias úteis.

Ciclo: oscilação mais ampla sem período rigidamente fixo; por exemplo, influência macroeconômica ou produção sazonal não totalmente regular.

Ruído/resíduo: parte não explicada pela estrutura escolhida. Nem todo resíduo é erro do sensor; pode incluir comportamento genuíno não modelado.

7.8.1 Exemplo de uma loja

Uma loja pode consumir pouco durante madrugada, muito entre 9h e 18h, pouco aos domingos e mais no verão. Uma queda observada em domingo não é anômala por si só: pode estar totalmente alinhada ao padrão semanal. Já uma queda sustentada em todos os dias úteis durante um mês merece investigação contextual, ainda que as médias de 30 dias escondam parte da transição.

7.9 Amostragem e aliasing: não observar não significa que não aconteceu

O fato de um medidor registrar a cada 15 minutos impõe um limite de resolução. Não podemos reconstruir formas de onda de 60 Hz, harmônicas nem eventos de poucos ciclos com esses pontos. Medidas agregadas podem mostrar consequências de eventos curtos, mas não sua forma temporal exata.

Aliasing, de maneira intuitiva, ocorre quando a amostragem é insuficiente para distinguir certas variações rápidas, que acabam aparecendo deformadas ou não aparecem. Não é preciso dominar a teoria de Fourier neste momento para respeitar o princípio: **a resolução da medição limita o tipo de fenômeno sobre o qual podemos fazer afirmações**.

No TCC, isso impede confundir "baixa tensão média do intervalo" com classificação regulamentar de um afundamento instantâneo de milissegundos. Do mesmo modo, uma mudança diária de patamar é observável na escala de dias mesmo que não saibamos o instante físico de início dentro do dia.

7.10 Como visualizar uma série para entender comportamento

Crie no mínimo quatro gráficos:

1. **Série completa:** mostra mudanças e lacunas grandes.
2. **Uma semana típica:** mostra o padrão de 24 horas e fim de semana.
3. **Perfil médio por hora:** resume a estrutura intradiária.
4. **Distribuição por dia da semana:** revela diferenças de rotina.

Não normalize nem interpole todos os dados antes de olhar os originais. Seu primeiro gráfico deve mostrar a realidade da coleta, inclusive lacunas.

7.11 Laboratório: 15 minutos -> hora/dia

```python
from datetime import datetime, timedelta
import polars as pl

inicio = datetime(2026, 10, 1)
linhas = [
    {"timestamp": inicio + timedelta(minutes=15 * i), "energia_kwh": 0.25}
    for i in range(96)
]
# Dados sintéticos: um dia com 96 intervalos completos.
df = pl.DataFrame(linhas).sort("timestamp")

por_hora = df.group_by_dynamic("timestamp", every="1h").agg(
    pl.col("energia_kwh").sum().alias("kwh_hora"),
    pl.len().alias("intervalos_observados"),
)
por_dia = df.group_by_dynamic("timestamp", every="1d").agg(
    pl.col("energia_kwh").sum().alias("kwh_dia"),
    pl.len().alias("intervalos_observados"),
)
print(por_hora.head())
print(por_dia)

# Resultado esperado: 24 kWh no dia e 96 intervalos observados.
```

Advertência: `group_by_dynamic` é apropriado para dados ordenados e intervalos consistentes; em cenários reais, inclua regras de timezone, bordas de janela, duplicatas, vigência do NIO e completude antes de consolidar resultados.

7.12 Exercícios do Dia 5

E5.1. 0,4 kWh em 10 minutos corresponde a que potência média?

E5.2. Um dia de 15 min contém 96 leituras esperadas. Quantas leituras são esperadas em 30 dias completos de 24 horas? E em uma semana?

E5.3. Se uma série tem amostras faltantes e você executa `shift(96)` sem regularizar a grade, que hipótese falsa pode estar fazendo?

E5.4. Por que não devemos somar 96 leituras de tensão de 127 V para produzir “tensão diária”?

E5.5. Para um alarme com `origin_time` anterior a `acting_time`, quais causas além do link de comunicação podem explicar a diferença?

E5.6. O que é mais importante para classificar um curto afundamento de tensão: 96 pontos/dia de tensão média ou uma forma de onda de alta frequência? Explique.

7.13 Checkpoint de domínio

- ☐ Sei diferenciar energia intervalar, potência média e tensão instantânea.
- ☐ Converto 5/10/15 minutos em intervalos por dia e lags equivalentes.
- ☐ Sei explicar como resampling errado muda unidade e significado.
- ☐ Distingo sazonalidade, tendência e evento isolado.
- ☐ Não faço inferências sobre transitórios rápidos a partir de dados de 15 minutos.

Entregável: gráfico diário, semanal, perfil por hora e tabela explicando a cadência de cada canal em análise.

8 Dia 6 — Autocorrelação e decomposição: a série tem memória?

Leitura-base: Hyndman & Athanasopoulos, 2ª ed., §2.8 (*Autocorrelation*), cap. 6 (*Time Series Decomposition*), §§6.1, 6.6 e 6.7; apoio em §3.3 (*Residual Diagnostics*). **Pré-requisito:** Dia 5. **Objetivo:** separar o que se repete, o que muda lentamente e o que sobra sem explicação.

8.1 Primeiro, em palavras simples

Uma padaria tende a consumir energia de maneira semelhante em duas manhãs de dias úteis. Isso é **memória temporal**: saber como estava ontem ou na mesma hora da semana passada ajuda a antecipar como estará hoje. A autocorrelação mede parte dessa semelhança. A decomposição separa um desenho complexo em camadas: padrão de longo prazo, padrão repetido e aquilo que não conseguimos explicar com essas camadas.

Isso é importante porque uma mudança persistente no consumo é mais fácil de enxergar **depois de descontar a rotina normal** do consumidor.

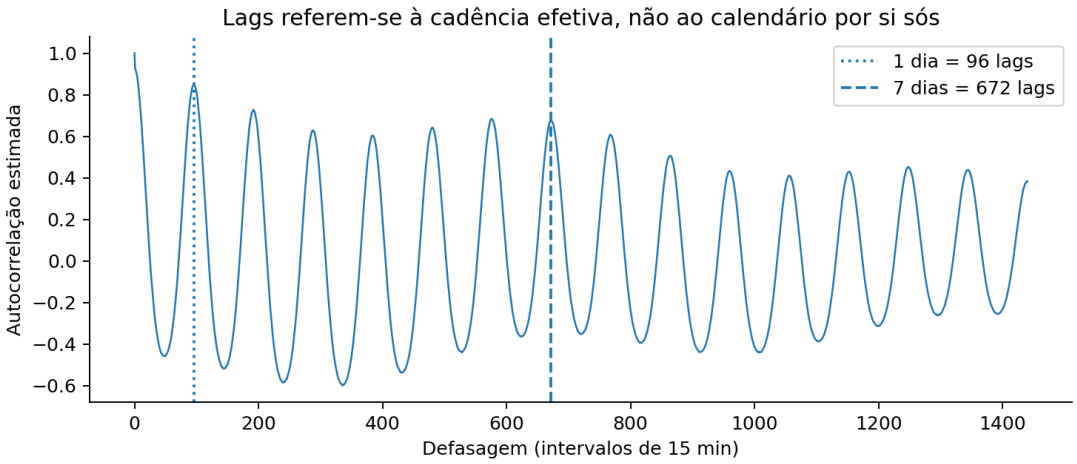
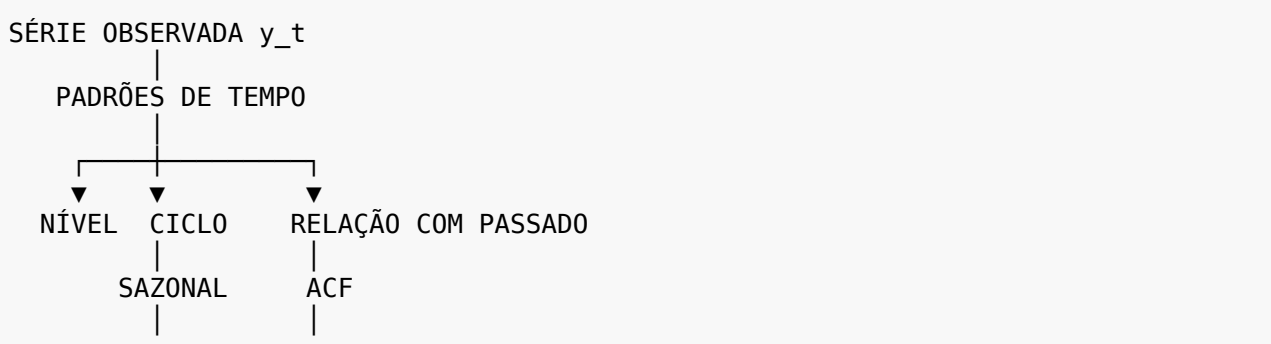


Figura 8.1: Autocorrelação na série sintética de 15 minutos

8.2 Onde entra no TCC



```
          └──────┬──────┘
                 ▼
   RESÍDUOS / FEATURES TEMPORAIS
```

Essa etapa pode melhorar a interpretação de uma mudança de consumo. **Não** implica que todo resíduo elevado seja irregularidade: pode representar variável externa não observada, comportamento legítimo ou problema de qualidade.

8.3 Autocorrelação: correlação de uma variável consigo mesma defasada

A autocorrelação amostral no lag k pode ser estimada por

$$\boxed{\hat{\rho}(k) = \frac{\sum_{t=k+1}^{n}(x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^{n}(x_t - \bar{x})^2}}.$$

A forma acima é uma convenção usual de estimativa da ACF; existem estimadores alternativos com denominadores por lag. O resultado mede associação **linear** entre valores separados por k passos.

- $\rho(0) = 1$ por definição, salvo degenerescências.
- $\rho(1)$ alto e positivo: valores vizinhos tendem a se parecer.
- $\rho(k)$ negativo: valores separados por k passos tendem a se opor linearmente.
- Picos repetidos em $k = 96, 192, \ldots$ numa grade de 15 min podem apontar repetição diária.
- Um pico em $k = 672$ pode indicar repetição semanal.

Premissa escondida: interpretar a ACF como propriedade estável de um processo costuma pressupor uma forma de estacionariedade. Se a série cresce continuamente ao longo do tempo, vários lags podem parecer altamente correlacionados sem existir repetição operacional útil.

8.4 Exemplo manual de lag

Considere a série diária $x = [10, 14, 10, 14, 10, 14]$. Há alternância. Comparar valores separados por **um** dia pode revelar associação negativa; comparar separados por **dois** dias, positiva. Esse exemplo ilustra que "perder autocorrelação no lag 1" não significa automaticamente perder estrutura: o período característico pode ser maior que um passo.

Para consumo horário, escolha lags que representem fenômenos relevantes: passo seguinte, mesma hora do dia anterior, mesma hora da semana anterior. Nunca reporte `autocorr_lag7` sem dizer se é **sete dias** ou **sete intervalos**.

8.5 ACF versus correlação entre medidores

- **ACF da UC:** relaciona a série com seus próprios valores passados.
- **Correlação entre UCs:** relaciona duas séries distintas e exige alinhamento temporal.
- **Correlação cruzada com defasagem:** relaciona séries distintas permitindo atrasos.

Uma queda simultânea em várias UCs do mesmo transformador pode justificar investigação de contexto de rede; ela **não** prova automaticamente ocorrência sistêmica, pois falha de comunicação comum, calendário ou agregação podem criar padrões semelhantes.

8.6 Estacionariedade, em nível introdutório

Uma série é **fracamente estacionária** quando sua média e variância não dependem do instante e sua autocovariância depende apenas da defasagem, sob condições formais. Não precisa provar teoremas agora. A intuição basta:

- Série cuja média aumenta ano após ano: não estacionária na média.
- Série com padrão diário forte: há sazonalidade a tratar.
- Série de resíduos depois de retirar tendência/sazonalidade: **candidata** a uma representação mais estável, não garantia.

Uma série em mudança de regime pode deixar de ser estacionária mesmo após retirar ciclo diário. É justamente uma motivação para CPD na Semana 2.

8.7 Decomposição aditiva

Modelo descritivo clássico:

$$\boxed{y_t = T_t + S_t + R_t},$$

em que T_t é tendência/ciclo de longo prazo, S_t é componente sazonal, e R_t é o restante. Em palavras: **observado** = **patamar** + **rotina** + **sobra**.

8.7.1 Exemplo

Suponha que o consumo em determinado dia seja 25 kWh, a tendência estimada seja 20 kWh e o efeito sazonal de "dia de alto consumo" seja +3 kWh. O resíduo é

$$R_t = 25 - 20 - 3 = 2 \text{ kWh}.$$

O resíduo positivo significa que o observado superou o valor descrito por essas componentes em 2 kWh. Isso não identifica a causa. Dependendo do processo, 2 kWh podem ser irrelevantes ou importantes.

8.8 Decomposição multiplicativa

Quando a amplitude da sazonalidade cresce com o nível, considere uma representação como

$$\boxed{y_t = T_t \, S_t \, R_t}, \quad y_t > 0,$$

ou transformação logarítmica para converter produto em soma:

$$\log y_t = \log T_t + \log S_t + \log R_t.$$

Cuidado: log não é definido para zero ou valor negativo na forma real usual. Energia reversa, balanços assinados e observações nulas exigem tratamento específico; não aplique `log(x)` indiscriminadamente. Usar `log1p(x)` para valores não negativos é outra transformação, com significado diferente.

8.9 STL: sazonalidade e tendência por suavização local

STL significa *Seasonal and Trend decomposition using Loess*. É uma técnica que estima componentes suavizados e sazonais, incluindo variantes robustas a observações extremas. O principal pré-requisito é definir a **periodicidade em número de observações**.

Exemplos:

- Dados diários, sazonalidade semanal: `period=7`.
- Dados 15-min, sazonalidade diária: `period=96`.
- Dados 15-min, semanal: `period=672`.

Uma decomposição STL padrão com **apenas um período** não modela simultaneamente, por completo, duas sazonalidades distintas. Para diárias e semanais sobrepostas, considere depois métodos específicos para múltiplas sazonalidades, transformação por calendário ou modelagens com duas camadas. **Não** tome o output de `STL(period=96)` como remoção garantida de todas as estruturas semanais.

8.10 Como diagnosticar resíduos

Um resíduo útil para detecção deve ser avaliado por:

1. média próxima do patamar esperado;
2. ausência de padrão sazonal forte remanescente;
3. dispersão relativamente estável;
4. ausência de uma dependência óbvia que o próprio modelo deveria explicar;
5. integridade do sinal e representatividade da janela.

O objetivo não é forçar os resíduos a parecerem ruído branco a qualquer custo. Se uma mudança relevante produz resíduos persistentes, "limpá-los" agressivamente pode apagar a evidência operacional.

8.11 Força da tendência e sazonalidade

Hyndman apresenta medidas baseadas em variância dos resíduos da decomposição. Uma forma para tendência e sazonalidade, respectivamente, é:

$$\boxed{F_T = \max\left(0, 1 - \frac{\mathrm{Var}(R)}{\mathrm{Var}(T+R)}\right)},$$

$$\boxed{F_S = \max\left(0, 1 - \frac{\mathrm{Var}(R)}{\mathrm{Var}(S+R)}\right)}.$$

Intuição: se a variação residual é pequena em relação à variação que inclui a componente estruturada, a força dessa componente aumenta. Essas medidas costumam ficar em [0,1] sob a formulação usual e denominadores válidos. Se um denominador é zero ou a série é muito curta/inválida, a feature deve ser tratada como **indefinida** em vez de inventar valor.

Essas medidas são candidatas a features, mas só devem ser usadas depois de escolher corretamente o período, a janela e a política de missing.

8.12 Decomposição não é causalidade

A componente T_t é um objeto estatístico. Não é necessariamente "crescimento econômico", "fraude", "GD" ou "troca de medidor". Sazonalidade pode representar hábitos, calendário, clima e operação. Um resíduo elevado é desvio em relação à representação adotada, **não um diagnóstico físico**.

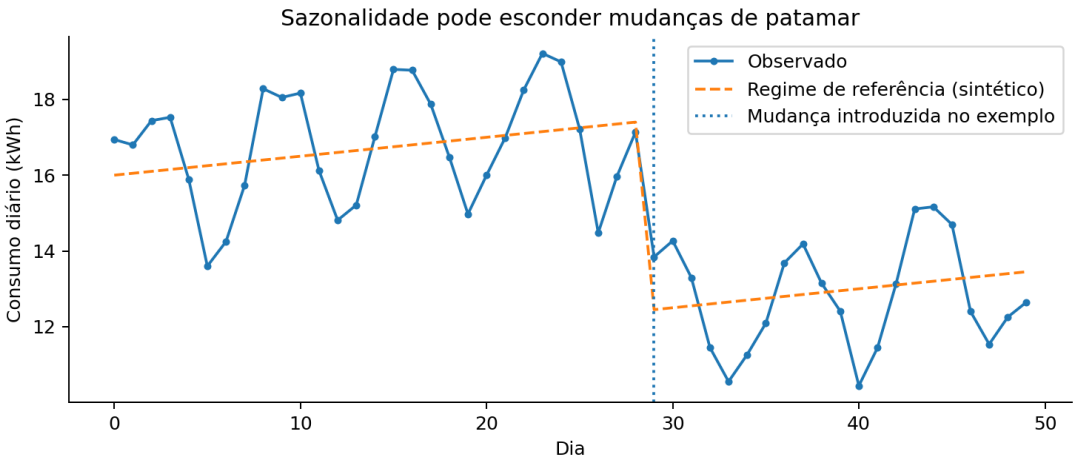


Figura 8.2: Mudança de patamar em série diária sintética

A figura mostra uma série onde introduzimos artificialmente uma redução de patamar. O ciclo semanal torna a quebra menos evidente numa inspeção pontual. Isso motiva duas etapas futuras: **comparação com o regime anterior** e **avaliação da persistência**, sem supor que toda mudança signifique fraude.

8.13 Laboratório: decomposição semanal em dados diários

```
import numpy as np
from statsmodels.tsa.seasonal import STL

rng = np.random.default_rng(42)
t = np.arange(56)
consumo_kwh = (
    20 + 0.03 * t
    + 3.0 * np.sin(2 * np.pi * t / 7)
    + rng.normal(0, 0.8, size=len(t))
)

# São 56 dias consecutivos completos, com sazonalidade semanal.
resultado = STL(consumo_kwh, period=7, robust=True).fit()
print("Tendência, primeiros dias:", resultado.trend[:5])
print("Sazonal, primeiros dias:", resultado.seasonal[:5])
print("Resíduo, primeiros dias:", resultado.resid[:5])

soma = resultado.trend + resultado.seasonal + resultado.resid
print("Erro da reconstrução:", np.max(np.abs(consumo_kwh - soma)))
```

Experimente acrescentar `consumo_kwh[35:] -= 6` antes da decomposição. Compare tendências e resíduos. Atenção: STL é método descritivo e, ao ajustar sobre **toda** a série, pode usar informações posteriores para estimar componentes anteriores. Para simular uma decisão online no dia 35, você não poderia ajustar a decomposição com os dias 36–55 e afirmar que aquela seria sua estimativa disponível no dia 35.

8.14 Exercícios do Dia 6

E6.1. Em dados a cada 15 minutos, qual lag representa o mesmo horário do dia anterior? E da semana anterior?

E6.2. Se $y = 31$, $T = 24$ e $S = 4$, qual é R na decomposição aditiva?

E6.3. Uma ACF alta no lag 1 prova que a série é estacionária? Justifique.

E6.4. Qual risco de usar `STL(period=7)` sobre uma série de 15 minutos, acreditando estar extraindo sazonalidade semanal?

E6.5. Um resíduo elevado pode significar fraude? Cite outras três possibilidades plausíveis.

E6.6. Por que uma decomposição retrospectiva ajustada na série inteira pode ser inválida como feature de uma previsão histórica no cutoff?

8.15 Checkpoint de domínio

- ☐ Explico a ACF e sua diferença de correlação entre UCs.
- ☐ Identifico lag diário/semanal na unidade temporal correta.
- ☐ Explico T, S e R e consigo reconstruir y.
- ☐ Sei escolher `period` conforme a cadência.
- ☐ Não transformo um resíduo elevado em diagnóstico causal.
- ☐ Reconheço que decomposição ajustada no futuro pode causar leakage.

Entregável: um gráfico de decomposição com descrição das três componentes e dois exemplos de interpretações indevidas que precisam ser evitadas.

9 Dia 7 — Engenharia de features temporais: converter uma trajetória em evidência

Leitura-base: síntese aplicada de Hyndman, 2ª ed., cap. 2, §3.3, cap. 6 e §6.7; Géron, cap. 2; Bruce, cap. 1. **Importante:** o capítulo chamado *Time Series Features* da **3ª edição** de Hyndman **não existe com essa numeração na sua 2ª edição**. As features abaixo são uma **proposta técnica adaptada ao TCC**, construída sobre aqueles fundamentos, não uma lista copiada dos autores. **Pré-requisito:** Dias 1–6.

9.1 Primeiro, em palavras simples

Um modelo tradicional de tabela espera **uma linha com números**. Já um medidor entrega **uma sequência enorme de medidas**. Engenharia de features temporais é a arte de transformar essa sequência em um resumo útil, preservando exatamente as propriedades que importam para a pergunta: nível típico de consumo, variação, horários de maior carga, repetição semanal e mudança ao longo da janela.

O perigo é resumir demais. Uma média de 30 dias não diz se houve uma queda no dia 20. Um máximo isolado não diz se o padrão persistiu. O objetivo não é criar centenas de colunas: é representar adequadamente a física e o tempo sem esconder transições.

9.2 Três decisões antes de calcular uma feature

1. **Qual a entidade?** UC, NIO físico, alimentador ou transformador?
2. **Qual o tempo?** Instante, dia, semana, janela retrospectiva de 7/30 dias?
3. **Qual o fenômeno?** Consumo, potência, tensão, comunicação, energia reversa, alarme?

Duas features com o mesmo nome e janelas distintas não são equivalentes. `fa_median_7d` e `fa_median_30d` captam horizontes diferentes. Uma feature elétrica com `coverage` misturado no mesmo vetor pode fazer o detector aprender **telemetria**, não comportamento elétrico; por isso nossa arquitetura separa os dois blocos.

9.3 Quadro geral de features

Família	Exemplos	Unidade	Pergunta respondida
Nível	mediana de FA diário	kWh/dia	Quanto a UC costuma consumir?
Dispersão	MAD, IQR, P95	kWh/dia	Qual a variação habitual?
Tendência	slope do total diário	kWh/dia por dia	Está aumentando ou diminuindo?
Forma diária	razão dia/noite, hora de pico	adimensional, hora	Quando consome?

Família	Exemplos	Unidade	Pergunta respondida
Regularidade	autocorrelação lag 7	adimensional	Repete o padrão semanal?
Intensidade relativa	fator de carga	adimensional	Quão contínua é a demanda?
Reversão	contagem de dias com RA > limiar válido	dias	Há exportação registrada?
Qualidade	cobertura e gaps	proporção, minutos	Temos dados suficientes?
Contexto	classe, fase, trafo, GD cadastrada	categoria	Com quem faz sentido comparar?

Separação de responsabilidades: a última família "Qualidade" é essencial ao pipeline, mas seu destino inicial é `S_comm` e metadados de confiabilidade, **não** o vetor físico X_{elec}.

9.4 Feature 1 — consumo diário típico

Defina a série diária E_d^{FA} como soma de incrementos válidos do dia d, **quando o dia atende às regras de cobertura**. Em uma janela W de dias válidos:

$$\boxed{x_{\text{fa_mediana}} = \text{mediana}_{d \in W}\, E_d^{FA}.}$$

A leitura é imediata: kWh de um dia típico naquela janela. A feature pode não ser adequada para agrupar residências e indústrias sem estratificar por classe ou escala; magnitude não é forma de consumo.

9.5 Feature 2 — instabilidade habitual (MAD)

$$\boxed{x_{\text{fa_mad}} = \text{mediana}_{d \in W} \left| E_d^{FA} - \text{mediana}_{j \in W}\, E_j^{FA} \right|.}$$

O MAD não detecta necessariamente uma ruptura estrutural. Ele responde quão dispersos são os dias em torno do consumo típico. Um degrau persistente no meio da janela pode elevar MAD temporariamente; quando o novo regime ocupa praticamente toda a janela, o MAD pode cair de novo. **Esse comportamento é um argumento para CPD**, que estudaremos depois.

9.6 Feature 3 — inclinação de tendência

Considere t_d como o número de dias decorridos desde o começo da janela, e E_d como energia diária. Uma inclinação linear por mínimos quadrados é

$$\boxed{\hat{\beta}_1 = \frac{\sum_d (t_d - \bar{t})(E_d - \bar{E})}{\sum_d (t_d - \bar{t})^2}.}$$

Se $\hat{\beta}_1 = -0{,}8$ em unidades de kWh/dia por dia, a reta ajustada indica decréscimo médio de cerca de 0,8 kWh no total diário a cada dia da janela. **Isso não equivale a um evento súbito**: uma queda abrupta e uma tendência gradual podem resultar em inclinações semelhantes.

Ajuste apenas se houver dias suficientes e variação temporal em t. OLS é sensível a outliers; uma alternativa robusta pode ser considerada depois. Reporte número de observações e qualidade da janela.

9.7 Feature 4 — fator de carga

O fator de carga, em uma definição operacional usual, relaciona potência média e pico na mesma janela:

$$\boxed{LF = \frac{\overline{P}_W}{P_{\max,W}}}, \qquad 0 \le LF \le 1$$

quando potências e janela são consistentes, $P_{\max,W} > 0$ e as potências são não negativas. **Exemplo:** consumo diário de 24 kWh implica potência média diária $24/24 = 1$ kW. Se o maior intervalo de demanda média equivalente foi 4 kW, então $LF = 1/4 = 0{,}25$.

Uma carga contínua tende a ter fator de carga alto; carga com picos curtos, menor. O pico definido por janelas de 15 min não é necessariamente igual ao pico instantâneo real. Portanto, inclua a cadência e a definição de P_{max} no metadata da feature.

9.8 Feature 5 — razão diurna/noturna

Defina intervalos de período diurno e noturno sem sobreposição, com fuso e regra de calendário explícitos:

$$\boxed{R_{D/N} = \frac{\sum_{t \in D} E_t^{FA}}{\sum_{t \in N} E_t^{FA}}}.$$

Essa razão é informativa para distinguir rotinas, mas o denominador pode ser zero. **Não** substitua cegamente por um número gigantesco somando ϵ sem documentar: isso muda a interpretação e pode gerar outliers artificiais. Prefira `null`/flag quando a razão for indefinida, ou use transformação definida explicitamente. O recorte 06–18h versus 18–06h é **uma hipótese de engenharia**, não uma regra universal.

9.8.1 Exemplo

Se energia diurna = 18 kWh e noturna = 6 kWh, razão 3. Se um comércio fecha à noite, um valor alto pode ser normal; numa residência, talvez a distribuição seja diferente. **Razões contextualizam**, não classificam causas.

9.9 Feature 6 — dias úteis versus finais de semana

$$\boxed{R_{U/F} = \frac{\text{média}(E_d : d \text{ útil})}{\text{média}(E_d : d \text{ fim de semana})}}.$$

Requer número mínimo de dias em cada grupo e calendário correto. Feriados e operação extraordinária podem tornar “dia útil” uma categoria insuficiente. Uma UC comercial em Curitiba e uma rural com trabalho de fim de semana podem ter comportamentos opostos.

9.10 Feature 7 — hora de pico em representação cíclica

Hora do dia não é uma reta: 23h e 0h são vizinhas no relógio. Codificar hora como 23 versus 0 cria grande distância artificial. Para $h \in [0, 24)$:

$$\boxed{x_{\text{peak_sin}} = \sin\left(2\pi\frac{h}{24}\right)}, \qquad \boxed{x_{\text{peak_cos}} = \cos\left(2\pi\frac{h}{24}\right)}.$$

Assim, 23h e 0h ficam próximos sobre o círculo. A hora de pico deve ser obtida de dados suficientemente completos; em dias sem medição da madrugada, a hora de pico "observada" pode ser uma ilusão.

9.11 Feature 8 — autocorrelação diária e semanal

Use a definição do Dia 6, mas nomeie a escala corretamente:

- `acorr_lag1_day` sobre **totais diários**: relação com dia anterior.
- `acorr_lag7_day` sobre **totais diários**: relação com mesma posição semanal.
- `acorr_lag96_15m` sobre série 15-min: relação com mesmo horário do dia anterior.

Se a janela tem 7 dias e queremos ACF no lag 7 da **série diária**, não há pares suficientes; a feature fica indefinida. Isso ilustra por que a janela de cálculo não pode ser escolhida só porque 7 dias é uma escala fácil de memorizar. Autocorrelação com lacunas também exige uma política de pares válidos, não zeros sintéticos.

9.12 Feature 9 — entropia de perfil, com definição explícita

A palavra "entropia" soa sofisticada, mas precisamos definir primeiro uma distribuição. Se $E_h \geq 0$ é a energia da hora h, e $E_{total} = \sum_h E_h > 0$, definimos frações

$$p_h = \frac{E_h}{E_{total}}, \quad \sum_{h=0}^{23} p_h = 1.$$

Então, a **entropia de Shannon das frações horárias** é

$$\boxed{H = -\sum_{h:p_h>0} p_h \log p_h}.$$

Entropia alta corresponde a energia distribuída de maneira relativamente uniforme entre horários; entropia baixa corresponde a concentração em poucos horários, **nessa definição específica**. Se os intervalos são de 15 min, podemos definir 96 categorias em vez de 24, com valores e máximos diferentes ($H_{max} = \log 96$ versus $\log 24$). Isso não é "entropia do sinal" em sentido único e pode variar muito conforme o particionamento. É uma candidata secundária, não um requisito obrigatório nesta semana.

9.13 Feature 10 — por que precisamos de qualidade separada

Cobertura por canal e janela:

$$\boxed{C_{c,W} = \frac{N_{\text{válido},c,W}}{N_{\text{esperado},c,W}}}.$$

A qualidade serve ao menos para duas coisas:

1. **Analisar comunicação**: um comportamento de gaps pode ser o próprio objeto de estudo.

2. **Avaliar confiabilidade elétrica**: se há poucas medidas, certas features elétricas não são confiáveis ou sequer definidas.

Na proposta anterior apareceu um gating do tipo $C_{30d} \geq 0{,}70$. **70% é uma escolha inicial de projeto**, não constante estatística universal nem limiar regulatório. É preciso validar sensibilidade, distinguir canais e examinar quais padrões de ausência tornam uma amostra inutilizável. Um dia com todas as madrugadas ausentes e outro com 30% de intervalos aleatoriamente ausentes podem ter a mesma cobertura e distorções elétricas muito diferentes.

9.14 Regimes: por que janelas fixas têm limite

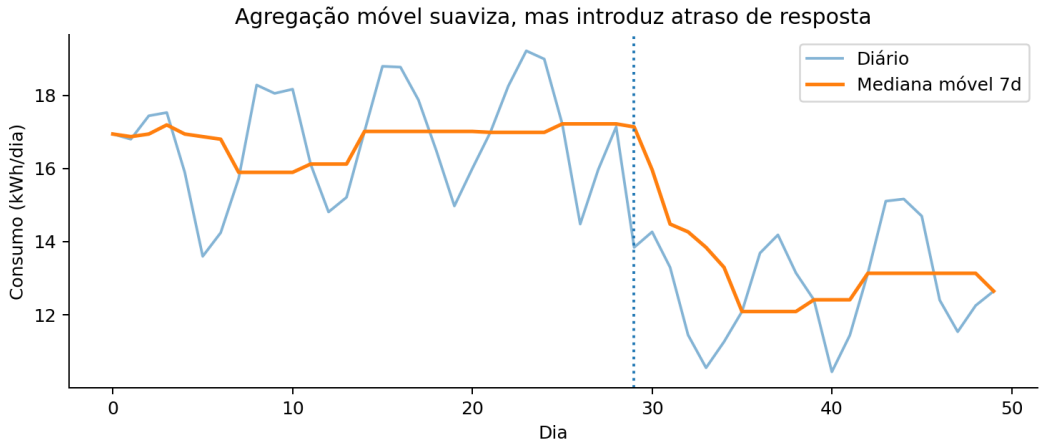
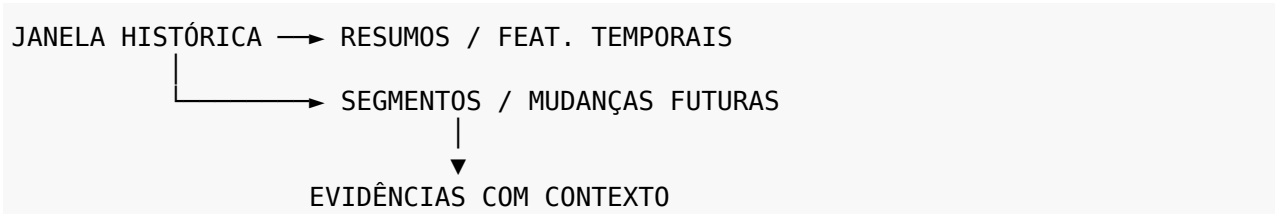


Figura 9.1: Mediana móvel atrasa a representação de uma mudança de regime

Uma mediana móvel de 7 dias suaviza picos, mas reage com atraso a uma mudança abrupta. Uma mediana de 30 dias pode misturar regime anterior e posterior. A Semana 1 termina sabendo **o que a janela resume** e **o que ela perde**. Na próxima etapa, Change Point Detection entra justamente para investigar transições estruturais, não para substituir a estatística descritiva.

9.14.1 Uma visão futura em duas etapas (sem implementar agora)



9.15 Dicionário de features: modelo mínimo

Nome	Granularidade	Janela	Unidade	Qualidade mínima	Observação
`x__hist_fa_sum_median_cutoff`	UC	30d	kWh/dia	dias válidos	mediana de totais diários
`x__hist_fa_sum_mad_cutoff`	UC	30d	kWh/dia	dias válidos	MAD bruto, não escalado

Nome	Granularidade	Janela	Unidade	Qualidade mínima	Observação
x__trend_fa_slope	UC × cutoff	30d	kWh/dia²	dias suficientes	reta de tendência
x__hist_load_factor_mean	UC × cutoff	30d	1	intervalos válidos	depende de pico definido
x__day_night_ratio	UC × cutoff	30d	1	cobertura D e N	indefinido se noite=0
x__acorr_lag7_day	UC × cutoff	30d	1	pares válidos	ACF semanal sobre dados diários
meta__data_quality	UC × cutoff	30d	1	canal conhecido	só gating, fora de X_elec
id__uc_id	UC × cutoff	—	—	ID consistente	não enviar ao estimador

Pontos para revisão futura: nomes, janelas e thresholds devem corresponder ao repositório real. Esta tabela é um **contrato de referência didática**, não evidência de que cada feature já esteja implementada com essa exata semântica.

9.16 Laboratório: montar features por cutoff

```
from datetime import date, timedelta
import numpy as np
import polars as pl

cutoff = date(2026, 10, 1)
inicio = cutoff - timedelta(days=30)

dias = [inicio + timedelta(days=i) for i in range(30)]
energia = [11.0 + 0.15 * i + 2 * (i % 7 == 0) for i in range(30)]

diario = pl.DataFrame({
    "uc_id": ["UC01"] * 30,
    "dia": dias,
    "fa_kwh_dia": energia,
    "cobertura": [1.0] * 30,  # dados sintéticos completos
})

janela = diario.filter(
    (pl.col("dia") >= inicio)
    & (pl.col("dia") < cutoff)
    & (pl.col("cobertura") >= 0.80)  # política ilustrativa
).sort("dia")

mediana = janela.select(pl.col("fa_kwh_dia").median()).item()
mad = janela.select(
    (pl.col("fa_kwh_dia") - mediana).abs().median()
).item()

v = janela["fa_kwh_dia"].to_numpy()
t = np.array([(d - inicio).days for d in janela["dia"].to_list()], dtype=float)
slope = float(np.polyfit(t, v, deg=1)[0]) if len(v) >= 3 else None
```

```
print({
    "id__uc_id": "UC01",
    "meta__cutoff_date": cutoff.isoformat(),
    "x__hist_fa_sum_median": mediana,
    "x__hist_fa_sum_mad": mad,
    "x__trend_fa_slope": slope,
})
```

O filtro `cobertura>=0.80` é **apenas pedagógico**; 80% não foi validado como requisito da concessionária. Uma solução real precisa verificar quais horários faltaram e se a energia diária é comparável. Não atribua automaticamente a uma UC dados de NIOs sem validar a vigência histórica.

9.17 Exercícios do Dia 7

E7.1. Uma UC consome 30 kWh no dia. A maior potência média de intervalo de 15 min foi 5 kW. Calcule o fator de carga diário conforme a definição apresentada.

E7.2. Consumo diurno = 16 kWh e noturno = 8 kWh. Qual a razão? E se noturno = 0?

E7.3. Em uma série diária com 30 pontos, o que significa lag 7? O que significaria lag 7 numa série de 15 minutos?

E7.4. Uma reta ajustada sobre 20 dias tem slope $-0{,}5$ kWh/dia². A queda foi certamente abrupta?

E7.5. Por que uma UC com 70% de cobertura, concentrada em perda noturna, pode ter razão dia/noite enviesada mesmo atendendo a um gating de 70%?

E7.6. Liste cinco informações que precisam acompanhar `x__hist_fa_sum_median` para torná-la reproduzível.

9.18 Checkpoint de domínio

- ☐ Consigo explicar cada feature com uma frase física e uma fórmula.
- ☐ Sei a diferença entre magnitude, forma, estabilidade e tendência.
- ☐ Não confundo lag em intervalos com lag em dias.
- ☐ Sei por que razões com denominador zero exigem tratamento explícito.
- ☐ Mantenho dados faltantes separados de comportamento elétrico.
- ☐ Consigo apontar por que uma janela de 30 dias pode misturar regimes.

Entregável: dicionário de features com origem, grão, janela, unidade, política de missing, periodicidade, fórmula, uso no modelo e risco de leakage.

10 Estudo de caso integrado — do dado bruto a uma hipótese de investigação

Este caso foi construído **somente para ensino**. Não representa diagnóstico de UC real, validação de algoritmo ou evidência de fraude.

10.1 O cenário

Uma UC apresenta consumo diário habitual ao redor de 10–11 kWh/dia. Em seguida, passa a registrar cerca de 4 kWh/dia. A comunicação parece suficientemente estável no exemplo e a tensão não apresenta alteração relevante no resumo agregado disponível. Nosso objetivo não é dizer **por que** isso aconteceu; é descrever a mudança de forma tecnicamente honesta.

Dia	Energia ativa (kWh/dia)	Fase no exemplo
1	10	Antes
2	11	Antes
3	9	Antes
4	10	Antes
5	12	Antes
6	10	Antes
7	11	Antes
8	4	Depois
9	5	Depois
10	4	Depois
11	4	Depois
12	5	Depois
13	3	Depois
14	4	Depois

10.2 Passo 1 — identificar unidades e observabilidade

Os valores são totais diários de energia direta em **kWh/dia**, calculados a partir de intervalos completos e validados. No mundo real, precisaríamos confirmar:

1. cobertura por canal, sem inferir que null = zero;
2. mesmo vínculo UC–NIO ou transição corretamente documentada;
3. consistência da cadência no período;
4. nenhuma duplicata/reprocessamento indevido;
5. dados disponíveis no instante de corte, se a análise for operacional;
6. se os valores são importação direta e não saldo líquido de importação menos exportação.

Sem essas verificações, a queda pode ser produzida pela própria engenharia de dados.

10.3 Passo 2 — descrever antes e depois

A mediana dos dias 1–7 é **10 kWh/dia**. A mediana dos dias 8–14 é **4 kWh/dia**. Logo,

$$\Delta \tilde{E} = 4 - 10 = -6 \text{ kWh/dia},$$

$$\boxed{\Delta \tilde{E}_{\%} = \frac{4-10}{10} \times 100 = -60\%.}$$

É legítimo dizer que **a mediana de consumo diário caiu 60% entre os dois segmentos escolhidos**. Não é legítimo dizer que "há 60% de probabilidade de fraude". Os segmentos foram **escolhidos conhecendo a transição**; isso é uma análise retrospectiva, não uma avaliação de desempenho de CPD.

10.4 Passo 3 — enxergar o problema da janela cega

Juntando os 14 dias, a mediana global é **7 kWh/dia**. Esse número não representa bem o regime antigo nem o novo. A média global é aproximadamente 7,29 kWh/dia. São resumos corretos da janela inteira, mas insuficientes para explicar a dinâmica.

Lição do Dia 1: uma estatística global pode esconder a heterogeneidade temporal. **Lição do Dia 5:** a ordem revela quando ocorreu a transição. **Lição do Dia 6:** em dados reais, devemos comparar a mudança com ciclo semanal, sazonalidade e possíveis mudanças externas.

10.5 Passo 4 — identificar o que ainda falta

Mesmo com queda sustentada, causas compatíveis incluem:

- menor ocupação ou fechamento temporário;
- mudança de horários de operação;
- nova fonte de geração local;
- problemas de medição;
- falhas de telecom ou agregação não identificadas;
- intervenção deliberada no sistema elétrico;
- mudança cadastral ou de ligação.

Se houver exportação de energia reversa, isso aumenta a relevância de investigar GD; não prova irregularidade cadastral. Se houver alarme de violação e mudança simultânea de consumo, a evidência conjunta pode justificar prioridade de investigação; ainda não equivale a confirmação de campo. Se outros medidores vizinhos apresentam mudança na mesma data, há hipótese de evento comum que precisa ser explorada.

10.6 Passo 5 — converter o caso em trabalho de pesquisa

Escreva uma ficha reproduzível:

```
Entidade: UC-EXEMPLO
Janela anterior: dias 1–7 (7 dias válidos)
Janela posterior: dias 8–14 (7 dias válidos)
Energia: FA direto, kWh/dia
Mediana pré: 10
Mediana pós: 4
Variação da mediana: -6 kWh/dia (-60%)
Relação com sazonalidade: não avaliada adequadamente
Cobertura: pressuposta completa na simulação
Troca de medidor: desconhecida na situação real
Alarmes/RA/GD: não fornecidos
Classificação causal: NÃO DETERMINADA
Próximas verificações: cadência, vínculo NIO, GD, alarmes, pares de rede
```

Este é o comportamento que queremos desenvolver: **quantificar o que vimos, reconhecer o que não sabemos e propor qual dado adicional pode decidir entre explicações**.

10.7 Perguntas para defesa oral

- Por que não basta comparar duas médias de 30 dias?
- Por que uma redução de 60% não é uma probabilidade de fraude?
- Qual a diferença entre uma análise retrospectiva que usa dias posteriores e uma decisão online no instante da mudança?
- Quais falhas de coleta poderiam fabricar a mesma curva?
- Por que comparar com classe e sazonalidade pode ser indispensável?

11 Folha de fórmulas — versão de consulta rápida

11.1 Estatística descritiva

Conceito	Fórmula	Unidade e uso
Média	$\bar{x} = \frac{1}{n}\sum_i x_i$	igual a x; resumo de soma/n
Mediana	$\tilde{x} = Q_{0.5}(x)$	igual a x; valor central
Variância populacional	$\sigma^2 = \frac{1}{N}\sum_i (x_i - \mu)^2$	unidade ao quadrado
Variância amostral	$s^2 = \frac{1}{n-1}\sum_i (x_i - \bar{x})^2$	unidade ao quadrado
Desvio padrão	$s = \sqrt{s^2}$	igual a x
IQR	$Q_{0.75} - Q_{0.25}$	igual a x
MAD bruto	$\text{med}\,\lvert x_i - \tilde{x}\rvert$	igual a x
MAD normal-equivalente	$1{,}4826 \times MAD$ (aprox.)	aproxima escala normal sob hipóteses
Percentil	$Q_p(x)$	mesmo tipo de grandeza

11.2 Relações entre variáveis

Conceito	Fórmula	Observação
Covariância	$\frac{1}{n-1}\sum_i (x_i - \bar{x})(y_i - \bar{y})$	unidade $x \times y$
Pearson	$r = \frac{\text{cov}(X,Y)}{s_X s_Y}$	linear, adimensional
Spearman	$\rho_S = \text{corr}(\text{rank}\,X, \text{rank}\,Y)$	associação monotônica
Z-score	$z = (x - \mu_{train})/\sigma_{train}$	treinar scaler só no treino
Robust scale	$(x - \tilde{x}_{train})/IQR_{train}$	tratar $IQR = 0$
Distribuição empírica	$\hat{F}_n(x) = \frac{1}{n}\sum_i \mathbf{1}(x_i \le x)$	percentil não é probabilidade de fraude

11.3 Tempo e energia

Conceito	Fórmula	Observação
Potência média de intervalo	$\bar{P} = E/\Delta t$	kWh/h = kW
Energia diária (incremental)	$E_d = \sum_{i \in d} E_i$	só intervalos válidos/disjuntos
Lag k	x_{t-k}	passos ≠ dias automaticamente
ACF no lag k	$\hat{\rho}(k) = \frac{\sum_{t>k}(x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_t (x_t - \bar{x})^2}$	estimador convencional
Decomposição aditiva	$y_t = T_t + S_t + R_t$	tendência + sazonal + resíduo

Conceito	Fórmula	Observação
Força de tendência	$F_T = \max(0, 1 - \mathrm{Var}(R)/\mathrm{Var}(T+R))$	indefinida se denominador=0
Força sazonal	$F_S = \max(0, 1 - \mathrm{Var}(R)/\mathrm{Var}(S+R))$	depende de período escolhido

11.4 Features AMI

Conceito	Fórmula	Condição
Mediana FA diária	$\mathrm{med}_{d \in W}\, E_d^{FA}$	dias elegíveis
Slope linear	$\hat{\beta}_1 = \frac{\sum (t-\bar{t})(E-\bar{E})}{\sum (t-\bar{t})^2}$	sem degenerescência
Fator de carga	$LF = P_{avg}/P_{max}$	janelas e potências comparáveis
Razão dia/noite	$\sum E_D / \sum E_N$	noturno não zero
Razão útil/fim de semana	$\bar{E}_{util}/\bar{E}_{fds}$	grupos válidos
Pico cíclico	$\sin(2\pi h/24)$ e $\cos(2\pi h/24)$	h na mesma convenção
Cobertura de canal	$C = N_{valido}/N_{esperado}$	configuração de cadência conhecida
Entropia horária	$H = -\sum_{h:p_h>0} p_h \log p_h$	$p_h = E_h / \sum E_h$; perfil válido

11.5 Dicionário de símbolos

Símbolo	Interpretação
x_i	i-ésima observação
n / N	tamanho amostral / tamanho de população definido
$\bar{x}$, μ	média de amostra / média populacional
s, σ	desvio-padrão amostral / populacional
Q_p	quantil de ordem p
t, t_c	índice/instante temporal; cutoff
k	defasagem expressa em passos da série
W	janela temporal especificada
E, P	energia, potência
FA, RA	energia ativa direta / energia ativa reversa conforme semântica validada
T_t, S_t, R_t	componentes de tendência, sazonalidade e resíduo
θ, λ	parâmetros aprendidos e hiperparâmetros
X, y	matriz de features; target quando disponível
C	cobertura/completude (definição por canal e janela)

12 Gabarito comentado dos exercícios

Consulte o gabarito **depois** de tentar resolver. O objetivo não é reproduzir frases; é comparar o raciocínio e corrigir as hipóteses inadequadas.

12.1 Dia 1 — estatística descritiva

E1.1. Média $= (4+4+5+6+6)/5 = 5$ kWh/dia; mediana $= 5$ kWh/dia. Coincidem numericamente nessa amostra, mas não possuem a mesma definição: uma é soma dividida por contagem; outra é a posição central.

E1.2. Média $= (1{+}2{+}3{+}14)/4 = 5$ kWh/dia. A mediana é $(2{+}3)/2 = 2{,}5$ kWh/dia. Se buscamos o comportamento típico, a mediana representa melhor os três primeiros valores; se buscamos total consumido, a soma e a média podem ser apropriadas.

E1.3. Com 72 de 96 leituras, cobertura $= 75\%$. A soma representa energia **registrada nos intervalos observados**, não necessariamente a energia de 24 horas. Poderia ser aceita como quantidade parcial ou eventualmente estimativa sob modelo explícito; deve ser rejeitada como total diário observado integral sem justificativa para os 24 intervalos ausentes.

E1.4. Não. $4 \times 1{,}4826 \approx 5{,}9304$. As duas features podem ser, respectivamente, MAD bruto e MAD escalado. Primeiro conferir fórmulas, versões e unidades.

E1.5. Para dimensionamento de risco associado a picos, P95 e máximos definidos em janelas adequadas são mais informativos que a mediana. P95 pode ignorar raríssimos picos, e máximo pode ser muito sensível a valores incorretos. O critério físico/operacional deve determinar a escolha.

12.2 Dia 2 — relações estatísticas

E2.1. Se $Y = 3X + 7$, Pearson $r = 1$ (X não constante). Se $Y = -3X + 7$, $r = -1$. Transformações lineares perfeitas com coeficiente angular positivo/negativo determinam o sinal da correlação; adição de constante não a altera.

E2.2. A mesma estação pode aumentar temperatura e ocupação, e a temperatura pode influenciar climatização. Correlação observacional não separa essas causas sem estratégia de análise/experimento e controle de variáveis relevantes.

E2.3. Treino $[10, 20, 30]$: média $= 20$; desvio-padrão populacional sobre os três valores $= \sqrt{[(10-20)^2 + 0 + (30-20)^2]/3} = \sqrt{200/3} \approx 8{,}165$. Valor de teste 40 tem $z = (40-20)/8{,}165 \approx 2{,}449$. Se usar desvio amostral $s = 10$, o resultado seria 2. Registre convenção; `StandardScaler` usa variância populacional com `ddof=0`.

E2.4. Percentil descreve posição relativa do score numa distribuição de referência. Para probabilidade posterior de fraude, precisaríamos de evidência/labels representativos, prevalência, avaliação de calibração e definição clara de evento e população. Mesmo assim, essa probabilidade teria incerteza e dependeria de validade externa.

E2.5. Não necessariamente. O cadastro estimado pode ser mais estável e independente, oferecendo referência para discrepância; também pode refletir uma cópia antiga de consumo observado, gerando redundância e possível leakage. Verificar proveniência, vigência e uso do atributo antes de removê-lo.

12.3 Dia 3 — fundamentos de ML

E3.1. Máximo teórico $2.000.000 \times 12 = 24.000.000$ linhas UC-mês, se toda UC tiver exatamente 12 cutoffs e não houver exclusões. Isso não é número de leituras AMI nem garantia de 24 milhões de exemplos elegíveis.

E3.2. Leakage direto de target. O estimador aprende a resposta fornecida como entrada; desempenho de teste pode ficar artificialmente excelente se a coluna também contaminar validação.

E3.3. (1) score atípico não tem interpretação causal; (2) taxa de flags pode refletir threshold/`contamination`; (3) referência de treino pode misturar classes e fenômenos; (4) qualidade/missingness pode dominar; (5) fraudes podem existir sem atipicidade estatística.

E3.4. Não. O primeiro mede transferência geográfica/de domínio; o segundo mede capacidade temporal sobre UCs conhecidas. Exigem divisões e interpretações diferentes.

E3.5. (a) regra determinística; (b) não supervisionado; (c) supervisionado, **se o label for confiável**; (d) não supervisionado/novelty detection, dependendo do treinamento.

12.4 Dia 4 — pipeline e leakage

E4.1. Janela $\big[$14/10/2026 00:00, 21/10/2026 00:00$\big)$ no fuso definido. Inclui 14/10 às 00h; exclui exatamente 21/10 às 00h e tudo posterior. É preciso verificar se timestamp do canal representa início ou fim do intervalo.

E4.2. Mesmo sem y, a distribuição de teste altera média/desvio que deveriam ser aprendidos só no treino. Isso informa o pipeline sobre os dados futuros e torna avaliação menos fiel ao cenário operacional.

E4.3. Energia: $24 \times 60/5 = 288$ observações; tensão: $24 \times 60/15 = 96$ observações. Pressupõe ambos os canais configurados, dia de 24 horas e disponibilidade esperada em todos os intervalos.

E4.4. Para simular decisão em 21/10: não, se só ficou disponível em 23/10. Para retrospectiva feita em novembro: sim, **se explicitamente descrita como análise consolidada**, evitando afirmar que o dado estava disponível em 21/10.

E4.5. Verificar histórico UC–NIO com vigências não sobrepostas e sem lacunas ou duplicatas indevidas; o mesmo NIO não deve ser vinculado automaticamente à UC atual em períodos antigos.

E4.6. O split por UC reduz vazamento entre entidades, mas não impede que janelas, transformações, alvos ou informações cadastrais de treino/teste incorporem tempos posteriores ao cutoff simulado. Dependendo da meta, avaliação temporal e por entidade devem ser tratadas em conjunto.

12.5 Dia 5 — séries temporais

E5.1. $\Delta t = 10/60 = 1/6$ h. $\bar{P} = 0{,}4/(1/6) = 2{,}4$ kW.

E5.2. 30 dias $= 30 \times 96 = 2.880$ observações; 7 dias $= 7 \times 96 = 672$. São contagens esperadas para cadência invariável, dias completos e canal configurado.

E5.3. Que 96 linhas atrás significa 24 horas atrás. A falta de linhas pode fazer essa distância corresponder a mais de 24h. Indexar por timestamps e grade esperada evita a confusão.

E5.4. Tensão em volts é uma grandeza medida de estado/intervalo. A soma dos 96 valores teria unidade V·contagem e não seria um indicador físico usual de tensão diária. Dependendo do objetivo, usar média, quantis ou critérios regulatórios próprios.

E5.5. Defasagem/erro de relógio do medidor, processamento intermediário, filas, timezones e campos sem semântica temporal padronizada, além do atraso de comunicação.

E5.6. Forma de onda ou medição compatível com resolução do evento. Uma média de 15 min pode perder quase toda a estrutura temporal de um afundamento de poucos ciclos.

12.6 Dia 6 — ACF e decomposição

E6.1. Lag diário = 96 amostras. Lag semanal = 672 amostras para série **regular de 15 min**.

E6.2. $R = y - T - S = 31 - 24 - 4 = 3$ unidades da série.

E6.3. Não. Tendência forte pode produzir autocorrelação alta; estacionariedade exige propriedades de média, variância e covariância mais específicas.

E6.4. `period=7` sobre 15 min representa um ciclo de 7 observações, isto é, 105 min, não 7 dias. Para semanal seriam 672 intervalos sob a cadência idealizada.

E6.5. Pode, mas não identifica causa. Também pode decorrer de mudança de ocupação, temperatura, atividade industrial, erro de sensor, falta de observação, troca de medidor ou evento de rede.

E6.6. Porque o método de decomposição usa observações posteriores à data de decisão para estimar tendência/seasonalidade/resíduos do passado. Seria análise retrospectiva, não feature histórica disponível naquele instante.

12.7 Dia 7 — features temporais

E7.1. Potência média $= 30/24 = 1{,}25$ kW; fator de carga $= 1{,}25/5 = 0{,}25$.

E7.2. Razão $= 16/8 = 2$. Com consumo noturno zero, o quociente é indefinido; guardar `null`, flag e regra para casos de zero, em vez de fabricar um valor extremo sem descrição.

E7.3. Em dados diários, lag 7 é uma semana de diferença. Na série de 15 minutos, lag 7 representa 105 minutos. Não são a mesma feature.

E7.4. Não. Slope linear resume tendência média e pode ser induzido por degradação progressiva, mudança abrupta, sazonalidade não removida ou extremos.

E7.5. A perda noturna remove precisamente grande parte do denominador, enviesando a razão dia/noite para cima, apesar de a cobertura global poder ultrapassar um limiar numérico de aceitação.

E7.6. Exemplos: origem/canal FA, semântica do intervalo, UC e vínculo NIO, cutoff e timezone, janela histórica, cobertura/dias válidos, regra de agregação diária, tratamento de duplicatas, unidade, versão do cálculo e disponibilidade temporal.

13 Perguntas rápidas para fixação — 35 cartões

Avalie cada conceito de **0 a 5 estrelas**, como no tracker: 0=não estudado; 1=já vi; 2=reconheço; 3=explico; 4=aplico sozinho; 5=consigo ensinar, implementar e defender. Não atribua cinco estrelas apenas porque a fórmula parece familiar.

ID	Pergunta de recuperação ativa	Conceito
S01	Média e mediana podem ser iguais por motivos diferentes?	Centro
S02	O que muda ao usar n versus $n-1$ na variância?	Variância
S03	Por que MAD pode ser útil para série com picos legítimos?	Robustez
S04	O que é percentil 95, em português comum?	Quantis
S05	Por que variância tem unidade ao quadrado?	Unidades
S06	O que diz Pearson próximo de zero?	Correlação linear
S07	O que a correlação não diz?	Causalidade
S08	Qual a diferença principal entre Pearson e Spearman?	Associação
S09	O que é uma distribuição multimodal?	Distribuição
S10	Por que `StandardScaler.fit` deve ocorrer só no treino?	Leakage
M01	O que é uma amostra de ML neste TCC?	Grão da amostra
M02	Por que UC e NIO não são intercambiáveis?	Identidade
M03	O que diferencia supervised de unsupervised?	Paradigma
M04	O que é y e quando ele existe?	Target
M05	Um score de anomalia é probabilidade de fraude?	Score
M06	Por que as features precisam de cutoff?	Tempo
M07	Como um split por UC e um split temporal diferem?	Validação
M08	Quando uma regra física é preferível a ML?	Método
M09	O que é overfitting?	Generalização
M10	Por que dados de qualidade ruim podem confundir detector?	Ruído

ID	Pergunta de recuperação ativa	Conceito
T01	Que diferença existe entre energia intervalar e potência média?	Energia/potência
T02	Quantos intervalos de 15 min existem em 24h?	Cadência
T03	O que ocorre se deslocar 96 linhas quando faltam pacotes?	Lag
T04	O que é sazonalidade?	Série temporal
T05	O que difere tendência de sazonalidade?	Decomposição
T06	O que é autocorrelação?	ACF
T07	Lag 7 é sempre sete dias?	Escala temporal
T08	O que são T_t, S_t e R_t?	Decomposição
T09	Por que `STL(period=7)` não é semanal em 15-min?	STL
T10	Por que um resíduo alto não identifica a causa?	Limitação causal
F01	O que é MAD da energia diária?	Feature
F02	Qual unidade de slope sobre consumo em kWh/dia?	Tendência
F03	Como fator de carga difere de consumo total?	Perfil
F04	Por que o denominador da razão dia/noite importa?	Razões
F05	Que informação uma mediana de 30 dias esconde?	Janela

13.1 Teste de proficiência da Semana 1

Faça **sem consulta** em até 45 minutos:

1. Defina um dataset `UC × cutoff` com duas features físicas e um metadata de qualidade. Desenhe suas dimensões.
2. Calcule mediana e MAD para $[12, 12, 13, 12, 60]$.
3. Explique em um parágrafo a diferença entre percentil de anomalia e probabilidade de fraude.
4. Uma série intervalar de 10 min contém 144 intervalos/dia. Qual é o lag semanal em passos? O que acontece se houver buracos no registro?
5. Defina autocorrelação e diga por que tendência interfere na interpretação.
6. Descreva três caminhos de data leakage em uma validação de modelo de medidor.
7. Diferencie tensão instantânea de energia incremental e indique um operador de agregação plausível para cada.
8. Explique por que é impossível concluir “by-pass” apenas a partir de queda de FA.
9. Justifique por que separaremos `S_comm` e `S_elec`.
10. Apresente o exemplo de uma janela de 30 dias que contém dois regimes e diga por que sua mediana pode ser insuficiente.

Rubrica: domínio excelente significa acertar o cálculo **e** apontar as premissas e limitações. Um erro físico de unidade ou um vazamento temporal não é compensado por fórmulas sofisticadas.

14 Plano de uso e registro de progresso

14.1 Checklist de fim de semana

Dia	Tópico	Produto concreto	Autoavaliação (0–5)
1	Estatística descritiva	tabela média, mediana, std, IQR, MAD	____
2	Relações estatísticas	matriz de correlação e escalonamento	____
3	Conceitos de ML	ficha de modelo, X/y/metadata	____
4	Pipeline e leakage	diagrama de ingestão -> treino -> score	____
5	Série temporal	quatro gráficos e tabela de cadências	____
6	ACF e decomposição	decomposição de série sintética	____
7	Features temporais	dicionário de features, unidades e cutoffs	____

Meta de compreensão: 3 estrelas = conseguir explicar, 4 = conseguir aplicar, 5 = conseguir defender limites. Prefira concluir a semana com 4 estrelas honestas em média a registrar 5 por familiaridade superficial.

14.2 Formato de ficha para anotações por conceito

```
Conceito / sinônimos:
Livro, capítulo e página:
Explicação para leigo (máx. 3 linhas):
Fórmula:
Símbolos e unidades:
Exemplo numérico:
Aplicação no pipeline AMI:
Premissas:
Quando NÃO usar / quando engana:
O que ainda não sei:
Domínio (0–5):
```

14.3 Leituras e limites das fontes

Bruce et al. (2020): fornece estatística exploratória e ferramentas para visualizar distribuições. Não define a taxonomia de alarmes do projeto nem regras de fraude.

Géron (2025): fornece a lógica de ML ponta a ponta, pipelines e validação. O exemplo prático principal do livro não é sobre medidores brasileiros; nossa convenção `id__/meta__/x__/y__` é uma adaptação de engenharia.

Hyndman & Athanasopoulos (2018): fornece temporalidade, autocorrelação, decomposição e avaliação de previsão. A aplicação a séries AMI específicas e aos canais de cada fornecedor é uma adaptação do projeto, que exige validação dos timestamps e da cadência.

Notebooks da UFPR (2026): servem como exercícios complementares de estatística descritiva e EDA. Os resultados de suas simulações não devem ser apresentados como validação de medidores reais.

O que esta apostila não afirma: que determinado limiar detecta fraudes, que existam rótulos confiáveis suficientes, que a arquitetura nova já esteja operacional, que dados de 15 min capturam eventos subcíclicos ou que os exemplos numéricos sintéticos sejam resultados experimentais do TCC.

Fim da Semana 1 — Base. O objetivo concluído é saber pensar com dados, reconhecer seus limites e escrever features reproduzíveis antes de escolher o próximo detector.