Da série temporal aos modelos: qualidade, mudança de regime e agrupamento

Apostila aplicada ao TCC de Engenharia Elétrica · Semana 2 — Núcleo (dias 8–14)

Material de estudo técnico · UFPR

Novembro de 2026

Sumário

Guia de entrada **3**
- Primeiro, em palavras comuns . . . 3
- Objetivos da semana . . . 3
- Dependências diretas da Semana 1 . . . 4

Mapa da semana — tópico, equação e função no pipeline **4**
- Macroarquitetura: colocar cada ferramenta no lugar . . . 5
- Como estudar um capítulo . . . 5
- Fontes, edições e escopo . . . 5
- Checklist de saída — versão curta . . . 6

Dia 8 — Dados ausentes, gaps e confiabilidade da medição **7**
- 1. Primeiro, em palavras leigas . . . 7
- 2. Como a ideia entra no TCC . . . 7
- 3. O primeiro erro: assumir uma cadência universal . . . 7
- 4. Fórmulas fundamentais . . . 8
- 5. Exemplo totalmente resolvido . . . 9
- 6. Três mecanismos de ausência: MCAR, MAR, MNAR . . . 9
- 7. O que observar antes de imputar . . . 9
- 8. UC–NIO, relógio e chegada atrasada . . . 10
- 9. Laboratório mínimo reproduzível . . . 10
- 10. Erros que anulariam a análise . . . 10
- 11. Exercícios de domínio . . . 10

Dia 9 — Engenharia de features: representar o fenômeno, não a planilha **12**
- 1. Em linguagem simples . . . 12
- 2. A pergunta que toda feature deve responder . . . 12
- 3. Quatro famílias separadas . . . 12
- 4. Transformações numéricas sem perder o sentido físico . . . 12
- 5. Features da AMI: não misture forma e magnitude . . . 13
- 6. Exemplo numérico — mesma forma, magnitudes distintas . . . 14
- 7. Categóricas, classes e risco de atribuir ordem . . . 14
- 8. Seleção e redundância . . . 15
- 9. Pipeline seguro no scikit-learn . . . 15
- 10. Exemplo de ficha de feature que serve ao TCC . . . 15
- 11. Exercícios de domínio . . . 16

Dia 10 — Change Point Detection I: reconhecer uma mudança de regime com CUSUM **17**
- 1. Em palavras leigas . . . 17
- 2. O que é uma mudança de regime? . . . 17
- 3. Primeiro remova o comportamento previsível . . . 17
- 4. CUSUM bicaudal: duas perguntas separadas . . . 18
- 5. Conta resolvida, passo a passo . . . 19

6. Como determinar a data estimada da mudança? . . . 19
7. CUSUM versus desvio-padrão de janela . . . 20
8. O que precisa acontecer antes do CUSUM em AMI . . . 20
9. Laboratório reproduzível . . . 20
10. Não confunda score, hipótese e causa . . . 20
11. Exercícios . . . 20

Dia 11 — Change Point Detection II: comparar janelas e segmentar regimes 22
1. Intuição simples . . . 22
2. Modelo de segmentos (offline) . . . 22
3. Custo de mudança de média . . . 22
4. Algoritmos de busca: o que são, sem decorar implementações . . . 23
5. Comparar distribuições de duas janelas . . . 23
6. O maior risco metodológico: janelas antes/depois em uma previsão online . . . 24
7. Múltiplos testes: por que um p-valor pequeno pode enganar . . . 25
8. Como caracterizar uma ruptura candidata . . . 25
9. `ruptures`: aplicação ilustrativa . . . 25
10. Validação de CPD sem circularidade . . . 25
11. Exercícios . . . 26

Dia 12 — PCA e SVD: comprimir informação sem inventar significado físico 27
1. Em palavras leigas . . . 27
2. O que realmente entra no PCA . . . 27
3. Centralização e covariância . . . 27
4. Exemplo manual de apenas duas features . . . 28
5. Ligação com SVD . . . 28
6. Variância explicada: como escolher k . . . 29
7. O dilema de escala . . . 29
8. PCA para explicar versus PCA para detectar . . . 30
9. Caso realista: 24 horas de consumo . . . 30
10. Código Python . . . 30
11. Exercícios . . . 30

Dia 13 — K-Means: descobrir arquétipos de consumo 32
1. Em palavras leigas . . . 32
2. Três palavras fundamentais . . . 32
3. Função objetivo . . . 32
4. Passos de Lloyd, sem mistério . . . 32
5. Conta manual de uma iteração . . . 32
6. Quais features usar no `BehavioralClusterer`? . . . 33
7. Número de clusters: decidir e justificar . . . 33
8. Clusters e mudança de regime . . . 34
9. K-Means não detecta fraude . . . 34
10. Código pronto de exemplo . . . 34
11. Erros comuns . . . 35
12. Exercícios . . . 35

Dia 14 — DBSCAN e HDBSCAN: grupos densos, vizinhanças e pontos sem grupo 36
1. Em palavras leigas . . . 36
2. O que significa “densidade” em features? . . . 36
3. DBSCAN: quatro conceitos . . . 36
4. Exemplo manual unidimensional . . . 36
5. Escolha de `eps` e `min_samples` . . . 37
6. Onde DBSCAN falha . . . 37
7. HDBSCAN: a ideia sem exigir implementação da árvore inteira . . . 37
8. Comparação dos três caminhos . . . 38
9. Quando um ponto é rotulado `-1` . . . 38
10. PCA antes de DBSCAN/HDBSCAN: quando ajuda? . . . 38
11. Código reproduzível com scikit-learn . . . 39
12. Projeto mínimo de comparação . . . 39
13. Exercícios . . . 39

Estudo de caso integrado — do dado bruto à evidência de mudança **40**
1. Cenário . . . 40
2. Etapa A — controlar observabilidade (D8) . . . 40
3. Etapa B — extrair features físicas (D9) . . . 40
4. Etapa C — descobrir o instante de ruptura (D10–D11) . . . 41
5. Etapa D — examinar a forma do consumo (D12–D14) . . . 41
6. Resultado operacional prudente . . . 41
7. Modelo de tabela para armazenar resultados . . . 41
8. Fluxo mínimo para a primeira implementação confiável . . . 42

Formulário de consulta — 20 fórmulas e regras **42**
Microprova oral (20 minutos) . . . 43

Gabarito comentado — exercícios dos sete dias **45**
Dia 8 — qualidade e comunicação . . . 45
Dia 9 — engenharia de features . . . 45
Dia 10 — CUSUM . . . 45
Dia 11 — CPD offline e distribuições . . . 46
Dia 12 — PCA . . . 46
Dia 13 — K-Means . . . 46
Dia 14 — densidade . . . 47

Rubrica de compreensão para o tracker (0–5 estrelas) **47**

Apêndice — Referência rápida para implementação e revisão **48**
A. Contrato de dados mínimo . . . 48
B. A distinção estatística que impede diagnósticos incorretos . . . 48
C. Polars Lazy: agregar sem ocultar qualidade . . . 48
D. Checklist de auditoria para qualquer laboratório . . . 49
E. Vocabulário de consulta em português e inglês . . . 49
F. Sugestão de registro no tracker . . . 50
G. Referências para localizar as seções originais . . . 50
H. O que ainda não faz parte desta apostila . . . 50

Guia de entrada

Esta apostila é a continuidade da Semana 1. Na primeira semana aprendemos a descrever observações, respeitar unidades, entender uma série temporal e construir features sem usar informações do futuro. Nesta segunda semana passamos a responder duas questões mais difíceis: **como distinguir falha de medição de mudança real?** e **como comparar padrões de consumo diferentes sem confundir magnitude, forma e contexto?**

Primeiro, em palavras comuns

Imagine uma padaria cujo consumo geralmente aumenta antes do amanhecer. Num certo mês, o gráfico parece despencar. Há três explicações muito diferentes: (a) a padaria realmente consumiu menos; (b) o medidor não comunicou parte dos pacotes; (c) mudou o modo de operação e o consumo permaneceu baixo. Um algoritmo que vê apenas "média mensal baixa" confunde os três casos.

Nosso trabalho de engenharia é, nessa ordem: verificar **se os dados são observáveis e confiáveis**; representar adequadamente o **comportamento normal**; procurar **transições de regime**; e comparar a UC com **padrões semelhantes**. Nenhuma dessas etapas, isoladamente, comprova fraude, defeito, geração distribuída ou irregularidade.

> **Regra de ouro:** anomalia estatística é uma evidência; hipótese causal depende de cruzamento com física, cadastro, alarmística, topologia e, quando necessário, inspeção.

Objetivos da semana

Ao terminar, você deve conseguir:

1. Montar uma grade de timestamps **por canal e cadência vigente**, identificando lacunas sem inventar ausência de pacotes.
2. Definir cobertura, contagem/duração de gaps e decisão de confiabilidade com unidades, denominador e limites documentados.
3. Construir `X_comm` e `X_elec` separadamente, evitando que telemetria ruim se transforme em falsa anomalia elétrica.
4. Explicar e calcular CUSUM, distinção entre *online* e *offline*, e a diferença entre detectar uma mudança e atribuir sua causa.
5. Interpretar uma função de custo de segmentação, a penalização por excesso de mudanças e os algoritmos de varredura/PELT.
6. Calcular uma projeção PCA simples, variância explicada e os riscos de escalar mal os dados.
7. Formular a função-objetivo do K-Means e comparar agrupamentos por centróide versus densidade.
8. Explicar DBSCAN e HDBSCAN, inclusive o significado de "ruído" e de uma UC sem cluster.
9. Defender quais blocos **devem ser implementados agora** e quais permanecem hipóteses de pesquisa.

Dependências diretas da Semana 1

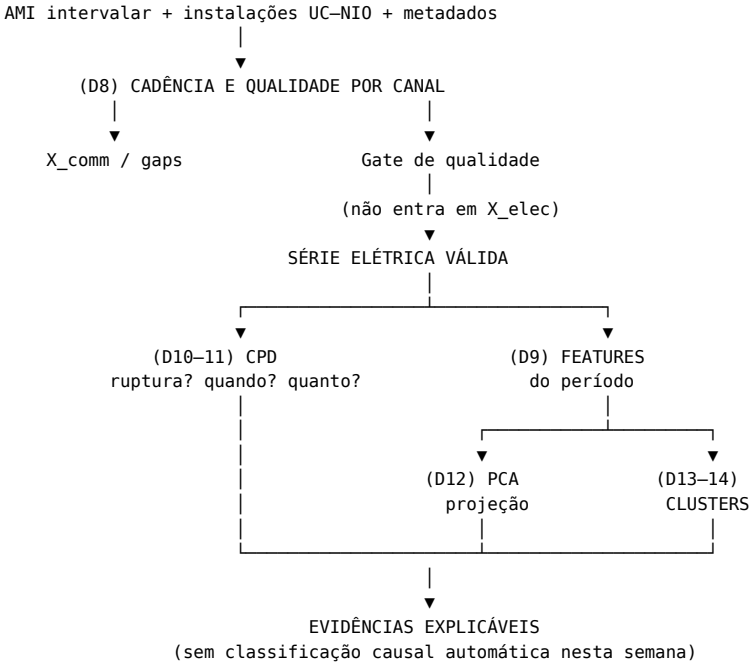
Requisito	Antes de começar, saber explicar
Estatística descritiva	Média, mediana, desvio-padrão, IQR, MAD e quantis
Séries temporais	Janela, lag, série ordenada, sazonalidade, resíduos
Governança temporal	`cutoff_date`, intervalos de instalação UC–NIO, não vazamento de futuro
Álgebra elementar	Vetor, média vetorial, produto escalar, matriz
Física básica	Energia (kWh), potência (kW), tensão (V), medição ausente versus energia nula

Se algum desses itens estiver fraco, revise a apostila anterior antes da derivação correspondente. Não é necessário estudar redes neurais ou PyTorch nesta semana.

Mapa da semana — tópico, equação e função no pipeline

Dia	Núcleo	Fórmula para reconhecer	Onde se encaixa
8	Missing, gaps e completude	$C = N_{obs}/N_{esp}$; $G_{max} = \max_j \lvert g_j \rvert \Delta t$	`S_comm`, confiança de `S_elec`
9	Engenharia de features	$z = (x-\mu)/\sigma$; $x' = \log(1+x)$	Construção de `X_comm` e `X_elec`
10	CPD I: CUSUM	$S_t^+ = \max\{0, S_{t-1}^+ + z_t - k\}$	Alertas de mudança persistente
11	CPD II: segmentação	$\sum_j c(y_{\tau_j:\tau_{j+1}}) + \beta m$	Datas candidatas de ruptura
12	PCA/SVD	$\Sigma v_i = \lambda_i v_i$; $Z = X_c V_k$	Comprimir perfis; estudar redundância
13	K-Means	$\min \sum_i \lVert x_i - \mu_{c_i} \rVert_2^2$	Arquétipos de curva de consumo
14	DBSCAN / HDBSCAN	$N_\varepsilon(x) = \{y : d(x,y) \le \varepsilon\}$	Grupos densos, heterogêneos e ruído

Macroarquitetura: colocar cada ferramenta no lugar



A figura é **arquitetura-alvo didática**, não alegação de que todos os blocos foram implantados ou validados. Resultados reproduzidos nesta apostila utilizam **séries sintéticas**.

Como estudar um capítulo

1. **Entenda como leigo:** uma analogia, uma frase sem símbolos.
2. **Veja o mapa:** qual problema a técnica resolve e o que ela não resolve.
3. **Escreva a fórmula:** defina unidades, índices, hiperparâmetros e hipóteses.
4. **Faça uma conta curta:** antes de ver o código.
5. **Teste:** um experimento reproduzível, com dados sintéticos.
6. **Critique:** que erro de observabilidade, escalonamento ou validação destruiria a conclusão?
7. **Anote no tracker:** leitura concluída não equivale a conceito dominado; use a escala de 0–5 estrelas por conceito.

Sessão sugerida: 50 min leitura, 30 min contas, 60 min laboratório, 25 min explicação oral, 15 min registro. O capítulo de CPD provavelmente exigirá mais de uma sessão; o prazo é um **marco de competência**, não um limite rígido para entender matemática.

Fontes, edições e escopo

As obras abaixo foram consultadas em **suas edições presentes no acervo enviado**, não em edições genéricas de internet.

Código	Obra fornecida	Base principal da semana
HY	R. J. Hyndman; G. Athanasopoulos. *Forecasting: Principles and Practice*, **2ª ed. (2018)**	§12.9 missing e outliers; §§3.2–3.3 ajustes e resíduos; ch. 6 decomposição
ZC	A. Zheng; A. Casari. *Feature Engineering for Machine Learning* (2018)	ch. 1–2, ch. 6, ch. 7, apêndice A
GE	A. Géron. *Hands-On Machine Learning with Scikit-Learn and PyTorch* (**edição fornecida de 2025**)	ch. 2, ch. 7 e ch. 8

Código	Obra fornecida	Base principal da semana
TR	C. Truong; L. Oudre; N. Vayatis. *Selective Review of Offline Change Point Detection Methods* (arXiv:1801.00718v3)	§§2–6, seção 8 e bibliografia
BR	P. Bruce; A. Bruce; P. Gedeck. *Practical Statistics for Data Scientists*, 2ª ed. (2020)	reforço de escalonamento, distribuições e correlação

Delimitação de fontes: o artigo TR trata de **CPD offline**. As fórmulas de CUSUM sequencial, a recomendação de gate de completude e a arquitetura UC–NIO são **sistematização didática/aplicação do projeto**, não prescrições literais dessas obras. Referências de pesquisa externa e definições convencionais aparecem ao longo do texto, sem reproduzir longos trechos protegidos por direitos autorais.

Checklist de saída — versão curta

- ☐ Sei definir `N_expected` com instalação, cadência e canal configurado.
- ☐ Sei diferenciar `NaN`, zero legítimo, ausência por atraso e desconexão.
- ☐ Sei definir features com agregação e sem vazamento de futuro.
- ☐ Sei obter e interpretar um CUSUM de pelo menos cinco observações.
- ☐ Sei mostrar quando CPD online seria diferente de offline.
- ☐ Sei explicar PCA sem confundir componentes com variáveis físicas.
- ☐ Sei calcular uma iteração de K-Means manualmente.
- ☐ Sei descrever core/border/noise no DBSCAN e a ideia de estabilidade do HDBSCAN.
- ☐ Sei propor uma validação que não dependa de rotular toda UC estranha como fraude.

Dia 8 — Dados ausentes, gaps e confiabilidade da medição

Referências: HY §12.9 (*Missing Values and Outliers*, edição 2), contextualização temporal de HY §§2.1–2.8; BR ch. 1 como revisão. **Prazo de domínio:** definir a cadência de cada canal, construir uma máscara observacional e calcular cobertura/gaps sem chamar consumo nulo de "falha".

1. Primeiro, em palavras leigas

Um relógio de ponto deve registrar a entrada de um funcionário às 8h. Se a folha está vazia, isso não prova que ele faltou: pode ter falhado o relógio, a transmissão, a importação, ou ser dia de folga. Da mesma forma, **uma medição elétrica que não chegou não é uma medição de energia igual a zero**.

Há dois problemas distintos: **o que realmente aconteceu no sistema elétrico** e **o que nosso sistema conseguiu observar**. O modelo de comunicação estuda o segundo; o elétrico tenta estudar o primeiro, somente quando há informação suficiente.

2. Como a ideia entra no TCC

Uma UC pode receber energia normalmente, mas ter um modem intermitente. Se completarmos cada intervalo ausente com zero, criaremos artificialmente uma queda de consumo. Se interpolarmos uma desconexão de três dias, criaremos um consumo artificialmente estável. As duas práticas podem induzir falsas irregularidades.

A arquitetura separa três saídas:

1. **`observation_mask`**: onde a medida existiu, onde era esperada e onde não era aplicável.
2. **`X_comm`**: características de disponibilidade, gaps, alarmes e atraso.
3. **`quality_gate`**: decisão operacional sobre a suficiência da janela usada por `S_elec`.

O *gate* não determina verdade física: apenas declara que um score elétrico não deve ser apresentado como confiável com informação insuficiente.

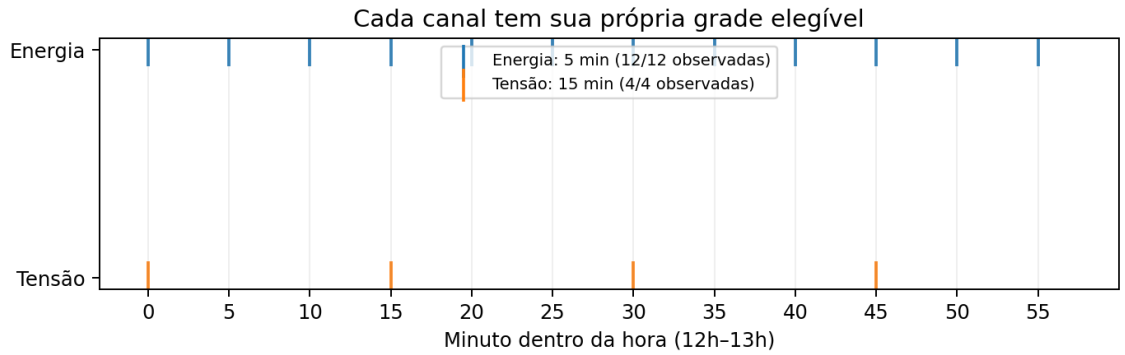


Figura 1: Cobertura calculada com cadências diferentes por canal

3. O primeiro erro: assumir uma cadência universal

Considere uma janela de uma hora, com os seguintes instantes esperados, entre 12h inclusive e 13h exclusivo:

- Energia a cada **5 min**: 12 medições esperadas.
- Tensão a cada **15 min**: 4 medições esperadas.

Se ambos os canais estiverem completos, um grid artificial de 5 min faria parecer que a tensão teve 8 intervalos faltantes em 12. A taxa inventada seria $4/12 = 33{,}3\%$ em vez de $4/4 = 100\%$.

Premissa do cálculo: canal ativo, medidor instalado, cadência contratada/configurada e janela elegível. Horário de manutenção, instalação de equipamento ou mudança de configuração precisam entrar na definição do que seria esperado.

No TCC, o grão de extração pode ser NIO × timestamp, mas o grão analítico pode ser UC × dia. Precisamos de uma tabela de vigências para transformar um no outro.

3.1. Três estados, não dois

Defina uma variável de observação para um canal c e instante t:

$$M_{c,t} = \begin{cases} 1, & \text{medição válida observada,} \\ 0, & \text{medição esperada, mas ausente,} \\ \text{NA}, & \text{medição não exigida/aplicável.} \end{cases}$$

O valor físico $E_{c,t} = 0$ é um possível conteúdo de uma medição com $M_{c,t} = 1$. Confundir M com E é um erro de semântica, não de algoritmo.

4. Fórmulas fundamentais

4.1. Completude por canal

Para janela W, conjunto $\mathcal{E}_c(W)$ de timestamps elegíveis e válidos pela configuração:

$$C_c(W) = \frac{N_{\text{obs},c}(W)}{N_{\text{esp},c}(W)}, \quad N_{\text{esp},c}(W) = |\mathcal{E}_c(W)|.$$

- C_c: razão sem unidade, $0 \le C_c \le 1$.
- N_{obs}: contagem de leituras **válidas e distintas** nos instantes esperados.
- N_{esp}: instantes que deveriam produzir leitura, após vigência/cadência.
- Se $N_{esp} = 0$, **não atribua 0%**: a cobertura é indefinida (`null`, `not_applicable`).

Exemplo: intervalo nominal de 15 min durante 24 h, com 4 registros faltantes: $N_{esp} = 96$, $N_{obs} = 92$, $C = 92/96 = 0{,}95833$ (95,83%).

4.2. Runs de falha (*gaps*)

Defina $A_t = 1 - M_t$ nos instantes elegíveis. Um *run* é uma sequência maximal de índices com $A_t = 1$; para a lacuna j de comprimento n_j:

$$D_j = n_j \Delta t, \qquad N_{gaps} = \#\{j\}, \qquad G_{\text{max}} = \max_j D_j, \qquad G_{\text{médio}} = \frac{\sum_j D_j}{N_{gaps}}.$$

A duração D_j está em minutos se Δt estiver em minutos. Se **não houver gaps**, recomenda-se $N_{gaps} = 0$ e $G_{max} = 0$; para a média, usar 0 ou `null` com convenção documentada.

4.3. Persistência e horário da falha

Contagens de gaps sozinhas escondem estrutura. Um modem com dez perdas isoladas e outro com uma ausência de dez pacotes têm a mesma completude, mas comportamento diferente.

Possíveis features:

$$R_{\text{noite}} = \frac{\#\{t : M_t = 0,\ 0 \le h(t) < 6\}}{\#\{t : M_t = 0\}}$$

Quando não houver perdas, essa razão é **indefinida**; não a interprete como “0% de falhas à noite” sem contextualização. Outra feature é a moda da hora do primeiro instante de cada gap; evite forçá-la como variável contínua linear (23h e 0h são vizinhas no relógio).

5. Exemplo totalmente resolvido

Cadência 15 min, janela de 12:00 a 14:00 (**8 pontos**). Sequência de presença:

Hora	12:00	12:15	12:30	12:45	13:00	13:15	13:30	13:45
Presença	1	1	0	0	1	0	1	1

Passo 1: $N_{esp} = 8$; $N_{obs} = 5$; $C = 5/8 = 62{,}5\%$.

Passo 2: runs ausentes $[12{:}30, 12{:}45]$ (2 intervalos) e $[13{:}15]$ (1 intervalo). Assim, $N_{gaps} = 2$.

Passo 3: durações: 30 e 15 min, $G_{max} = 30$ min, média $22{,}5$ min; percentil 95 dos dois runs depende da convenção de interpolação de quantis (NumPy pode retornar 29,25 min).

Passo 4: a série de energia nesses três momentos continua **desconhecida**. Não é correto inferir 0 kWh.

Passo 5: se o gate ilustrativo de qualidade fosse $0{,}70$, a janela seria insuficiente para um score elétrico confiável. Esse $0{,}70$ é **heurística do projeto**, não limite universal ou regulatório; deve ser avaliado empiricamente.

6. Três mecanismos de ausência: MCAR, MAR, MNAR

Não é necessário dominar inferência formal agora. Basta reconhecer como a interpretação muda:

- **MCAR** (*Missing Completely at Random*): a ausência não depende nem das variáveis observadas nem do valor ausente. Ex.: perda aleatória genuína de pacotes, condicionada a hipóteses fortes.
- **MAR** (*Missing at Random*, termo histórico): dadas variáveis observadas, a ausência não depende do valor faltante. Ex.: canal falha mais em determinada área/tecnologia já identificada no cadastro.
- **MNAR** (*Missing Not at Random*): mesmo após considerar os observáveis, a ausência depende do que não observamos. Ex.: medidor falha durante determinado regime elétrico não medido.

Não é possível deduzir qual mecanismo ocorre só olhando os `null`. Os termos são **hipóteses sobre mecanismo de ausência**, não etiquetas diagnósticas garantidas.

7. O que observar antes de imputar

Uma média mensal pode preservar nível médio e destruir eventos. Interpolação local pode ser aceitável para um buraco isolado em variável suavemente variante, mas **energia intervalar não é a mesma coisa que tensão média**, e não há garantia de que consumo siga reta entre amostras.

Política inicial por tipo de tarefa:

Tarefa	Tratamento básico	Alerta
Comunicação	Guardar máscara, gaps e horários	Não imputar presença
Energia e potência	Preserve ausência; agregue só dados válidos e registre cobertura	Soma parcial não é consumo total diário
Médias físicas	Agregação de válidos com cobertura explícita	Viés se ausência correlaciona com regime
PCA/K-Means	Filtrar cobertura e imputar feature **depois** do split, usando treino	Imputer pode distorcer clusters
Auditoria	Preservar bruto, duplicidades e correções	Deduplicação precisa regra temporal

A imputação que se aprende no `fit` deve usar exclusivamente treino. Dados de teste nunca podem determinar a mediana usada pelo `SimpleImputer`.

8. UC–NIO, relógio e chegada atrasada

Suponha UC `U005` instalada com NIO `N1` até 14:59 e NIO `N2` a partir de 15:00. Uma linha `N1` às 15:15 não deveria entrar automaticamente no histórico da UC; é necessário investigar inconsistência de vigência. O inverso, ausência de leitura do NIO antigo após a retirada, **não é falha de comunicação** da UC.

Outra diferença: `ORIGIN_TIME` do alarme reflete relógio/registro de origem, e `ACTING_TIME` o recebimento. A diferença pode indicar atraso de comunicação, mas também problemas de clock, buffering e sincronização. Não interprete toda latência alta como modem ruim.

Eventos reportados atrasados devem ter um **instante de medição** e um **instante de disponibilidade**. Uma inferência feita às 16:00 só poderia usar aquilo disponível até 16:00. Esse detalhe é indispensável ao simular monitoramento online.

9. Laboratório mínimo reproduzível

```python
import numpy as np

presence = np.array([1, 1, 0, 0, 1, 0, 1, 1], dtype=bool)
cadence_minutes = 15
coverage = presence.mean()
missing = ~presence
starts = np.flatnonzero(missing & ~np.r_[False, missing[:-1]])
ends = np.flatnonzero(missing & ~np.r_[missing[1:], False])
durations = (ends - starts + 1) * cadence_minutes

print("coverage:", coverage)           # 0.625
print("gaps:", len(durations))        # 2
print("durations_minutes:", durations)  # [30, 15]
print("longest_gap:", durations.max())  # 30
```

Na escala do projeto: implemente uma função por canal que receba (`cadence_history`, `installation_history`, `observations`, `cutoff_date`) e devolva `coverage`, `gap_count`, `longest_gap`, `eligible_expected_count`. Evite um `asfreq('5min')` indiscriminado.

10. Erros que anulariam a análise

1. Associar todos os canais a 5 min quando alguns são 15 min.
2. Contar o período anterior à instalação como falha de pacotes.
3. Tratar atraso de ingestão como ausência definitiva sem política de reprocessamento.
4. Calcular energia diária como soma de 40 observações, chamando-a de “consumo diário total”, quando eram esperadas 96.
5. Usar completude do mês no `X_elec` e atribuir score elétrico alto porque transmissão falhou.
6. Comparar famílias de medidores sem verificar se os canais estão realmente disponíveis nos dois grupos.

11. Exercícios de domínio

E8.1. Canal de 10 min com janela de 24 h e 127 registros válidos distintos: determine cobertura. A pessoa diz “houve 17 pacotes faltantes”. Em que premissas a conclusão é válida?

E8.2. Dois medidores têm 90% de cobertura: A perde 10 pacotes isolados; B perde dez consecutivos. Que features diferenciam suas falhas? Justifique impacto operacional.

E8.3. Uma janela de 30 dias contém troca de medidor no dia 12. Como construir cobertura da UC sem penalizar a transição indevidamente?

E8.4. Você encontra zero registrado em todos os intervalos de um domingo e tensão normal. Por que isso ainda não prova imóvel desocupado?

Checklist e ligação ao tracker

- ☐ Defino `N_expected` sem inventar cadência.
- ☐ Calculo runs consecutivos com unidades.
- ☐ Descrevo dois mecanismos diferentes que produzem a mesma completude.

- ☐ Explico por que `S_comm` e `S_elec` são vistas diferentes.
- ☐ Respondo E8.1–E8.4 sem consultar.

Ficha de conceito sugerida: `completude`, `cadência`, `run/gap`, `MCAR/MAR/MNAR`, `data_quality`, `gating`. Dê 5 estrelas apenas se conseguir implementar e criticar o cálculo em dados reais.

Dia 9 — Engenharia de features: representar o fenômeno, não a planilha

Referências: ZC ch. 1 (*The Machine Learning Pipeline*) e ch. 2 (*Fancy Tricks with Simple Numbers*), pp. 17–56 do PDF; GE ch. 2; BR ch. 1. **Prazo de domínio:** justificar cada coluna do vetor de entrada, seu cálculo, sua unidade, seu risco de vazamento e sua relação com o fenômeno estudado.

1. Em linguagem simples

Uma pessoa pode ser descrita por altura, peso, idade e número de sapato. Se queremos detectar mudança no hábito de caminhar, essas descrições são insuficientes: precisaremos de passos por dia, horas de atividade, tendência semanal. **Escolher features é decidir o que o modelo pode enxergar.**

Uma linha de telemetria bruta tem timestamp, NIO e valor medido. Uma linha analítica UC × data de corte pode conter mediana de energia diária, inclinação da tendência e assimetria de corrente. O cálculo que transforma as primeiras linhas nas últimas é a **engenharia de atributos**.

2. A pergunta que toda feature deve responder

Antes de calcular, preencha mentalmente:

- **Fenômeno:** consumo, comunicação, qualidade de energia ou cadastro?
- **População:** UC residencial e industrial podem ser comparadas diretamente?
- **Janela:** 1 dia, 7 dias, 30 dias, antes/depois do evento?
- **Unidade:** V, kW, kWh/dia, %, minutos, razão adimensional?
- **Observabilidade:** qual canal precisa existir?
- **Vazamento:** a informação existia no `cutoff_date`?
- **Interpretabilidade:** um valor alto significa exatamente o quê?

O erro não é ter poucas features. O erro é ter muitas features **sem contrato semântico**.

3. Quatro famílias separadas

Prefixo	Exemplos	Pode entrar no estimador?
`id__`	UC, NIO atual, ID do trafo	**Não**: identificadores, nunca variáveis físicas
`meta__`	`cutoff_date`, `data_quality`, família de medidor, split	Em regra **não**; úteis para gates, avaliação e segmentação
`x__`	mediana de FA, razão diurna, desvios de tensão	**Sim**, se pertinentes ao modelo e disponíveis na época
`y__`	irregularidade confirmada em inspeção	Só em tarefas supervisionadas, com proveniência adequada

Para `S_comm`, `x__` são features **de telecom**; para `S_elec`, `x__` são exclusivamente **elétricas**. O prefixo sozinho não basta: mantenha schemas/allowlists diferentes, não apenas filtros por nome genérico.

4. Transformações numéricas sem perder o sentido físico

4.1. Padronização (*standardization*)

$$z_i = \frac{x_i - \mu_{train}}{\sigma_{train}}.$$

- x: feature na unidade original.
- $\mu_{train}, \sigma_{train}$: média e desvio aprendidos **somente no treino**.
- z: adimensional; $z = 2$ significa duas unidades de desvio acima da média de referência, não "dobro de consumo".

Exemplo: mediana $\mu = 20$ kWh/dia, desvio $\sigma = 5$ kWh/dia, UC com 30 kWh/dia: $z = (30 - 20)/5 = 2$.

Quando $\sigma = 0$, uma variável constante não carrega informação de variação; bibliotecas robustas tratam casos degenerados, mas devemos reconhecê-los.

4.2. Escalonamento robusto

$$r_i = \frac{x_i - \tilde{x}_{train}}{Q_{0.75,train} - Q_{0.25,train}}.$$

Usa mediana $\tilde{x}$ e intervalo interquartil (IQR). É menos sensível a pontos extremos na estimação de centro e escala. **Não elimina outliers** nem é garantia de melhora do modelo.

4.3. Transformação logarítmica

Para contagens e grandezas não negativas com cauda longa:

$$x' = \log(1 + x).$$

Ela comprime diferenças proporcionais em valores altos. Só faz sentido para valores com domínio compatível; não aplique cegamente a energia reversa com sinal ou a variáveis que possuem negativos significativos. O número somado antes do log determina escala e precisa considerar unidade; em produção, defina referência adimensional apropriada.

4.4. Ratios e denominadores pequenos

Uma variável como

$$R_{rev} = \frac{E_{reversa}}{E_{direta}}$$

explode se $E_{direta} \to 0$. Substituir denominador por ϵ arbitrário pode produzir outliers numéricos artificiais. Alternativas: declarar `null` abaixo de limite físico, usar duas grandezas separadas, limitar a análise a janelas elegíveis ou registrar um indicador de denominador pequeno **fora de `X_elec` quando ele representar insuficiência de dado**, não comportamento físico.

5. Features da AMI: não misture forma e magnitude

5.1. Magnitude

Mediana diária de energia direta:

$$f_{\text{med}} = \text{mediana}_{d \in W} \left(E_{FA,d} \right),$$

com $E_{FA,d} = \sum_{t \in d} E_{FA,t}$ **somente se a cobertura diária for suficiente**. Se não, marque o dia insuficiente ou use uma política de estimação explicitamente validada.

5.2. Variabilidade robusta

$$\text{MAD}_{FA} = \text{mediana}_{d \in W} \, |E_{FA,d} - f_{\text{med}}|.$$

Unidade: kWh/dia. **MAD bruto não equivale a desvio-padrão**; a constante 1,4826 às vezes aproxima a escala de σ sob normalidade, mas não deve ser aplicada sem motivo.

5.3. Tendência

Regressão linear descritiva em índices diários $d = 1, 2, \ldots, n$:

$$\hat{\beta}_1 = \frac{\sum_d (d - \bar{d})(E_{FA,d} - \bar{E})}{\sum_d (d - \bar{d})^2}.$$

Unidade: kWh/dia **por dia**. Para dias irregulares, use o tempo real em vez de índice sequencial; do contrário, o slope fica distorcido.

5.4. Forma de curva (independente de escala)

Para cada UC, média por hora h de energia/potência em intervalos comparáveis $e_h \geq 0$, defina:

$$p_h = \frac{e_h}{\sum_{j=0}^{23} e_j}, \quad \sum_{h=0}^{23} p_h = 1.$$

Se o denominador for zero/insuficiente, a curva normalizada não existe. Com p_h, duas UCs podem ter forma semelhante mesmo consumindo quantidades absolutas diferentes. Isso é excelente para *clustering* comportamental, mas perde a informação de magnitude. Portanto, registre também magnitude e cobertura.

5.5. Codificação de hora cíclica

$$\text{peak_sin} = \sin(2\pi h_{pico}/24), \quad \text{peak_cos} = \cos(2\pi h_{pico}/24).$$

O par representa 23h próximo de 0h no círculo; um inteiro `23` sozinho pareceria muito distante de `0` na distância euclidiana.

6. Exemplo numérico — mesma forma, magnitudes distintas

Duas UCs com energia por quatro blocos de seis horas:

UC	Madrugada	Manhã	Tarde	Noite	Total
Residência A	1	2	1	6	10 kWh
Residência B	10	20	10	60	100 kWh
Loja C	1	5	5	1	12 kWh

Curvas normalizadas A e B: $(0{,}1; 0{,}2; 0{,}1; 0{,}6)$, **iguais**. Curva C: $(1/12; 5/12; 5/12; 1/12)$, diferente. Distância em kWh faria A e C parecerem muito mais semelhantes do que A e B; em forma normalizada, a conclusão se inverte.

Lição: antes de escolher K-Means, declare se buscamos arquétipos de magnitude ou de forma. As duas tarefas são legítimas, mas não intercambiáveis.

7. Categóricas, classes e risco de atribuir ordem

`CLASSE=Residencial/Comercial/Industrial` não possui ordem numérica universal. Codificar `1,2,3` e medir distância euclidiana pressupõe artificialmente que industrial está duas unidades "mais longe" de residencial do que comercial. Para modelos compatíveis, use One-Hot Encoding aprendido em treino; ou, preferencialmente, compare populações por classe antes de agrupar.

Categorias operacionais também podem mudar: `meta__classe` deve respeitar a **data de validade**, não o valor cadastral mais recente aplicado retroativamente.

8. Seleção e redundância

Se duas variáveis são quase cópias (ex.: mediana diária e média diária em consumo muito regular), dão peso duplicado a uma dimensão de comportamento. Em métodos baseados em distância, isso altera a geometria. Em alguns modelos de árvore, pode ter menor impacto, mas redundância ainda atrapalha interpretação.

Comece com catálogo reduzido e avalie ablação:

1. **Baseline físico:** energia direta, reversa, desequilíbrio, perfil.
2. + **temporal:** slope, autocorrelação, métricas CPD.
3. + **contexto:** classe/segmentação adequada, mas metadados não viram ID disfarçado.
4. **Sem missingness em `X_elec`:** o gate é aplicado antes de inferir.

Compare estabilidade, distribuição de scores e revisão manual dos casos. Sem labels, não chame "melhora" qualquer aumento da taxa de alertas.

9. Pipeline seguro no scikit-learn

```python
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import RobustScaler, OneHotEncoder

numeric = ["fa_median", "fa_mad", "trend_slope"]
categorical = ["class"]

prep = ColumnTransformer(
    transformers=[
        ("num", Pipeline([
            ("impute", SimpleImputer(strategy="median")),
            ("scale", RobustScaler()),
        ]), numeric),
        ("cat", OneHotEncoder(handle_unknown="ignore"), categorical),
    ],
    remainder="drop",
)

# prep.fit(X_train) aprende medianas/escalas/categorias apenas do treino.
# prep.transform(X_test) usa os parâmetros do treino.
```

Importante: manter missingness fora de `X_elec` não exige rejeitar *toda* amostra com feature ausente. O gate filtra janelas inadequadas; uma quantidade residual de `NaN` pode ser imputada cuidadosamente depois do split, se o procedimento for compatível com a física e com a validação. A imputação não deve transformar uma janela sem consumo observado em "consumo típico" sem ressalva.

10. Exemplo de ficha de feature que serve ao TCC

Campo	Conteúdo
Nome	`x__trend_fa_slope`
Entidade e grão	UC × `cutoff_date`
Origem	Energia direta intervalar de NIO vigente
Unidade	(kWh/dia)/dia
Janela	Últimos 30 dias completos até o cutoff
Agregação	Soma diária dos intervalos válidos, mínimo de cobertura definido
Cálculo	Coeficiente angular de reta ajustada em função dos dias
Exclusões	Dias sem cobertura, períodos sem instalação válida
Interpretação	Direção/magnitude de mudança aproximadamente linear
Risco	Sazonalidade, feriados, troca de medidor e mudança de cadastro
Entrada	`S_elec`, após gate de qualidade

Uma ficha por feature evita a situação em que nomes obscuros como `HIST_FA_SUM_MEDIAN` viram a única "documentação" do algoritmo.

11. Exercícios de domínio

E9.1. Uma feature tem média de treino 80 e desvio 20; UC tem 110. Calcule z-score. O z-score seria diferente se a média fosse estimada no teste? Isso seria permitido?

E9.2. Um vetor de curva de quatro intervalos é $(0, 3, 0, 3)$ kWh. Normalize para soma 1. É aceitável calcular essa normalização quando os intervalos de tarde faltaram?

E9.3. Considere `FA=0` e `RA=2`. O que acontece com `RA/FA`? Proponha política sem inventar valor infinito como indicador de fraude.

E9.4. Dê duas features elétricas e duas de comunicação com unidades, janelas e tratamento de ausência.

Checklist

- ☐ Sei explicar por que escalas de kW, kWh e % não são intercambiáveis.
- ☐ Sei separar forma do perfil e magnitude absoluta.
- ☐ Sei evitar `fit` do scaler/imputer no teste.
- ☐ Sei documentar as entradas por modelo especializado.
- ☐ Tenho respostas para E9.1–E9.4.

Dia 10 — Change Point Detection I: reconhecer uma mudança de regime com CUSUM

Referência-base de CPD: TR §§2 e 4.1, sobretudo formulação de pontos de mudança, modelos de segmentos e funções de custo. **CUSUM sequencial:** explicação matemática complementar baseada em teoria clássica de controle estatístico de processos; **não confundir** com uma seção central do artigo TR, cujo foco é detecção **offline**. **Prazo de domínio:** saber calcular CUSUM, explicar baseline, parâmetros de referência/limiar e distinguir alerta de diagnóstico causal.

1. Em palavras leigas

Você acompanha uma pessoa que costuma chegar ao trabalho às 8h. Um atraso isolado de 15 minutos não muda seu hábito. Mas uma sequência de pequenos atrasos pode indicar mudança de turno. **CUSUM guarda memória dos pequenos desvios**: os soma progressivamente e dispara somente quando a acumulação ultrapassa um limite.

Em uma UC, um consumo diário abaixo do esperado pode ser férias, chuva, erro de medição ou mudança de operação. Uma queda persistente após determinada data merece atenção; CUSUM é uma maneira simples de monitorar essa persistência.

2. O que é uma mudança de regime?

Considere uma série $y_1, \dots, y_T$. Dizemos haver um *change point* τ se certas propriedades de sua distribuição mudam entre antes e depois de τ, por exemplo:

$$y_t \sim F_0 \quad (t < \tau), \qquad y_t \sim F_1 \quad (t \geq \tau), \qquad F_0 \neq F_1.$$

A mudança pode ser de **média**, **variância**, **padrão horário**, **autocorrelação** ou de várias propriedades juntas. Portanto, CPD não significa sempre "degrau na média". Um detector de média é apenas um tipo de CPD.

Distinções importantes:

- **Outlier pontual:** um dia apresenta valor raro, mas os próximos voltam ao normal.
- **Mudança persistente:** um novo patamar começa e permanece.
- **Deriva gradual:** o patamar se desloca lentamente, sem instante exato evidente.
- **Mudança sazonal esperada:** feriados, safra agrícola, férias, horário comercial; não necessariamente anomalia.

3. Primeiro remova o comportamento previsível

Se uma padaria consome muito de manhã e pouco de madrugada, aplicar CUSUM diretamente na série de 15 minutos acumulando desvios de uma média global causará falsos alertas a cada mudança de horário.

Uma aproximação é calcular resíduo:

$$e_t = y_t - \widehat{m}(h_t, d_t, c_t),$$

onde $\widehat{m}$ é a referência **estimada apenas com dados disponíveis até o momento da análise** e h_t, d_t, c_t representam hora, dia da semana e contexto relevante. Na versão diária, pode ser o consumo observado menos a mediana de dias comparáveis ou menos uma previsão sazonal.

Em seguida, padronize em relação à variabilidade histórica:

$$z_t = \frac{e_t - \mu_{e,0}}{\sigma_{e,0}}, \qquad \sigma_{e,0} > 0.$$

Se os resíduos forem muito assimétricos ou tiverem picos, uma escala robusta pode ser investigada. **Padronizar por mediana/MAD não torna os dados automaticamente normais**.

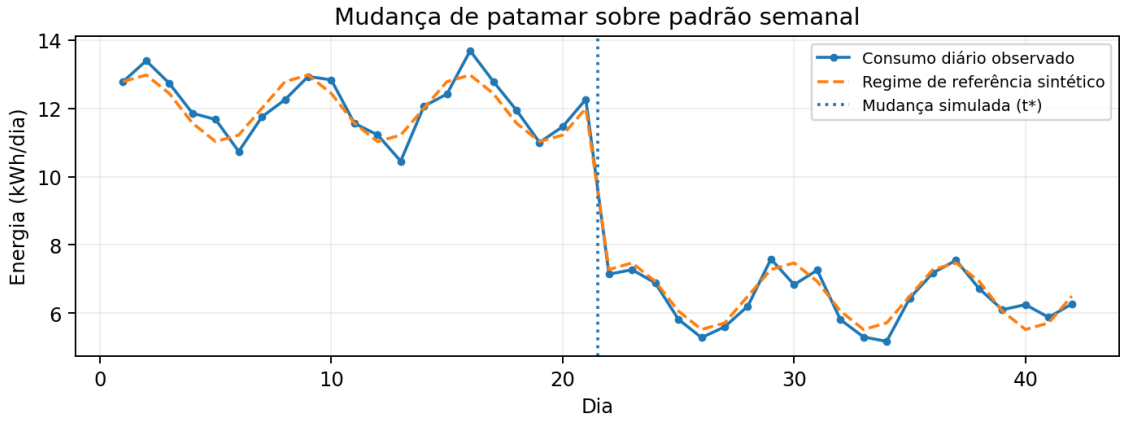


Figura 2: Consumo diário com alteração persistente e sazonalidade

4. CUSUM bicaudal: duas perguntas separadas

O CUSUM positivo procura aumentos sustentados:

$$S_t^+ = \max(0, S_{t-1}^+ + z_t - k), \qquad S_0^+ = 0.$$

O negativo procura quedas sustentadas:

$$S_t^- = \max(0, S_{t-1}^- - z_t - k), \qquad S_0^- = 0.$$

O alarme é emitido se $S_t^+ > h$ ou $S_t^- > h$ (defina e mantenha a convenção $>$ ou $\geq$).

Símbolo	Leitura física/estatística
z_t	Desvio padronizado da referência, adimensional
k	Valor de referência, região de tolerância a pequenas oscilações
h	Limiar acumulado de disparo
S_t^+	Evidência acumulada de **aumento**
S_t^-	Evidência acumulada de **queda**

O operador $\max(0, \cdot)$ impede acumular negativamente para sempre; quando evidência deixa de apontar naquela direção, a memória diminui até zero.

4.1. Por que há um k?

Sob hipótese simples de resíduos independentes aproximadamente normais com variância unitária, detectar um deslocamento de média de δ desvios-padrão sugere referência $k \approx \delta/2$. Essa interpretação deriva da razão de verossimilhanças sequencial. Não é um valor ótimo universal; autocorrelação, sazonalidade residual e custos de falso alarme exigem calibração.

4.2. O que significa h?

h regula sensibilidade: pequeno detecta cedo, mas gera mais alarmes; grande pede evidência mais persistente. Um $h = 3$ de exemplo **não constitui evidência de 99,7% de confiança** nem um p-valor. A avaliação relevante pode ser taxa de falsos alertas em períodos conhecidos como estáveis, atraso médio de detecção e custo operacional por alerta.

5. Conta resolvida, passo a passo

Considere resíduos diários padronizados:

$$z = (0{,}2, -0{,}4, -1{,}0, -1{,}5, -1{,}3, -0{,}8).$$

Adote $k = 0{,}25$, $h = 3{,}0$ e calcule S_t^-. Queremos detectar queda de consumo.

Dia	z_t	Parcela $-z_t - k$	$S_t^- = \max(0, S_{t-1}^- +$ parcela$)$
1	+0,20	-0,45	0,00
2	-0,40	+0,15	0,15
3	-1,00	+0,75	0,90
4	-1,50	+1,25	2,15
5	-1,30	+1,05	3,20
6	-0,80	+0,55	3,75

Resultado: primeiro cruzamento de $h = 3$ no dia 5. O algoritmo diz que há **evidência acumulada de redução**, não que "uma fraude começou no dia 5". O instante real da mudança pode ser anterior ao disparo; CUSUM tem atraso de detecção.

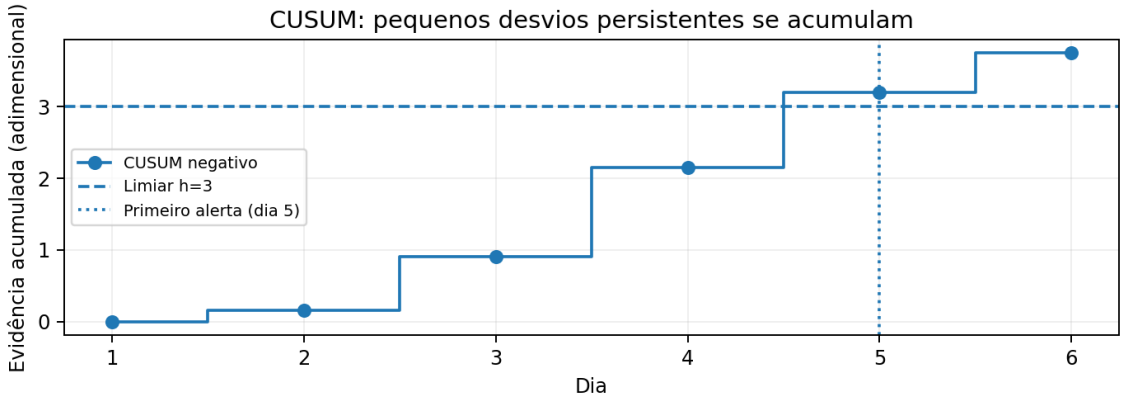


Figura 3: CUSUM negativo: acúmulo e disparo

6. Como determinar a data estimada da mudança?

O dia do alarme não é necessariamente t^*. Uma estimativa informal é rastrear o ponto em que a soma começou a subir de forma sustentada (último reinício em zero), mas essa heurística não fornece automaticamente um estimador ótimo do change point. Na avaliação offline podemos usar um método de segmentação sobre uma janela maior para estimar a ruptura.

Isso leva a uma arquitetura prudente:

```
CUSUM online → data de alerta → candidato de mudança
                                        |
                                        ▼
                                  análise histórica
                               e estimativa do t* (offline)
                                        |
                                        ▼
                                 comparação antes/depois
```

Uma decisão **operacional no dia** t não pode usar dados de $t + 1$; uma reconstrução **retrospectiva** pode fazê-lo desde que seja identificada como análise posterior.

7. CUSUM versus desvio-padrão de janela

Uma média de 30 dias pode esconder uma redução nos últimos cinco. Exemplo:

- 20 dias consumindo 10 kWh/dia.
- 10 dias consumindo 4 kWh/dia.

A média de 30 dias é $(20 \cdot 10 + 10 \cdot 4)/30 = 8$ kWh/dia; não revela quando ocorreu a queda. O CPD procura **a ordem temporal e o contraste entre regimes**, que a média agregada perde.

Se a queda já dura seis meses e só temos 30 dias recentes, não existe referência anterior **dentro da janela**. CPD não cria memória histórica que não foi extraída. A solução é armazenar um baseline anterior legítimo ou comparar com contexto/pares, registrando a limitação.

8. O que precisa acontecer antes do CUSUM em AMI

1. Validar canal e cobertura; não transformar gaps em zeros.
2. Garantir horários locais consistentes (Brasil: `America/Sao_Paulo`) e vigência do medidor.
3. Escolher resolução de análise. Para consumo comportamental, **diário** pode ser mais robusto que 15 minutos.
4. Separar dias úteis, fim de semana, eventos especiais e mudanças cadastrais quando aplicável.
5. Estimar referência apenas no passado e observar *drift* legítimo.
6. Verificar autocorrelação dos resíduos; independência é hipótese importante em calibrações clássicas.
7. Associar sinal detectado à janela e à qualidade, não a um veredito causal.

Alarme de violação física pode reforçar investigação, mas sozinho não constitui confirmação de fraude. Uma inspeção de campo com rótulo confiável pertence a uma etapa posterior.

9. Laboratório reproduzível

```python
import numpy as np

z = np.array([0.2, -0.4, -1.0, -1.5, -1.3, -0.8])
k, h = 0.25, 3.0
s_plus = s_minus = 0.0
for t, value in enumerate(z, start=1):
    s_plus = max(0.0, s_plus + value - k)
    s_minus = max(0.0, s_minus - value - k)
    print(t, round(s_plus, 2), round(s_minus, 2), s_minus > h)
```

Experimento obrigatório: mantenha a mesma série e teste $k \in \{0{,}25, 0{,}5\}$, $h \in \{2, 3, 4\}$. Compare primeira data de alerta e número de disparos, documentando necessidade de política de reset após um alerta (se você continuar acumulando, vários pontos consecutivos acima do limiar não são necessariamente “várias fraudes”).

10. Não confunda score, hipótese e causa

- CUSUM alto = **evidência acumulada em um processo de monitoramento**.
- CPD detectado = **hipótese de mudança em propriedade estatística**.
- Queda de FA = **alteração em energia registrada**, que pode ter várias origens.
- Fraude = **hipótese causal específica que exige corroboração**, idealmente inspeção.

Não produza `cpd_confidence=0.93` sem definir método de estimação e validação; um valor normalizado ad hoc é **score**, não probabilidade nem significância estatística.

11. Exercícios

E10.1. $z = (-0{,}3, -0{,}9, -1{,}2)$, $k = 0{,}2$, $h = 1{,}5$. Calcule S_t^- em cada dia e a primeira ocorrência de $S_t^- > h$.

E10.2. A padaria tem forte padrão de segunda a sexta e fins de semana muito baixos. Por que um CUSUM sobre energia diária subtraindo a mesma média global é arriscado? Proponha baseline mínimo.

E10.3. Compare detecção online às 18h com uma análise offline feita no próximo mês. Qual conjunto de dados cada uma pode utilizar?

E10.4. O valor de h foi escolhido porque "gerou 3% de alarmes no próprio conjunto usado para ajustar o baseline". O que há de insuficiente nessa avaliação?

Checklist

- ☐ Explico a diferença entre outlier pontual e regime persistente.
- ☐ Derivo e calculo CUSUM bicaudal por recorrência.
- ☐ Diferencio tempo de alerta e tempo de mudança.
- ☐ Sei explicar por que sazonalidade e gaps interferem na detecção.
- ☐ Tenho respostas para E10.1–E10.4.

Dia 11 — Change Point Detection II: comparar janelas e segmentar regimes

Referências: TR §2 (*Problem formulation*), §3 (*Evaluation*), §4 (*Models and cost functions*), §5 (*Search methods*) e §6 (*Estimating the number of changes*); HY §§3.3 e 6.6 para resíduos/sazonalidade. **Prazo de domínio:** explicar diferença entre comparar distribuições e minimizar custos de segmentos; obter manualmente uma mudança de média; reconhecer a limitação de olhar para o futuro.

1. Intuição simples

Um gráfico com três meses de consumo pode conter três histórias: meses normais, reforma da loja, reabertura. Você pode perguntar **"há diferença entre os dois últimos quinzenários?"** ou **"como dividir a série inteira em trechos internamente estáveis?"**. São perguntas relacionadas, mas algoritmos diferentes.

- **Comparação de janelas:** duas fotografias estatísticas, antes e depois.
- **Segmentação global:** procura as melhores divisões de um filme inteiro.

A primeira pode ser simples e rápida; a segunda usa contexto temporal mais amplo para propor datas de mudança.

2. Modelo de segmentos (offline)

Para $y_1, \dots, y_T$, queremos instantes $\tau_1 < \cdots < \tau_m$ que dividam a série em $m+1$ segmentos. Um objetivo recorrente na literatura de CPD é:

$$\min_{m,\, \tau_1, \dots, \tau_m} \left[\sum_{j=0}^{m} c\left(y_{(\tau_j+1):\tau_{j+1}}\right) + \beta m \right],$$

com $\tau_0 = 0$, $\tau_{m+1} = T$.

- $c(\cdot)$: custo de explicar um segmento por um regime aproximadamente homogêneo.
- m: quantidade de mudanças.
- β: penalidade por introduzir mais uma mudança.

Interpretação: queremos segmentos que expliquem bem os dados, mas não uma divisão em cada ponto. Se permitirmos uma quebra por amostra e custo quadrático, obteremos ajuste perfeito inútil. Penalização e tamanho mínimo de segmento controlam isso.

3. Custo de mudança de média

Para um segmento I de índices consecutivos:

$$c_{L2}(y_I) = \sum_{t \in I} (y_t - \overline{y}_I)^2.$$

Quanto menor a variação interna ao redor da média de cada segmento, menor o custo. A função L_2 é sensível a outliers. Alternativa robusta com mediana e desvios absolutos:

$$c_{L1}(y_I) = \sum_{t \in I} |y_t - \text{mediana}(y_I)|.$$

A escolha de custo expressa a hipótese: uma mudança de média não é automaticamente mudança de variância, forma diária ou correlação.

3.1. Conta manual de segmentação

Considere $y = (10, 10, 10, 4, 4, 4)$ kWh/dia.

Sem mudança: média global $\bar{y} = 7$; custo $c_{L2} = 3(10-7)^2 + 3(4-7)^2 = 54$ (kWh/dia)^2.

Com uma mudança depois do terceiro dia: cada segmento constante, custo total 0; custo penalizado $0 + \beta$.

- Para $\beta = 10$, a segmentação com uma quebra custa 10, menor que 54: **prefere uma mudança**.
- Para $\beta = 60$, custa 60, maior que 54: **prefere nenhuma mudança**.

Isso demonstra que **data de mudança e número de mudanças dependem do critério e da penalidade**; não são verdades reveladas pela biblioteca. `beta` precisa estar na escala do custo.

4. Algoritmos de busca: o que são, sem decorar implementações

Algoritmo/família	Ideia operacional	Observação
Varredura de corte único	Calcula custo de dividir em cada ponto elegível	Boa linha de base para 1 ruptura
Programação dinâmica	Reutiliza custos de subproblemas para buscar ótimo sob objetivo definido	Pode ser custosa
PELT	Programação dinâmica com poda de candidatos incapazes de ser ótimos sob condições	Custo frequentemente reduzido; não há garantia universal de tempo linear
Binary Segmentation	Divide na melhor quebra, depois repete recursivamente	Aproximada; barata, sujeita a erros locais
Bottom-Up	Começa com muitos segmentos, funde vizinhos	Aproximada e dependente de inicialização

PELT não é uma fórmula de detecção de fraude. É um algoritmo de busca para uma função de custo e penalização. Ele não determina sozinho o que constitui alteração operacional importante.

5. Comparar distribuições de duas janelas

Duas janelas podem ter a mesma média e distribuição diferente. Ex.: $A = (5, 5, 5, 5)$ e $B = (0, 0, 10, 10)$; médias iguais, variância muito diferente. Um detector apenas de média não apontaria alteração; uma comparação da distribuição poderia.

5.1. Teste/diferença de Kolmogorov–Smirnov

Dadas funções de distribuição acumulada empíricas $\widehat{F}_A$ e $\widehat{F}_B$:

$$D_{KS} = \sup_x |\widehat{F}_A(x) - \widehat{F}_B(x)|.$$

A estatística é uma distância vertical máxima entre duas CDFs, entre 0 e 1. Ela não indica direção física do efeito. Um p-valor do teste KS tradicional requer hipóteses, especialmente sobre independência e amostragem; duas janelas temporais com forte autocorrelação **não satisfazem automaticamente essas hipóteses**.

Exemplo: $A = (1, 2, 3)$ e $B = (4, 5, 6)$. Antes de 4, a CDF de A já chegou a 1, mas B ainda está em 0, portanto $D_{KS} = 1$. Isso diz que as amostras estão perfeitamente separadas no domínio observado, **não prova** causa da separação.

5.2. Distância de Wasserstein de ordem 1

Em uma dimensão, com distribuição de probabilidade F e G e CDFs finitas:

$$W_1(F,G) = \int_{-\infty}^{\infty} |F(x) - G(x)|\, dx.$$

Para amostras de mesmo tamanho, valores ordenados $a_{(i)}$ e $b_{(i)}$ e pesos iguais:

$$\widehat{W}_1 = \frac{1}{n}\sum_{i=1}^{n} |a_{(i)} - b_{(i)}|.$$

Exemplo $A = (1,2,3)$ e $B = (4,5,6)$: $W_1 = (3+3+3)/3 = 3$ unidades da variável (kWh/dia, se esse for o dado). Diferentemente do KS, Wasserstein reflete **escala de deslocamento**. Se misturarmos kWh e V num vetor, precisamos de definição multivariada e normalização adequada; não use essa fórmula 1D diretamente.

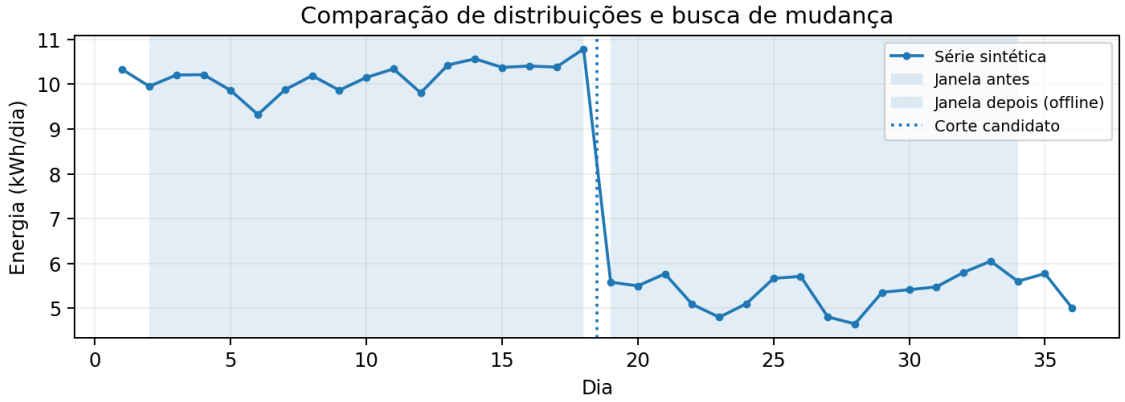


Figura 4: Separação de janelas e mudança de nível

6. O maior risco metodológico: janelas antes/depois em uma previsão online

A comparação

$$A_t = (y_{t-15}, \dots, y_{t-1}), \quad B_t = (y_t, \dots, y_{t+14})$$

é uma **análise retrospectiva centrada em** t. Para emitir alerta em t, os dados de $t+14$ não existem. Se essa informação for usada no treino/validação de um detector que afirma funcionar ao vivo, há *look-ahead bias*.

Para operação online, compare **referência congelada no passado** com uma janela que termina no presente:

$$A_t = (y_{t-L-H+1}, \dots, y_{t-H}), \quad B_t = (y_{t-H+1}, \dots, y_t).$$

Onde L é comprimento do baseline e H o comprimento da janela atual, ambos completos até o tempo t. É possível usar janelas de comprimento igual ou diferente; explicitamos o desenho experimental e evitamos sobreposição quando ela prejudicar o cálculo.

Exemplo: em 30/09, comparar 01–15/09 com 16–30/09 é possível; comparar 25/09 com 26/09–10/10 e afirmar que alertou em 25/09 é impossível.

7. Múltiplos testes: por que um p-valor pequeno pode enganar

Suponha que cada UC seja submetida diariamente a muitos testes de janela. Mesmo com taxa nominal de falso positivo de 5%, o número acumulado de alertas espúrios pode ser grande. Além disso, janelas sobrepostas não são independentes.

Por isso, o parâmetro de decisão deve ser **calibrado em cenário operacional**: distribuição do máximo ao longo do tempo, taxa de alertas por UC-mês, estabilidade em segmentos presumidamente normais, revisão dos principais casos e custo de inspeção. Se houver ground truth, medir precisão, recall e atraso de detecção; sem ground truth, não inventar taxas de acerto.

A estatística do KS **não é** automaticamente um `cpd_confidence`; uma distância de Wasserstein **não é** probabilidade de fraude. Um score $0 \dots 1$ somente após transformação tem interpretação condicionada à transformação e calibração.

8. Como caracterizar uma ruptura candidata

Uma vez estimada a data t^*, calcule features auditáveis em dois segmentos adequadamente completos:

$$\Delta_{\text{nível}} = \tilde{y}_{post} - \tilde{y}_{pre}, \quad R_{\text{nível}} = \frac{\tilde{y}_{post}}{\tilde{y}_{pre}} \text{ (se denom. elegível)},$$

$$\Delta_{\text{MAD}} = \text{MAD}_{post} - \text{MAD}_{pre}, \quad D_{\text{persist}} = \#\{\text{dias do novo regime aceitos por critério explícito}\}.$$

A magnitude pode ser dada em kWh/dia ou em mudança percentual com denominador legítimo. Persistência exige observar dias após a ruptura; em análise online, sua estimativa tem **latência intrínseca**.

Exemplo de relato prudente: “a mediana diária da energia registrada caiu de 10 para 4 kWh/dia; mudança estimada entre os dias 18 e 19, com 8 dias posteriores observados e cobertura diária suficiente”. A frase não atribui fraude.

9. `ruptures`: aplicação ilustrativa

```python
import numpy as np
# Instalação complementar: uv add ruptures
import ruptures as rpt

y = np.array([10, 10, 10, 4, 4, 4], dtype=float)
model = rpt.Pelt(model="l2", min_size=2).fit(y)
ends = model.predict(pen=10)
print(ends)  # esperado: [3, 6] para este exemplo simples
```

Uma lista `[3,6]` são **fins de segmentos** em convenção da biblioteca; o último índice 6 é o fim da série, **não** uma mudança adicional. Essa distinção é importante na documentação do dataset.

Sem `ruptures`: implementar um corte único via loop sobre $t = 2, \dots, T-2$ e comparar as somas de quadrados já ensina a ideia. O laboratório completo acompanha esta apostila.

10. Validação de CPD sem circularidade

Em séries **sintéticas** com mudanças implantadas e verdade conhecida, verifique:

- **precision/recall de eventos:** quantas mudanças estimadas correspondem a mudanças conhecidas, com tolerância temporal declarada;
- **atraso de detecção:** $\hat{t}_{alerta} - t^*$ para detector online;
- **erro na localização da ruptura:** $|\hat{t}^* - t^*|$ offline;
- **falso alarme:** eventos sinalizados em regimes estáveis;
- **robustez:** mudança de amplitude, duração, ruído, sazonalidade e dados faltantes.

Em dados reais AMI, uma mudança conhecida no cadastro ou na instalação pode ser **proxy de evento**, mas não deve ser automaticamente rotulada como fraude. Mudanças de consumo por férias e migração de tarifa também precisam aparecer como casos negativos difíceis.

11. Exercícios

E11.1. Para $y = (8, 8, 8, 2, 2, 2)$, obtenha o custo quadrático sem quebras, com corte após o terceiro dia e escolha para $\beta = 5$ e $\beta = 100$.

E11.2. $A = (0, 1, 2)$ e $B = (2, 3, 4)$. Calcule a distância de Wasserstein 1D por emparelhamento ordenado.

E11.3. Alguém usa 15 dias posteriores à data t para uma decisão marcada como "online em t". Explique problema e correção.

E11.4. Uma UC apresenta queda real em 20/09, mas o detector alerta apenas em 24/09. Diferencie t^*, t_{alerta} e persistência.

E11.5. Uma UC exibe desvio significativo nas janelas de consumo e lacuna simultânea de três dias em dados de energia. Qual sequência de verificação é exigida antes de dizer que houve mudança elétrica?

Checklist

- ☐ Derivo função objetivo de segmentação e explico a penalidade.
- ☐ Sei interpretar `breakpoints` e fim da série.
- ☐ Diferencio KS (diferença máxima de CDFs) e Wasserstein (escala de deslocamento).
- ☐ Não confundo p-valor, score e probabilidade causal.
- ☐ Consigo desenhar janelas online e offline sem usar futuro.

Dia 12 — PCA e SVD: comprimir informação sem inventar significado físico

Referências: ZC ch. 6 (*Dimensionality Reduction: Squashing the Data Pancake with PCA*) e apêndice A; GE ch. 7 (*Dimensionality Reduction*, edição com PyTorch). **Prazo de domínio:** interpretar vetores/eixos, calcular uma projeção simples, variância explicada, limitações do PCA e aplicação em perfis AMI.

1. Em palavras leigas

Imagine fotografar um lápis de vários ângulos. Alguns ângulos permitem ver comprimento inteiro; outros mostram quase só um ponto. O PCA procura ângulos de visão que preservam a maior quantidade possível da **variação existente nos dados**.

Em vez de desenhar uma UC em um espaço com 24 valores horários, podemos projetar todas as UCs em dois eixos construídos estatisticamente. Isso facilita visualizar grupos e redundância, mas os eixos PCA **não correspondem automaticamente** a "consumo noturno" ou "fraude".

2. O que realmente entra no PCA

Considere n UCs e p features. Matriz $X \in \mathbb{R}^{n \times p}$:

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{np} \end{bmatrix}.$$

Cada linha deve representar a **mesma entidade analítica** (ex.: UC × `cutoff_date`), com mesma definição de janelas e features. Ex.: 24 proporções horárias + `load_factor` + razões diurno/noturno.

Antes de PCA, decida o objetivo:

- **Forma do consumo:** normalize cada curva pela energia total elegível; mantenha magnitude em variável à parte.
- **Amplitude física:** energia diária pode importar, mas escalonamento precisa ser deliberado.
- **Análise do histórico:** médias de fases/magnitudes distintas podem merecer modelos separados.

Nunca inclua `id__uc_id` ou o timestamp codificado como inteiro em PCA: criarão distâncias sem interpretação física.

3. Centralização e covariância

Defina média da coluna j: $\overline{x}_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}$ e matriz centralizada:

$$X_c = X - \mathbf{1}\overline{x}^T.$$

A covariância amostral é:

$$\widehat{\Sigma} = \frac{1}{n-1} X_c^T X_c.$$

A direção do primeiro componente principal é o vetor unitário v_1 que maximiza variância projetada:

$$\max_{\|v\|=1} v^T \widehat{\Sigma} v.$$

Isso leva ao problema de autovalores/autovetores:

$$\widehat{\Sigma} v_i = \lambda_i v_i.$$

- v_i: direção de projeção (*loading* do componente, coeficientes sobre as features).
- λ_i: variância da projeção nessa direção.
- Componentes diferentes são ortogonais no PCA usual.
- O sinal de v_i é arbitrário: trocar v_i por $-v_i$ não muda a solução essencial.

4. Exemplo manual de apenas duas features

Considere três observações de duas grandezas numéricas relacionadas:

$$X = \begin{bmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{bmatrix}, \qquad \overline{x} = (2, 4).$$

Centralizando:

$$X_c = \begin{bmatrix} -1 & -2 \\ 0 & 0 \\ 1 & 2 \end{bmatrix}.$$

Covariância amostral:

$$\widehat{\Sigma} = \frac{1}{2} \begin{bmatrix} 2 & 4 \\ 4 & 8 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

Essa matriz possui autovalores $\lambda_1 = 5$, $\lambda_2 = 0$. Direção do primeiro componente:

$$v_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Projeções (*scores* do PCA):

$$Z_1 = X_c v_1 = (-\sqrt{5},\ 0,\ \sqrt{5})^T.$$

A proporção de variância explicada é $5/(5+0) = 100\%$. Um único componente preserva toda a **variância dos pontos observados** porque a segunda feature é exatamente o dobro da primeira. Isso não quer dizer que aprendemos algo causal nem que o fenômeno físico tem uma única dimensão em toda a população.

5. Ligação com SVD

A decomposição em valores singulares da matriz centralizada é:

$$X_c = U \Sigma V^T.$$

Para evitar confusão com matriz de covariância, chame a matriz diagonal de valores singulares de Σ_{SVD}:

$$X_c = U \Sigma_{SVD} V^T.$$

As colunas de V dão as direções PCA; autovalores da covariância se relacionam aos valores singulares s_i:

$$\lambda_i = \frac{s_i^2}{n-1}.$$

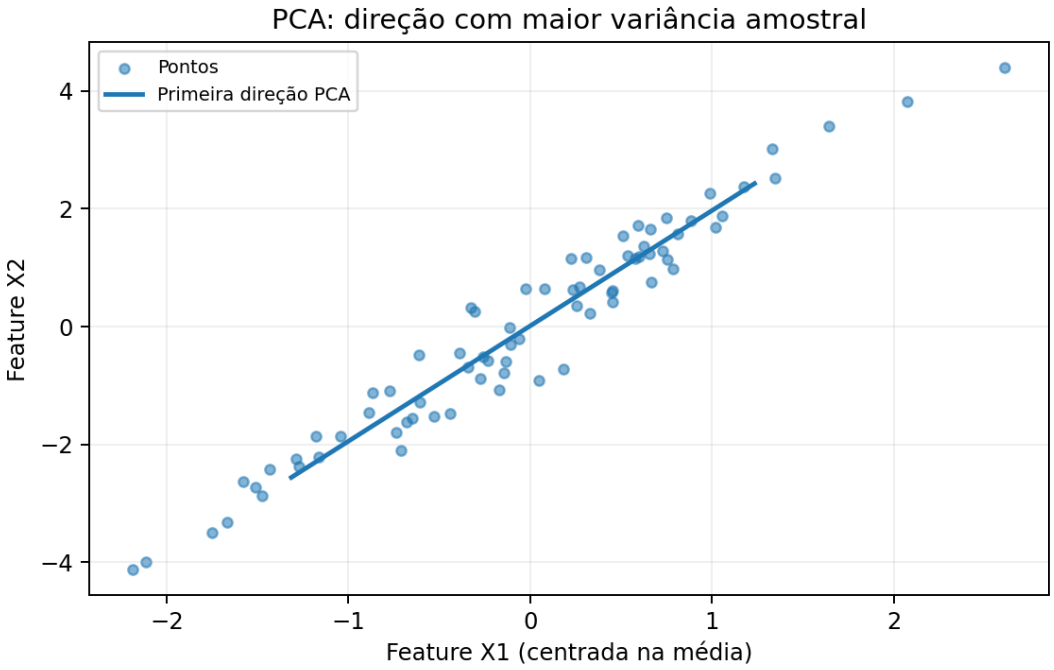


Figura 5: Direção principal em uma nuvem bidimensional

Os k primeiros componentes dão projeção:

$$Z = X_c V_k, \qquad X_{rec} = Z V_k^T + \mathbf{1}\bar{x}^T.$$

Essa reconstrução é **aproximada** quando $k < p$ e a variância descartada não é zero.

6. Variância explicada: como escolher k

$$\text{EVR}_k = \frac{\sum_{i=1}^{k} \lambda_i}{\sum_{i=1}^{p} \lambda_i}.$$

Se $\text{EVR}_3 = 0{,}90$, os três primeiros componentes explicam 90% da variabilidade amostral das features **na escala usada no ajuste**. Isso não significa 90% de precisão para detectar fraudes; nem significa que os 10% descartados sejam puro ruído. Uma anomalia rara pode estar justamente em direção de variância pequena.

Regra prática: faça curvas de variância acumulada e experimente k em validação. Não imponha 95% como critério universal.

7. O dilema de escala

Uma feature tem tensão em torno de 220 V, outra tem percentual de desequilíbrio de 1–5%. Se usar valores brutos, a dimensão em V pode dominar a variância. Com `StandardScaler`, você muda a pergunta: "quais direções mais variam em unidades de desvio de cada feature?". Com `RobustScaler`, a escala é outra. As três versões podem ser legítimas, mas respondem perguntas diferentes.

Armadilha física: não normalizar automaticamente tensão por uma base arbitrária. Se a variável é tensão de atendimento de 127 V ou 220 V, use base física nominal correta quando fizer sentido analisar em p.u.; para PCA, ainda pode ser necessário aplicar padronização estatística adicional, separadamente, aprendida no treino.

Armadilha de missing: `PCA` clássico do scikit-learn não recebe `NaN` como uma feature física válida. Primeiro filtrar janelas adequadas, depois imputar faltantes residuais somente com parâmetros de treino, documentando o procedimento. A máscara de ausência pertence a `S_comm`/metadados, não precisa entrar em `X_elec`.

8. PCA para explicar versus PCA para detectar

Duas aplicações diferentes:

A. Visualização ou compressão. PCA transforma 24 horários + outros índices em poucas coordenadas. Podemos visualizar clusters no plano PC1–PC2; **distância 2D não equivale necessariamente à distância original**.

B. Reconstrução. Se uma UC tem perfil que não pode ser bem reconstruído por subespaço aprendido em referências confiáveis:

$$R_i = \|x_i - \hat{x}_i\|_2^2,$$

isso pode servir de **score de novidade em relação ao subespaço**. Não equivale a probabilidade de fraude. Residual alto também pode vir de mudança de tarifa, feriados, classe errada, outlier de sensor ou perfil solar legítimo.

Se treinarmos PCA com toda a população, incluindo fraudes sistemáticas e GD não cadastrada, o subespaço pode aprender parte desse comportamento. Qual conjunto de referência usar é tão importante quanto o algoritmo.

9. Caso realista: 24 horas de consumo

Crie por UC um vetor $p = (p_0, \dots, p_{23})$, onde $\sum p_h = 1$. Cada p_h representa fração de energia por hora. Treine PCA com UCs adequadamente completas, mesmo tipo de medição e contexto comparável. Registre em separado:

- mediana de energia total diária;
- classe/categoria cadastral válida;
- número de dias completos;
- existência conhecida de GD cadastrada;
- cluster gerado posteriormente.

O objetivo da PCA é detectar formas dominantes (manhã/noite, diurno/contínuo etc.). Interprete *loadings* inspecionando os 24 coeficientes da componente; o título “padrão noturno” só surge **depois da inspeção**.

10. Código Python

```python
import numpy as np
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

X_train = np.array([
    [1.0, 2.0, 1.2],
    [2.0, 3.0, 1.8],
    [3.0, 3.5, 2.7],
    [4.0, 5.0, 3.6],
    [5.0, 6.0, 4.4],
], dtype=float)

scaler = StandardScaler().fit(X_train)
Xs = scaler.transform(X_train)
pca = PCA(n_components=2).fit(Xs)
Z = pca.transform(Xs)
print("Explained variance ratio:", pca.explained_variance_ratio_)
print("Loadings (linhas=componentes):", pca.components_)
print("Scores:", Z)
```

Em produção, `scaler` e `PCA` são ajustados **apenas no treino**. Registre `feature_order`, versão do transformador, janela, população, período e `random_state` quando aplicável.

11. Exercícios

E12.1. Para matriz do exemplo, calcule projeção de $(3, 6)$ no primeiro componente e a variância explicada pelo segundo.

E12.2. Duas UCs têm mesmo perfil relativo, mas 10 e 100 kWh/dia. O PCA sobre perfis normalizados as distinguirá apenas pela magnitude? Explique.

E12.3. PCA 2D explica 88% da variância. O analista diz que “detectamos 88% das irregularidades”. Identifique erro lógico.

E12.4. Qual a diferença entre ajustar PCA com todas as UCs de 2026 e usar o score para uma previsão histórica de janeiro/2026?

E12.5. Uma componente PCA dá peso positivo grande nas horas 18–22 e negativo nas 9–14. Que interpretação comportamental **provisória** isso sugere? Que verificação ainda falta?

Checklist

- ☐ Sei centralizar uma matriz e calcular covariância.
- ☐ Sei relacionar autovalores e variância explicada.
- ☐ Sei o significado de `components_` e `transform`.
- ☐ Reconheço a sensibilidade a escala e os limites de interpretação.
- ☐ Respondo E12.1–E12.5.

Dia 13 — K-Means: descobrir arquétipos de consumo

Referências: ZC ch. 7 (*Nonlinear Featurization via K-Means Model Stacking*) e GE ch. 8 (*Unsupervised Learning Techniques*, edição PyTorch), seções de K-Means e limites dos agrupamentos. **Prazo de domínio:** calcular uma iteração, explicar centroide, escolher características e justificar como avaliar a estabilidade de arquétipos sem interpretar cluster como irregularidade.

1. Em palavras leigas

Você entra num estacionamento e agrupa veículos por semelhança: motos, carros pequenos e caminhões. O K-Means faz algo parecido **com pontos num espaço de números**. Ele cria K representantes (*centroides*) e coloca cada ponto no grupo do representante mais próximo.

Se a entrada for o **perfil horário normalizado**, pode agrupar UCs com consumo maior à noite, durante expediente ou praticamente constante. Se a entrada for **energia mensal bruta**, pode agrupar simplesmente por tamanho do consumidor. Ambos são agrupamentos, mas respondem questões diferentes.

2. Três palavras fundamentais

- **Ponto:** linha de `X` com características de uma UC/janela.
- **Distância:** função que define o que significa ser semelhante. O K-Means padrão usa distância euclidiana ao quadrado.
- **Centroide:** média vetorial dos pontos de um grupo.

O algoritmo não conhece, por si só, residencial/comercial/GD, nem quem comete fraude. Os nomes dados aos clusters são **interpretação posterior**, idealmente sustentada por gráficos e cadastro.

3. Função objetivo

Dados $x_1, \dots, x_n \in \mathbb{R}^p$, centros $\mu_1, \dots, \mu_K$ e atribuição $c_i \in \{1, \dots, K\}$:

$$\min_{\mu_1,\dots,\mu_K;\, c_1,\dots,c_n} J = \sum_{i=1}^{n} \|x_i - \mu_{c_i}\|_2^2.$$

Isso é **soma das distâncias quadráticas intra-cluster**. O scikit-learn reporta em `inertia_`. Menor inércia por si só não prova clusters melhores: quando K aumenta, a inércia tende a diminuir, podendo chegar a zero com um centro por ponto.

4. Passos de Lloyd, sem mistério

1. Escolha K centroides iniciais.
2. **Atribuição:** cada ponto vai ao centroide mais próximo.
3. **Atualização:** cada centroide vira média de seus pontos.
4. Repita até estabilizar ou atingir limites de iteração.

K-Means converge para uma solução local do objetivo; inicializações diferentes podem levar a soluções diferentes. `k-means++` e múltiplas inicializações reduzem esse risco, mas não garantem recuperar a "verdade" dos dados.

5. Conta manual de uma iteração

Pontos de uma feature: $x = (1, 2, 8, 9)$ e $K = 2$.

Centros iniciais $\mu_1 = 2$, $\mu_2 = 8$.

Ponto	Distância ao centro 2	Distância ao centro 8	Grupo
1	1	7	1
2	0	6	1
8	6	0	2
9	7	1	2

Atualize:

$$\mu_1 = \frac{1+2}{2} = 1{,}5, \qquad \mu_2 = \frac{8+9}{2} = 8{,}5.$$

Inércia após atualização:

$$J = (1-1{,}5)^2 + (2-1{,}5)^2 + (8-8{,}5)^2 + (9-8{,}5)^2 = 1.$$

O exemplo é propositalmente fácil. Com perfis de 24 dimensões e subgrupos sobrepostos, a escolha de K e o significado da distância se tornam os desafios centrais.

6. Quais features usar no `BehavioralClusterer`?

Uma estrutura inicial defensável:

$$X_{shape} = [p_0, p_1, \dots, p_{23}, \text{load_factor}, \text{peak_sin}, \text{peak_cos}].$$

- p_h é fração do consumo total diário associada à hora h (média de vários dias elegíveis).
- `load_factor` pode ter correlação com o perfil; testar inclusão/ablação.
- `peak_sin/cos` representam hora de pico cíclica.
- Energia total/mediana pode ser mantida em metadado descritivo e testada separadamente.

Cuidado com redundância: as proporções somam 1; logo as 24 componentes não são independentes em sentido linear. PCA pode reduzir dimensão; também pode distorcer distâncias úteis para grupos minoritários. Compare com K-Means direto nos perfis normalizados.

Cuidado com composição: perfis médios de seg-sex e fim de semana podem diferir enormemente. Um único perfil agregado pode esconder turnos industriais e comércio. Uma evolução é vetor com dois perfis de 24 h, mantendo documentação do aumento de dimensão.

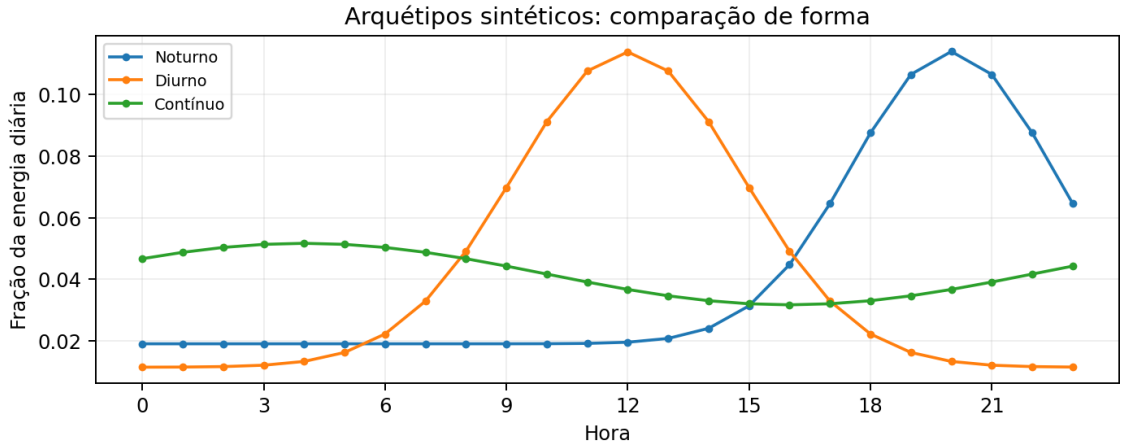


Figura 6: Arquétipos sintéticos de consumo normalizado

7. Número de clusters: decidir e justificar

Método	Ideia	Limitação
Elbow/inércia	Procurar redução marginal de inércia ao aumentar K	Cotovelo pode não existir
Silhouette	Relação entre coesão do próprio cluster e separação do mais próximo	Pode favorecer formas compactas; não mede interpretação física
Davies–Bouldin	Similaridade entre dispersão interna e separação dos grupos	Sensível à geometria/métrica
Estabilidade	Verificar se grupos persistem em seeds, períodos e subamostras	Pode penalizar mudanças reais de regime
Inspeção física	Plotar perfis médios, cobertura, classes, horários e GD	Requer julgamento de domínio

A silhueta de cada ponto (quando definida) é:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

onde $a(i)$ é distância média aos demais pontos do próprio grupo; $b(i)$ é a menor distância média a outro grupo. Varia aproximadamente de -1 a 1. **Silhouette alta não significa baixa fraude**, apenas boa separação conforme métrica e agrupamento avaliados.

8. Clusters e mudança de regime

Suponha que uma UC tinha perfil noturno e passou a consumir majoritariamente de dia. O ID do cluster pode mudar por comportamento legítimo, mudança de morador ou GD. Esse *cluster transition* é **feature contextual** interessante para CPD, mas:

- rótulos de clusters são arbitrários: `cluster_id=0` pode virar `cluster_id=3` após novo treino;
- se reajustar clusterer com dados futuros, não é comparação temporal justa;
- a atribuição a grupos deve usar modelo e transformações congelados para avaliar mudança em datas históricas;
- uma mudança de grupo pode refletir justamente a instabilidade dos clusters, não da UC.

Para monitoramento longitudinal, versionar centroides e alinhar clusters entre versões antes de interpretar transições.

9. K-Means não detecta fraude

Por si só, o K-Means responde “qual representante de consumo está mais próximo?”. UCs com GD regular podem formar um grupo raro e legítimo. Irregularidades persistentes e frequentes podem formar um grupo estável e parecerem perfeitamente “normais” dentro dele.

Dois usos metodologicamente defensáveis:

A. Estratificação: comparar uma UC com pares do mesmo arquétipo ao calcular anomalia elétrica.

B. Feature adicional: distância até o centroide (ou distâncias aos K centroides), evitando usá-la como score de fraude sem validação.

Um cluster com poucos elementos não deve ser automaticamente marcado “fraudulento”. Desconhecido, raro e irregular são palavras distintas.

10. Código pronto de exemplo

```
import numpy as np
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

profiles = np.array([
```

```
    [0.1, 0.2, 0.1, 0.6],
    [0.1, 0.2, 0.1, 0.6],
    [0.15, 0.2, 0.15, 0.5],
    [0.1, 0.4, 0.4, 0.1],
    [0.1, 0.5, 0.3, 0.1],
    [0.2, 0.4, 0.3, 0.1],
], dtype=float)

km = KMeans(n_clusters=2, n_init=10, random_state=42)
labels = km.fit_predict(profiles)
print("centroides:", km.cluster_centers_)
print("inércia:", km.inertia_)
print("silhouette:", silhouette_score(profiles, labels))
```

Esses perfis já somam 1, mas não representam necessariamente resolução de 15 minutos. São quatro faixas horárias sintéticas, úteis para fixar a lógica.

No TCC, verifique tamanho mínimo por grupo, proporção de UCs de cada classe e estabilidade no tempo. Nunca aplique `fit_predict` a todas as datas antes de realizar avaliação histórica cujo objetivo exige desconhecer o futuro.

11. Erros comuns

1. K-Means sobre energia em kWh e tensão em V sem ponderação deliberada.
2. Interpretar inércia quase zero como acurácia de fraude quase perfeita.
3. Assumir clusters esféricos de tamanhos semelhantes quando há grupos irregulares e densidades variadas.
4. Usar perfil médio de 30 dias atravessando troca de medidor sem considerar sua relevância.
5. Tratar ID de cluster como atributo ordinal em outro estimador.
6. Batizar clusters automaticamente sem examinar perfis e cadastros.

12. Exercícios

E13.1. Para $x = (0, 2, 10, 12)$, $K = 2$, centros iniciais 0 e 10, calcule atualização e inércia resultante.

E13.2. UCs A e B têm perfis proporcionais 10×. Mostre matematicamente por que normalização pela soma produz a mesma curva.

E13.3. Uma solução K=8 tem menor inércia do que K=4. Isso basta para preferir K=8? Que outras três verificações você faria?

E13.4. Um cluster com 1% das UCs mostra exportação de energia concentrada ao meio-dia. Dê três hipóteses legítimas e uma forma de buscar evidência cadastral.

E13.5. Após retraining, cluster 0 de ontem vira cluster 2 de hoje. Como manter rastreabilidade?

Checklist

- ☐ Calculo uma iteração de Lloyd e inércia.
- ☐ Explico o papel da métrica e da normalização.
- ☐ Sei por que o melhor K não é dado pela menor inércia.
- ☐ Sei distinguir arquétipo comportamental e suspeita de irregularidade.
- ☐ Respondo E13.1–E13.5.

Dia 14 — DBSCAN e HDBSCAN: grupos densos, vizinhanças e pontos sem grupo

Referências: GE ch. 8 (DBSCAN e agrupamento não supervisionado). **Complemento externo à bibliografia enviada:** literatura do HDBSCAN de Campello, Moulavi e Sander, e documentação oficial da biblioteca escolhida; os PDFs de estudo cobrem principalmente os **pré-requisitos** de agrupamento por densidade, não uma apresentação integral de HDBSCAN. **Prazo de domínio:** definir vizinhança, core/border/noise, comparar K-Means e densidade e justificar o que significa uma UC sem cluster.

1. Em palavras leigas

Imagine pessoas em uma praça. Há uma multidão perto do palco, outra pequena aglomeração próxima a um quiosque e duas pessoas caminhando sozinhas. O K-Means obrigaria cada pessoa a pertencer a algum grupo escolhido previamente. O DBSCAN tenta encontrar **regiões em que há concentração suficiente de pessoas**, e pode deixar pontos isolados sem grupo.

No nosso TCC, UCs com rotinas parecidas podem formar nuvens densas de perfis. Uma UC fora dessas nuvens merece análise de contexto — **mas não vira fraude só por estar isolada**.

2. O que significa "densidade" em features?

Cada UC é um ponto no espaço das features. Densidade é proximidade de vários pontos conforme uma métrica. Em perfis horários normalizados, duas UCs estão perto se suas curvas forem parecidas nos horários, não se estiverem geograficamente perto. **Proximidade comportamental não equivale a proximidade elétrica**.

A escala e a métrica mudam o espaço. Um único atributo com valores enormes pode dominar distâncias. O método usa o que você forneceu, não sabe corrigir conceito físico mal representado.

3. DBSCAN: quatro conceitos

Parâmetros:

- ε (*eps*): raio da vizinhança.
- `min_samples`: quantidade mínima de pontos na vizinhança para que um ponto seja **core**; na implementação usual do scikit-learn o próprio ponto conta.

Vizinhança de x:

$$N_\varepsilon(x) = \{y \in X : d(x, y) \leq \varepsilon\}.$$

Classificações:

- **Core:** tem pelo menos `min_samples` pontos na vizinhança.
- **Border:** não é core, mas está na vizinhança de algum core.
- **Noise:** não foi associado a região densa.

Um cluster cresce por pontos que são alcançáveis a partir de cores conectados, incorporando bordas. Pontos de borda podem ser ambíguos quando próximos a mais de uma região; detalhes de implementação determinam a atribuição.

4. Exemplo manual unidimensional

Considere valores $x = (0,0; 0,1; 0,2; 3,0; 3,1; 7,0)$, $\varepsilon = 0{,}25$ e `min_samples=2` (contando o próprio ponto).

- $(0,0; 0,1; 0,2)$ formam uma região densa; cada ponto tem pelo menos 2 vizinhos incluindo a si.
- $(3,0; 3,1)$ formam segunda região densa.
- $7{,}0$ fica sem vizinhos suficientes: recebe rótulo de **ruído** (`-1` em scikit-learn).

Se `min_samples=3`, a segunda dupla deixa de satisfazer o requisito; não há evidência suficiente para chamá-la de cluster denso **segundo essa parametrização**. Nenhum desses rótulos prova irregularidade elétrica.

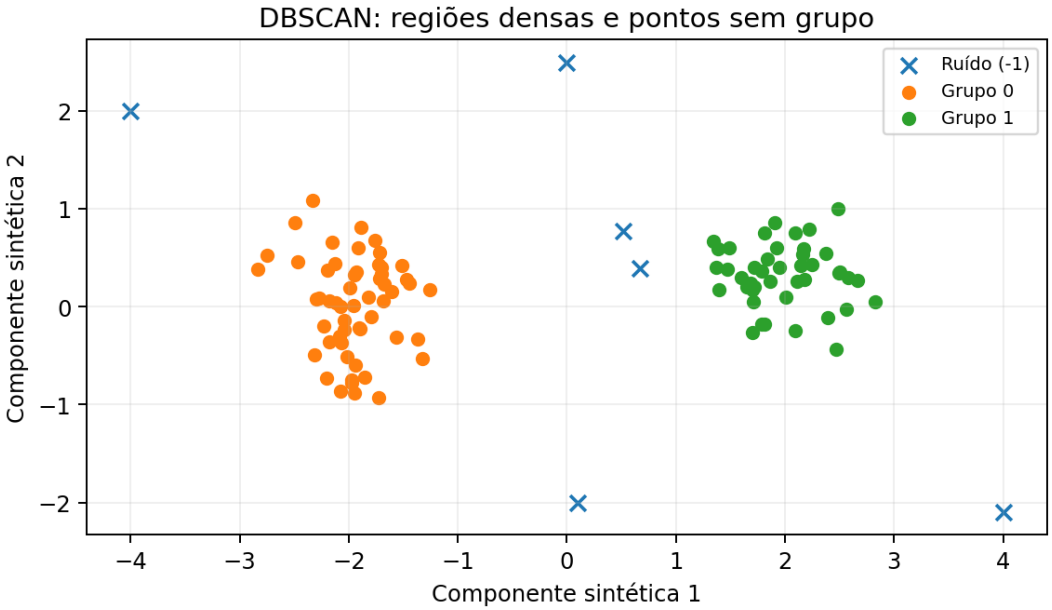


Figura 7: Grupos densos e pontos isolados em dados sintéticos

5. Escolha de `eps` e `min_samples`

Um `eps` pequeno divide grupos e produz muito ruído; grande demais funde grupos. `min_samples` define rigor mínimo de densidade. Portanto:

1. Compare distâncias entre vizinhos e inspecione histogramas/k-distance plots.
2. Conheça quantidade de amostras e dimensionalidade.
3. Teste estabilidade ao mudar hiperparâmetros.
4. Visualize perfis médios e dispersão dos grupos resultantes.
5. Verifique composição por classe, família de medidor, GD e cobertura.

Não escolha parâmetros apenas para obter “5% de UCs suspeitas” se não há justificativa para essa taxa.

6. Onde DBSCAN falha

Se a população possui um grupo muito denso (residências regulares) e outro esparso (indústrias heterogêneas), **um único `eps`** pode funcionar para um e falhar para o outro. Além disso, quando dimensão cresce, distâncias tendem a concentrar-se, dificultando distinção de vizinhanças.

Por isso HDBSCAN costuma ser considerado para grupos com **densidades variadas**, mas tem seus próprios parâmetros e hipóteses. Ele não resolve magicamente escolha de features nem necessidade de validação.

7. HDBSCAN: a ideia sem exigir implementação da árvore inteira

HDBSCAN pode ser visto como extensão hierárquica do DBSCAN que examina estrutura de densidade em múltiplas escalas e extrai grupos relativamente estáveis.

Etapas conceituais:

1. Cada ponto recebe uma **distância de núcleo** relacionada à vizinhança de densidade necessária.
2. Constrói-se uma distância que considera tanto separação entre pontos quanto a dificuldade de estar em região densa (*mutual reachability*).

3. Uma hierarquia de conexões se forma ao variar a escala.
4. Condensa-se a hierarquia considerando tamanho mínimo dos grupos.
5. Selecionam-se grupos com persistência/estabilidade relevantes ao longo das escalas; alguns pontos permanecem sem grupo.

Uma definição usual da distância de alcançabilidade mútua é:

$$d_{mreach,k}(a,b) = \max\{\text{core}_k(a), \text{core}_k(b), d(a,b)\}.$$

Onde $\text{core}_k(x)$ é a distância até o vizinho de ordem k segundo a **convenção de vizinhança da implementação**. `min_samples` pode contar ou não o ponto em si conforme biblioteca, portanto verifique antes de replicar hiperparâmetros entre pacotes.

A estabilidade de clusters está relacionada à persistência dos membros através de escalas, muitas vezes representadas por $\lambda = 1/d$ (para $d > 0$). **Não confunda estabilidade com confiança probabilística de ausência de fraude**.

8. Comparação dos três caminhos

Propriedade	K-Means	DBSCAN	HDBSCAN
Precisa definir K?	Sim	Não	Não diretamente
Centroide explícito?	Sim	Não	Não necessariamente
Identifica ruído?	Não por padrão	Sim	Sim
Formato de cluster	Prefere grupos compactos	Regiões densas, formatos variados	Hierarquia/densidades variadas
Atribuição de novo ponto	Natural com `predict`	Necessita política específica/modelo auxiliar	Algumas bibliotecas oferecem `approximate_predict`
Custo	Geralmente baixo	Varia com índice de vizinhança/dimensão	Pode ser maior
Aplicação inicial no TCC	**Baseline principal**	Comparação exploratória	Experimento posterior

Não migraria para HDBSCAN antes de demonstrar uma limitação concreta do K-Means em perfis de carga. O ganho precisa justificar custo e dificuldade de manter grupos estáveis no tempo.

9. Quando um ponto é rotulado `-1`

Significa **não associado a cluster denso segundo os parâmetros e dados analisados**. Não significa necessariamente:

- consumo irregular;
- fraude;
- defeito do medidor;
- leitura incorreta;
- perfil de produção solar clandestina.

Pode ser uma UC comercial rara, uma estação de recarga, uma indústria, uma UC com poucos dias válidos ou um contexto de rede legítimo e distinto. A primeira ação é verificar confiabilidade, classe e perfil real.

10. PCA antes de DBSCAN/HDBSCAN: quando ajuda?

PCA pode remover redundância e melhorar visualização, porém também pode descartar componentes de baixa variância que carregam grupos minoritários. A comparação deve incluir:

- clustering nas features originais selecionadas e normalizadas;
- clustering em componentes PCA com variância preservada documentada;

- avaliação de estabilidade dos grupos e de suas curvas médias;
- inspeção da taxa e da composição de ruído;
- validação fora do período de ajuste, sempre que possível.

Importante: t-SNE/UMAP em 2D são úteis para visualização, mas distâncias no mapa 2D podem distorcer a estrutura original. Não atribua significado físico absoluto a uma distância nesse gráfico.

11. Código reproduzível com scikit-learn

```python
import numpy as np
from sklearn.cluster import DBSCAN

X = np.array([0.0, 0.1, 0.2, 3.0, 3.1, 7.0]).reshape(-1, 1)
labels = DBSCAN(eps=0.25, min_samples=2).fit_predict(X)
print(labels)  # grupos 0, 1; o último ponto deve receber -1
```

Se decidir testar HDBSCAN futuramente, instale e versiona a biblioteca escolhida. As APIs e interpretações exatas dos parâmetros podem diferir; evite copiar configurações entre `sklearn.cluster.HDBSCAN` e `hdbscan.HDBSCAN` sem conferir documentação da versão.

12. Projeto mínimo de comparação

Use um mesmo dataset sintético de perfis de 24 h com três padrões (noturno, diurno, contínuo) e alguns pontos intermediários:

1. Crie `X` com curvas normalizadas por soma e cheque nenhuma coluna contém `NaN`.
2. Treine K-Means com $K = 3$.
3. Treine DBSCAN com `eps`/`min_samples` explicitados.
4. Compare composição, perfis médios e ruído.
5. Registre padrões mal classificados, sem chamá-los de fraude.
6. Repita depois de trocar a escala/métrica, documentando alterações.

Este exercício demonstra que **o resultado é condicionado à representação e ao método**. Sem ground truth, não existe uma "acurácia de clustering" diretamente comparável à classificação supervisionada.

13. Exercícios

E14.1. No conjunto $(0, 0{,}1, 0{,}2, 3, 3{,}1, 7)$, com `eps=0.25` e `min_samples=2`, classifique grupos e ruído; depois repita com `min_samples=3`.

E14.2. Explique por que pontos isolados por forma de consumo podem estar geograficamente próximos do mesmo transformador e vice-versa.

E14.3. O clustering mudou muito quando `eps` passou de 0,4 a 0,5. Qual a implicação para usar IDs de grupo como feature operacional?

E14.4. Por que HDBSCAN é candidato interessante para grupos de diferentes densidades? Que limitação de entrada ele não resolve?

E14.5. Uma UC sem grupo tem baixa completude, muitas ausências noturnas e energia diária subestimada. Qual bloco deve ser revisado **antes** de interpretar o perfil como estranho?

Checklist

- ☐ Distingo ponto core, border e noise.
- ☐ Faço atribuição DBSCAN manual em 1D.
- ☐ Sei explicar a intuição do HDBSCAN e da distância mútua.
- ☐ Sei por que ruído não é sinônimo de fraude.
- ☐ Respondo E14.1–E14.5.

Estudo de caso integrado — do dado bruto à evidência de mudança

A seguir, vamos reunir os sete dias num **exemplo sintético**. O objetivo não é simular todo o funcionamento da concessionária: é exercitar decisões que precisam ser documentadas antes de qualquer inferência. Não confunda números do exercício com registros de clientes reais ou com resultados experimentais do TCC.

1. Cenário

Uma UC residencial possui canal de energia ativa de 15 em 15 minutos, medidor instalado durante toda a janela e cadastro sem GD conhecida. Durante 30 dias, observa-se:

- Dias 1–15: consumo típico diário de 12 kWh.
- Dias 16–30: consumo típico diário de 6 kWh.
- Dias 22–23: recepção incompleta (parte das medidas ausente).
- Durante o período completo: cadência nominal de 15 min, isto é, **96 intervalos esperados por dia**, se não houver exclusões por política de elegibilidade.
- Um grupo de UCs comparáveis apresenta perfis noturnos; outra população tem consumo diurno.

O problema aparente é “consumo caiu pela metade”. A investigação correta exige cinco verificações independentes: **qualidade**, **magnitude**, **temporalidade**, **perfil**, **contexto**.

2. Etapa A — controlar observabilidade (D8)

Cada um dos 30 dias tem 96 intervalos elegíveis; total esperado $N_{esp} = 30 \cdot 96 = 2880$.

Suponha 96 ausências no dia 22 e 48 no dia 23, sem outras faltas. Então:

$$N_{obs} = 2880 - 96 - 48 = 2736, \qquad C_{30d} = \frac{2736}{2880} = 0{,}95.$$

À primeira vista, a janela de 30 dias tem ótima cobertura (**95%**). Contudo, o dia 22 tem cobertura 0% e o dia 23, 50%. Usar soma diária bruta sem excluí-los criaria **duas quedas artificiais** de consumo, potencialmente confundidas com um evento elétrico.

Conclusão: uma regra `C_30d>=0,70` **não é suficiente** para qualquer técnica. Para estimar mudança temporal em dias consecutivos, precisamos também verificar cobertura **local** e tamanho mínimo dos segmentos pré/pós. O gate de 30 dias é apenas primeiro filtro.

Protocolo:

1. Marcar dias 22 e 23 como baixa qualidade.
2. Para comparações de consumo diário total, não tratá-los como observações completas.
3. Manter a máscara e os gaps para `S_comm`.
4. Não preencher dias incompletos com zeros.
5. Em análise de CPD, usar custos/métodos que tratem dias ausentes ou separar trechos elegíveis, registrando a consequência sobre a localização da mudança.

3. Etapa B — extrair features físicas (D9)

Nos 15 primeiros dias confiáveis, mediana pré-evento $\widetilde{E}_{pre} = 12$ kWh/dia; nos dias posteriores confiáveis, $\widetilde{E}_{post} = 6$ kWh/dia.

$$\Delta E = 6 - 12 = -6 \text{ kWh/dia}; \qquad \Delta_{rel} = \frac{6 - 12}{12} \times 100\% = -50\%.$$

Isso é uma alteração clara de **energia registrada**. Não podemos concluir ainda se houve mudança no consumo real, no sistema de medição ou de atividade na UC.

Outras features a coletar de maneira consistente:

- relação dia/noite, antes versus depois;
- fração de consumo por hora, antes versus depois;
- tendência pré e pós, calculadas **dentro dos regimes**, não apenas na janela toda;
- energia reversa de um canal configurado e elegível;
- desequilíbrio de fases quando a UC/equipamento realmente dispõe de medições adequadas;
- mudanças de medidor, classe, contrato, demanda e GD conhecida com vigência temporal.

4. Etapa C — descobrir o instante de ruptura (D10–D11)

Uma média móvel de 30 dias mistura dois patamares; não permite saber quando houve mudança. Um CUSUM poderia gerar alerta após a queda persistir. Uma segmentação offline com custo quadrático tenderia a propor ruptura entre dias 15 e 16, desde que ruído/ausências não deformem o custo.

Por que não usar o dia do alarme como t^*? Porque detecção acumulativa precisa de observações após a mudança para reunir evidência. Logo, `cpd_alert_date` e `cpd_estimated_change_date` são variáveis diferentes.

Por que não chamar "significativo" um score alto? Um custo de segmentação, distância KS, Wasserstein ou CUSUM cru não é p-valor. Precisamos calibrar sobre séries estáveis e casos sintéticos com verdade conhecida.

5. Etapa D — examinar a forma do consumo (D12–D14)

Duas hipóteses:

- **H1:** toda a curva cai aproximadamente 50% em todos os horários, com mesma forma normalizada. Isso pode indicar menor atividade, limitação de medição, alteração operacional ou outros fatores; o modelo não identifica causa por si.
- **H2:** o consumo diurno se reduz, aparece exportação em horário solar e a forma horária muda. Isso é compatível com efeitos de geração, entre outros. Precisamos cruzar com GD cadastral e com a confiabilidade real do canal de energia reversa.

No perfil normalizado, H1 pode permanecer próxima do mesmo centroide/cluster; H2 pode mudar de cluster ou tornar-se ruído. **PCA serve para visualizar componentes de variação**, K-Means agrupa formas e DBSCAN identifica regiões densas. Nenhum deles determina se a atividade é lícita.

6. Resultado operacional prudente

Em vez de:

> FRAUDE CONFIRMADA — score 0,95.

Produzir:

> **Mudança de regime candidata:** redução estimada de 12 para 6 kWh/dia (-50%), com transição próxima do dia 16. Período de 30 dias com cobertura agregada de 95%, porém dois dias com qualidade insuficiente excluídos do cálculo elétrico. Verificar histórico da UC, instalação do medidor, alarmes, GD cadastral e comportamento de pares antes de atribuir causa.

Esse é um **diagnóstico operacional compatível com evidências**, não uma acusação de fraude.

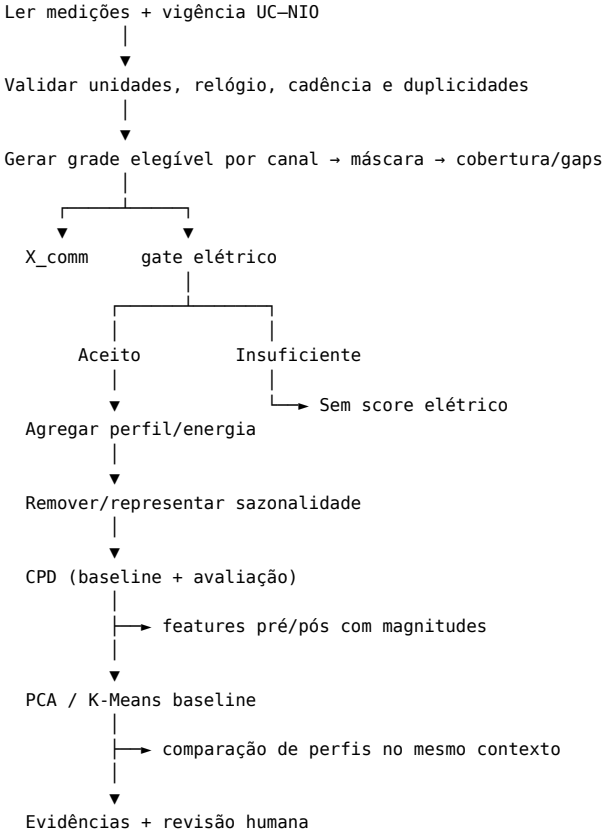
7. Modelo de tabela para armazenar resultados

Campo	Tipo	Exemplo / observação
`id__uc_id`	String	`U005`
`meta__cutoff_date`	Date	fim da janela analisada
`meta__n_expected`	Int32	2880 em exemplo sem exclusões
`meta__coverage_30d`	Float64	0,95
`meta__eligible_days`	Int16	28 dias completos neste exercício

Campo	Tipo	Exemplo / observação
`meta__is_reliable_elec`	Boolean	depende do gate **global e local**
`cpd__method`	String	`cusum_neg` / `l2_offline`
`cpd__change_date`	Date/null	estimativa, distinta do alerta
`cpd__alert_date`	Date/null	emissão efetiva da evidência
`cpd__delta_kwh_day`	Float64	-6,0
`cpd__relative_delta`	Float64/null	-0,50 quando denominador válido
`cluster__id`	Int32/null	versão do modelo junto
`cluster__noise`	Boolean/null	`true` se densidade insuficiente
`diagnosis`	String	`MUDANCA_REGIME_CAUSA_INDETERMINADA`
`model_version`	String	rastreabilidade

Sugestão de estrutura: outputs `cpd__*` podem ficar numa tabela de **eventos por UC** antes de serem agregados para `UC × cutoff_date`. Uma UC pode ter múltiplas mudanças numa mesma janela; reduzi-las a um único `cpd__change_date` perde informação. O schema acima é simplificado para estudo.

8. Fluxo mínimo para a primeira implementação confiável



A implementação deliberadamente não adiciona `MoERouter`, rede neural, PyOD ensemble ou classificação causal completa. O trabalho desta semana é obter **observações corretas e hipóteses estatísticas defensáveis**.

Formulário de consulta — 20 fórmulas e regras

Nº	Conceito	Expressão mínima	Armadilha principal
1	Cobertura	$C = N_{obs}/N_{esp}$	Denominador depende de cadência/vigência

Nº	Conceito	Expressão mínima	Armadilha principal
2	Run de ausência	$D_j = n_j \Delta t$	Não confundir com queda de energia
3	Gate	reliable $= \mathbb{1}(C \geq q)$	q não é universal; cobertura local importa
4	Z-score	$z = (x - \mu_{tr})/\sigma_{tr}$	`fit` só no treino
5	Escala robusta	$(x - \text{med})/\text{IQR}$	Não apaga outliers
6	Log transform	$\log(1 + x)$	Domínio e unidade
7	Mediana de FA	$\text{med}_d(E_{FA,d})$	Dia incompleto distorce soma
8	MAD	$\text{med}\lvert E - \text{med}(E)\rvert$	Unidades são preservadas
9	Slope	$\sum(t - \bar{t})(y - \bar{y})/\sum(t - \bar{t})^2$	Índices e unidades de tempo
10	Forma horária	$p_h = e_h/\sum_j e_j$	Perfil indefinido com soma zero
11	Hora cíclica	$\sin(2\pi h/24)$, $\cos(2\pi h/24)$	23h é vizinha de 0h
12	CUSUM +	$S_t^+ = \max(0, S_{t-1}^+ + z_t - k)$	Aumento, não queda
13	CUSUM -	$S_t^- = \max(0, S_{t-1}^- - z_t - k)$	h não é p-valor
14	Custo L2	$\sum_{t \in I}(y_t - \bar{y}_I)^2$	Outliers elevam custo
15	Segmentação	$\sum_j c(segmento_j) + \beta m$	Mais cortes nem sempre é melhor
16	KS	$\sup_x \lvert F_A(x) - F_B(x)\rvert$	Independência e sobreposição
17	Wasserstein 1D	$\int \lvert F_A - F_B\rvert dx$	Tem unidade da variável
18	PCA	$Z = X_c V_k$	Eixos não são causas físicas
19	Variância PCA	$\sum_{i \leq k} \lambda_i / \sum_i \lambda_i$	Não é recall de fraudes
20	K-Means / DBSCAN	$\min \sum_i \lVert x_i - \mu_{c_i}\rVert^2$; N_ε	Cluster raro não é fraude

Microprova oral (20 minutos)

Sem consultar o texto, explique:

1. Por que um valor `null` não é equivalente a zero kWh?
2. Como 15 min e 5 min afetam `N_expected`?
3. Por que a cobertura mensal pode esconder um buraco local grande?
4. O que muda entre `X_comm` e `X_elec`?
5. Por que `fit` do scaler não pode enxergar teste?
6. Quais interpretações físicas distintas têm o mesmo z-score?
7. Por que uma queda persistente é diferente de um outlier isolado?
8. O que CUSUM acumula; o que representa o limiar h?
9. Por que o alerta não coincide necessariamente com a ruptura?
10. Qual dado futuro uma janela pós-evento utiliza?
11. O que a penalidade β impede?
12. Qual a diferença conceitual entre KS e Wasserstein?

13. O que a PCA **não** diz sobre fraudes?
14. Por que dois perfis 10× diferentes podem cair no mesmo cluster?
15. O que significa rótulo `-1` no DBSCAN?
16. O que faltaria para atribuir uma mudança a GD não cadastrada?

A resposta considerada madura inclui hipótese, unidade, fonte e limitação. Decorar símbolos sem essas quatro coisas não basta.

Gabarito comentado — exercícios dos sete dias

O gabarito foi feito para explicar **a lógica**, não apenas oferecer números finais. Em questões abertas há mais de uma resposta admissível; o critério é respeitar origem, janela, unidade, hipótese e limitações.

Dia 8 — qualidade e comunicação

E8.1. Em um dia de 24 h, canal de 10 min: $N_{esp} = 24 \cdot 60/10 = 144$. Com 127 leituras válidas distintas, $C = 127/144 \approx 0{,}88194 = 88{,}19\%$. A frase "17 pacotes faltantes" só é válida se todos os 144 instantes eram realmente elegíveis (cadência efetiva constante, canal configurado, medidor instalado, ausência de exceções), sem duplicações/correções que alterem contagens e após política definida de atraso de ingestão.

E8.2. Mesma taxa de cobertura não significa mesma instabilidade. Compare `gap_count`, `max_consecutive_missing`, `longest_gap_min` e distribuição dos horários. Dez falhas isoladas tendem a elevar contagem de runs; dez consecutivas elevam duração máxima. Para inferir dano a análise elétrica, verifique se há longos buracos consecutivos cobrindo os períodos críticos.

E8.3. Construir grade elegível por vigência do NIO e configurações de cada instalação. Retirar intervalos não aplicáveis ao equipamento antigo/depois da remoção e ao novo/antes da instalação. Registrar intervalo de transição separadamente; divergências de horário merecem auditoria. Não transformar a troca em perda sistemática de comunicação automaticamente.

E8.4. Zero registrado pode ser real (sem consumo); também pode decorrer de característica do medidor, ausência de carga, falha de medição, disjuntor aberto, condição cadastral ou outros fatores. Tensão normal em um canal não prova ocupação. Atribuição "desocupada" exigiria contexto externo e definição operacional.

Dia 9 — engenharia de features

E9.1. $z = (110 - 80)/20 = 1{,}5$. Reestimar média no teste pode produzir outro número, mas constitui *leakage* se os dados de avaliação influenciam parâmetros do preprocessamento. Aplicar somente média e escala do treino.

E9.2. Soma observada $0 + 3 + 0 + 3 = 6$ kWh; perfil $(0, 0{,}5, 0, 0{,}5)$. Se intervalos inteiros estão faltantes, a soma é parcial e a normalização altera a forma artificialmente; primeiro aplicar critério de cobertura e elegibilidade.

E9.3. Divisão por zero é indefinida. Não converter em $+\infty$ e entregar como "probabilidade alta". Reportar RA e FA separadamente, flag de denominador insuficiente/zero com semântica física, e analisar somente ratios elegíveis. O fato de FA=0 também pode refletir erro de observação, exigindo qualidade válida.

E9.4. Exemplos: `x__hist_fa_sum_median` (kWh/dia, 30d, exige dias elegíveis); `x__hist_voltage_imbalance_max` (% na janela, somente fases medidas e qualidade definida); `x__gap_count` (contagem por canal em 7d); `x__maior_gap_min` (minutos em 30d). Diferenciar claramente campos de comunicação e elétricos.

Dia 10 — CUSUM

E10.1. Com $k = 0{,}2$, parcelas $-z_t - k$: $0{,}1$, $0{,}7$, $1{,}0$. Acumulados $S^- = (0{,}1, 0{,}8, 1{,}8)$. Primeiro cruzamento de $h = 1{,}5$ no **dia 3**. Não significa que a mudança começou exatamente no dia 3.

E10.2. Uma média global é alta durante dias úteis e excessiva no fim de semana, criando resíduos negativos em sábados/domingos mesmo sem mudança de regime. Usar referência por dia da semana, por calendário comercial ou outro modelo sazonal simples treinado no passado. Checar resíduos para evitar padrão remanescente.

E10.3. Online às 18h: somente observações e metadados disponíveis até 18h, inclusive atrasos de recebimento. Offline no próximo mês: pode usar período posterior para estimar ruptura retrospectivamente, mas não pode afirmar que a previsão anterior tinha esses dados.

E10.4. A taxa de 3% é interna e pode refletir overfitting, contaminação do baseline, sazonalidade ou próprio conjunto usado para escolher limiar. Necessário período/UCs de avaliação separado, simulação de falsas detecções, comparação por segmentos e custo operacional. Repetir alertas após primeiro disparo precisa ser definido.

Dia 11 — CPD offline e distribuições

E11.1. $y = (8, 8, 8, 2, 2, 2)$, média global 5: custo sem corte $6 \cdot 9 = 54$. Com corte depois do terceiro dia, custos intra-segmento zero. Se $\beta = 5$, custo final com uma quebra $5 < 54$: seleciona corte. Se $\beta = 100$, custo $100 > 54$: seleciona sem corte. Isso ilustra efeito da penalidade.

E11.2. Amostras ordenadas A: $(0, 1, 2)$, B: $(2, 3, 4)$. $W_1 = (|0-2| + |1-3| + |2-4|)/3 = (2+2+2)/3 = 2$ unidades da variável.

E11.3. *Look-ahead*: evento rotulado como alerta no instante t utiliza informação de $t+1$ até $t+15$. Corrigir usando somente baseline histórico e janela atual terminada em t, ou então redefinir a tarefa explicitamente como detecção retrospectiva feita depois do período.

E11.4. $t^* = 20/09$ é data real da mudança segundo o experimento; $t_{alerta} = 24/09$ é decisão disponível ao detector; atraso de alerta, seguindo convenção de diferença de datas, é 4 dias. Persistência pode ser número de dias posteriores em que o novo regime continua observado; depende do momento de avaliação.

E11.5. Primeiro verificar cobertura, canal e vigência; identificar se há troca de medidor, atraso de ingestão e zeros artificiais. Excluir dias insuficientes da comparação elétrica ou tratar como indisponíveis em modelo apropriado. Só então recalcular a evidência de CPD, sem converter gaps em consumo baixo.

Dia 12 — PCA

E12.1. No exemplo X_c centralizado, a observação $(3, 6)$ tem vetor $(1, 2)$ e $v_1 = (1, 2)/\sqrt{5}$, portanto score $z_1 = (1 \cdot 1 + 2 \cdot 2)/\sqrt{5} = \sqrt{5} \approx 2{,}236$. Segundo autovalor 0, variância explicada pelo segundo componente 0%.

E12.2. Se curvas são proporcionais e a normalização é por soma diária, resultam no mesmo vetor de proporções; o PCA não distinguiu a magnitude porque ela foi removida na entrada. Para distinguir, incluir feature de magnitude em vista adequada ou analisar separadamente.

E12.3. 88% é fração da variabilidade de `X` captada pelos componentes segundo escala e amostras; não mede taxa de irregularidades detectadas (recall). Seria preciso rótulos de verdade, protocolo de avaliação e regra de decisão.

E12.4. Ajustar PCA com dados de todo 2026 para alegar previsão em janeiro/2026 usa informação futura para definir direções/escala. Separar treino temporal anterior à data, guardar versão e transformar apenas os dados elegíveis na época.

E12.5. Pode contrastar carga noturna versus comercial diurna, provisoriamente. Confirmar observando pesos por hora, curvas reais das UCs com scores extremos, escala, centralização e composição cadastral. O sinal do componente é arbitrário.

Dia 13 — K-Means

E13.1. Grupos: $(0, 2)$ e $(10, 12)$. Novos centros $\mu_1 = 1$, $\mu_2 = 11$. Inércia $J = (0-1)^2 + (2-1)^2 + (10-11)^2 + (12-11)^2 = 4$.

E13.2. Se $b_h = 10a_h$, então $p_h^{(B)} = 10a_h/(\sum_j 10a_j) = a_h/\sum_j a_j = p_h^{(A)}$. Normalização elimina fator multiplicativo (desde que soma não seja zero e perfis elegíveis).

E13.3. Não basta. Inércia sempre tende a cair com maior K. Verificar silhouette, estabilidade em diferentes seeds/períodos, perfis médios interpretáveis e composição por classes, evitando clusters minúsculos sem utilidade.

E13.4. GD cadastrada ainda não associada corretamente, prosumidor legítimo com contrato diferente, erro de cadastro do grupo, ou perfil de produção/consumo raro. Cruzar autorização/vigência de GD, canal de energia reversa e horário solar, sem concluir irregularidade.

E13.5. Versionar modelo, scaler, centroides e ordem das features. Comparar centroides/atribuições de UCs de referência entre versões e executar alinhamento dos grupos antes de interpretar transição de ID.

Dia 14 — densidade

E14.1. `eps=0,25`, `min_samples=2`: grupo 1 $(0,0{,}1,0{,}2)$, grupo 2 $(3,3{,}1)$, ruído 7. Com `min_samples=3` e a mesma distância, primeiro trio continua cluster; segunda dupla e 7 são ruído. No scikit-learn o próprio ponto conta.

E14.2. As variáveis de clustering são perfil elétrico/horário; as coordenadas físicas ou hierarquia de trafo não entram automaticamente no vetor. UCs do mesmo trafo podem ter cargas diversas e UCs distantes podem compartilhar horário de comércio.

E14.3. Alta instabilidade de atribuições significa que a variável `cluster_id` é frágil como entrada operacional. Fazer análise de sensibilidade, reduzir ruído, melhorar features ou optar por baseline mais estável; versionar modelo e parâmetros.

E14.4. Analisa estrutura de densidade em múltiplas escalas, útil quando não existe `eps` único adequado. Não substitui limpeza, cobertura correta, escalonamento, métrica significativa e avaliação do domínio.

E14.5. Revisar `S_comm`, máscara e critérios de qualidade; uma curva calculada a partir de somas parciais pode parecer exótica por erro de observação. Não concluir comportamento elétrico sem dados suficientes.

Rubrica de compreensão para o tracker (0–5 estrelas)

Estrelas	Interpretação operacional	Exemplo prático
0/5	Não estudado	Nunca vi CUSUM
1/5	Reconheço a palavra	Sei que é detecção acumulativa
2/5	Explico qualitativamente	Descrevo por que detecta persistência
3/5	Resolvo exemplo	Calculo uma sequência à mão
4/5	Implemento e valido	Código + teste sintético + sem leakage
5/5	Defendo criticamente	Explico limites, falsos positivos e alternativa

Critério mínimo para avançar: 3 estrelas nos conceitos centrais dos dias 8–14; 4 estrelas para o conceito usado imediatamente na refatoração do código. Não há motivo para zerar o progresso da semana por não dominar HDBSCAN ao nível de implementador.

Apêndice — Referência rápida para implementação e revisão

Este apêndice não cria novos requisitos para a Semana 2. Ele serve para consultar durante refatoração do pipeline ou discussão com orientador.

A. Contrato de dados mínimo

Dado	Grão	Uso legítimo	Erro a evitar
`meter_installation_history`	UC × NIO × vigência	Associar equipamento ao período	Usar NIO mais recente retroativamente
`channel_cadence_history`	NIO × canal × vigência	Calcular N_{esp}	Grade universal de 5 min
`ami_interval`	NIO × canal × instante medido	Construir energia/curva por janela	Confundir `null` com zero
`alarm_events`	NIO × tipo × instante de origem/recebimento	Contextualizar telecom/tamper	Tratar cada alarme como fraude confirmada
`uc_day_features`	UC × dia elegível	Sumário temporal com qualidade	Somar intervalos incompletos como dia completo
`uc_window_features`	UC × cutoff × janela	Treinamento/inferência	Usar registros pós-cutoff
`cpd_event`	UC × episódio × versão	Guardar datas/magnitude de mudança	Guardar apenas a última quebra
`behavior_cluster`	UC × cutoff × versão de modelo	Comparar perfis	Tratar cluster_id como categoria permanente

B. A distinção estatística que impede diagnósticos incorretos

Qualidade de observação: $P(\text{registro presente} \mid \text{canal/configuração/tempo})$ — nossa completude é uma **frequência observada**, não estimativa calibrada de probabilidade sem modelo explícito.

Atipicidade: $\text{score}(X)$ — pontuação do método; não é, por definição, $P(\text{fraude} \mid X)$.

Mudança de regime: τ — data candidata em que modelo estatístico descreve transição; não equivale à data exata de uma ação humana.

Causa: exige evidência adicional. A partir de $FA \downarrow$ e $RA \uparrow$ durante o dia podemos propor **compatibilidade com efeito de geração**, mas não inferir ilegalidade sem verificar GD registrada, configuração de medição e cadastro vigente.

C. Polars Lazy: agregar sem ocultar qualidade

O trecho abaixo é **esqueleto pedagógico** para adaptar aos nomes reais do seu Parquet; não foi executado nesta sessão porque Polars não estava instalado no ambiente. Ele mostra apenas a agregação das observações válidas. A tabela de elegibilidade e o denominador esperado devem ser gerados separadamente com cadastro, instalação e cadência por canal.

```
import polars as pl

lf = pl.scan_parquet("ami_interval_curated.parquet")

observed_daily = (
    lf.filter(pl.col("energy_kwh").is_not_null())
      .with_columns(pl.col("measurement_ts_local").dt.date().alias("day"))
      .group_by(["uc_id", "day", "channel"])
      .agg(
          pl.col("energy_kwh").sum().alias("partial_energy_kwh"),
          pl.col("measurement_ts_local").n_unique().alias("observed_slots"),
      )
```

```
)

# Enriquecer observed_daily com expected_slots por canal/dia.
# C = observed_slots / expected_slots, quando expected_slots > 0.
# Não usar partial_energy_kwh como consumo diário completo sem gate.
```

Esse padrão torna explícito que `observed_daily` não é, sozinho, uma tabela com completude. **A grade elegível é parte do modelo de dados**, e não consequência automática de uma soma.

D. Checklist de auditoria para qualquer laboratório

Verificação	Pergunta objetiva	Evidência a registrar
Escopo	Qual população/canal é analisada?	filtros, data de corte
Semântica	Qual unidade e definição?	dicionário de dados
Elegibilidade	Em quais timestamps a leitura era esperada?	cadência + instalação
Integridade	Duplicatas, atraso, null e zeros foram tratados?	testes de qualidade
Transformação	Qual scaler/imputer e quando houve fit?	parâmetros e split
Hipótese	Detector de média, densidade ou forma?	modelo matemático
Threshold	De onde vem h, β, K ou `eps`?	validação/sensibilidade
Reprodutibilidade	Resultado pode ser reproduzido?	versão, seed, código
Interpretação	Quais afirmações são suportadas?	limitações e revisão

E. Vocabulário de consulta em português e inglês

Português	Inglês	Síntese
Completude	Coverage / completeness	Parte elegível efetivamente observada
Lacuna consecutiva	Missing run / gap	Sequência contígua de instantes ausentes
Suficiência de dados	Quality gate	Aceita, rejeita ou qualifica uma inferência
Variável derivada	Engineered feature	Resumo de dados com significado definido
Escalonamento robusto	Robust scaling	Mediana e intervalo interquartil
Vazamento temporal	Look-ahead leakage	Uso de informação do futuro
Mudança de regime	Change point / regime shift	Mudança de propriedade estatística
Soma cumulativa	CUSUM	Evidência acumulada de desvios
Função de custo	Segment cost function	Quanto um regime explica mal os dados
Penalização	Penalty / regularization	Impede cortes excessivos
Distância de Wasserstein	Earth mover's distance (1D)	Deslocamento entre distribuições
Autovetor	Eigenvector	Direção característica de matriz
Valor singular	Singular value	Escala na decomposição SVD
Variância explicada	Explained variance ratio	Fração de variância preservada por componentes
Centroide	Centroid	Média vetorial de cluster

Português	Inglês	Síntese
Inércia	Inertia	Soma de distâncias quadráticas intra-cluster
Ponto núcleo	Core point	Vizinhança suficientemente populada
Ponto de borda	Border point	Próximo de core, porém não suficientemente denso
Ruído	Noise / unassigned	Sem grupo denso conforme parâmetros
Estabilidade de cluster	Cluster stability	Persistência estrutural em escalas/versões

F. Sugestão de registro no tracker

Ao concluir um capítulo, anote sempre quatro linhas:

```
Conceito:
1 frase simples:
Fórmula + unidade/condição:
Onde aparece no TCC:
Falha mais perigosa:
Experimento/teste que executei:
```

Avalie separadamente **leitura** e **compreensão**. Exemplo: ter lido todo ZC ch. 6 não significa entender que o sinal de um autovetor PCA é arbitrário ou que variância explicada não é recall de fraudes.

G. Referências para localizar as seções originais

- **HY:** Hyndman, Rob J.; Athanasopoulos, George. *Forecasting: Principles and Practice*, 2nd ed., OTexts, 2018. Cap. 3, cap. 6, §12.9. A edição pública online mais conhecida é a 3ª e tem numeração diferente: consulte a sua cópia de 2018.
- **ZC:** Zheng, Alice; Casari, Amanda. *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*, O'Reilly, 2018. Cap. 1–2 (PDF 17–56), cap. 6 (115–130), cap. 7 (131–148), apêndice A (aprox. 195–208).
- **GE:** Géron, Aurélien. *Hands-On Machine Learning with Scikit-Learn and PyTorch*, edição fornecida (2025). Cap. 2 (PDF 71–136), cap. 7 (aprox. 251–274), cap. 8 (aprox. 275–314).
- **TR:** Truong, Charles; Oudre, Laurent; Vayatis, Nicolas. *Selective Review of Offline Change Point Detection Methods*, arXiv:1801.00718v3. §2 (PDF 3–7), §3 (8–11), §4 (12–27), §5 (28–39), §6 (40–44), §8 (47–48).
- **BR:** Bruce, Peter; Bruce, Andrew; Gedeck, Peter. *Practical Statistics for Data Scientists*, 2nd ed., O'Reilly, 2020. Cap. 1 e seções de padronização/variáveis categóricas do cap. 7.

Fonte externa sugerida, não exigida agora: documentação do HDBSCAN sobre hierarquia de densidade, distância mútua e seleção estável de clusters. Se for implementar, cite o método e a versão da biblioteca utilizada.

H. O que ainda não faz parte desta apostila

- Modelo de anomalia elétrica (Isolation Forest, LOF e residual de PCA como detector formal).
- Validação de causalidade de fraude ou GD irregular.
- Regras elétricas específicas da PRODIST, incluindo limiares por classe e tensão.
- Modelos hierárquicos/MoE e filtros espaciais.
- Calibração probabilística de scores e interpretação supervisionada de inspeção.

Esses conteúdos ficam **fora do escopo da Semana 2**. Ao concluir este volume, a competência exigida é saber preparar representações e localizar mudanças, não afirmar que os modelos finais de fraude já foram comprovados.