Da anomalia ao diagnóstico: detecção, física e integração

Apostila aplicada ao TCC de Engenharia Elétrica · Semana 3 — Especialização (dias 15–21)

Material de estudo técnico · UFPR

Novembro de 2026

Sumário

1 Guia de entrada — Semana 3 **3**
- 1.1 Em palavras simples . . . 4
- 1.2 Objetivos verificáveis . . . 4
- 1.3 Mapa inicial: tópicos, fórmulas e lugar no pipeline . . . 4
- 1.4 Macroarquitetura mínima . . . 5
- 1.5 Pré-requisitos da Semana 2 . . . 5
- 1.6 Método para cada dia . . . 5
- 1.7 Referências do acervo recebido . . . 5

2 Dia 15 — O que é, afinal, uma anomalia? **7**
- 2.1 1. Explicação sem matemática . . . 7
- 2.2 2. Mapa: quatro perguntas diferentes . . . 7
- 2.3 3. Uma observação não é necessariamente um ponto temporal . . . 7
- 2.4 4. Anomalia, mudança, distúrbio e fraude não são sinônimos . . . 8
- 2.5 5. Univariado versus multivariado . . . 8
- 2.6 6. Exemplo numérico — o que é raro depende da referência . . . 8
- 2.7 7. Como escolher a população de referência . . . 8
- 2.8 8. O problema dos rótulos . . . 9
- 2.9 9. Aplicação ao projeto . . . 9
- 2.10 10. Erros frequentes . . . 9
- 2.11 11. Exercícios . . . 10
- 2.12 12. Laboratório . . . 10

3 Dia 16 — Isolation Forest: entender antes de confiar **11**
- 3.1 1. Em palavras leigas . . . 11
- 3.2 2. O que o algoritmo realmente faz . . . 11
- 3.3 3. Equação original e cuidado com implementações . . . 11
- 3.4 4. Exemplo numérico do escore — cálculo ilustrativo . . . 12
- 3.5 5. Parâmetros que realmente importam . . . 12
- 3.6 6. Por que os modelos podem apontar tudo como anômalo? . . . 13
- 3.7 7. Observabilidade e gate . . . 13
- 3.8 8. Escore não equivale a probabilidade . . . 13
- 3.9 9. Laboratório e interpretação . . . 13
- 3.10 10. Exercícios . . . 14

4 Dia 17 — LOF: estranho em relação aos vizinhos **15**
- 4.1 1. Em palavras leigas . . . 15
- 4.2 2. Distância e vizinhança . . . 15
- 4.3 3. Densidade local e razão LOF . . . 15
- 4.4 4. Exemplo numérico simplificado . . . 16
- 4.5 5. Duas operações distintas na biblioteca . . . 16
- 4.6 6. Ajuste de k e interpretação . . . 16
- 4.7 7. Quando LOF ajuda e quando não ajuda . . . 17

4.8 8. Aplicação AMI . . . 17
4.9 9. Laboratório . . . 17
4.10 10. Exercícios . . . 17

5 Dia 18 — Alta dimensionalidade, PCA residual e ensembles: menos modelos, mais evidência 18
5.1 1. Em palavras leigas . . . 18
5.2 2. Maldição da dimensionalidade . . . 18
5.3 3. PCA residual: o que mede? . . . 18
5.4 4. Exemplo numérico — reconstrução . . . 19
5.5 5. O que é um ensemble? . . . 19
5.6 6. Ablation study: o experimento mais valioso agora . . . 19
5.7 7. Normalizar scores: três possibilidades . . . 20
5.8 8. O que validar antes de declarar melhoria . . . 20
5.9 9. Colinearidade e PCA não curam leakage . . . 20
5.10 10. Laboratório . . . 20
5.11 11. Exercícios . . . 21

6 Dia 19 — Qualidade de energia: o que a medição permite dizer 22
6.1 1. Em palavras leigas . . . 22
6.2 2. O mapa físico . . . 22
6.3 3. Tensão por unidade (*per unit*) . . . 22
6.4 4. Desequilíbrio entre fases . . . 23
6.5 5. O problema do timestamp . . . 23
6.6 6. PRODIST Módulo 8: como implementar sem criar norma fictícia . . . 23
6.7 7. Quando um pacote ausente não é interrupção . . . 24
6.8 8. Fluxo reverso e GD . . . 24
6.9 9. Regras físicas e regras regulatórias são camadas diferentes . . . 24
6.10 10. Laboratório e exercícios . . . 24

7 Dia 20 — Regras físicas, modelos supervisionados e atribuição de causa 26
7.1 1. Em palavras leigas . . . 26
7.2 2. Determinístico versus estatístico . . . 26
7.3 3. Perigo da circularidade de rótulos . . . 26
7.4 4. Classificação e matriz de confusão . . . 26
7.5 5. Precision-recall e custo operacional . . . 27
7.6 6. Random Forest e boosting, sem pular etapas . . . 28
7.7 7. Como validar com dados UC × tempo . . . 28
7.8 8. Evidência e causas — linguagem controlada . . . 28
7.9 9. Filtro espacial: atenção ao que não devemos descartar . . . 28
7.10 10. Laboratório . . . 29
7.11 11. Exercícios . . . 29

8 Dia 21 — Integração do TCC: de scores a uma evidência operacional 30
8.1 1. Em palavras leigas . . . 30
8.2 2. Os seis contratos de saída . . . 30
8.3 3. Grain e contrato de fonte . . . 30
8.4 4. Regra de gating e três estados . . . 31
8.5 5. Consenso espacial: hipótese, não exclusão . . . 31
8.6 6. Orquestrador simples, evitando MoE prematuro . . . 31
8.7 7. Diagnóstico operacional: ordem de precedência . . . 32
8.8 8. Exemplo numérico — síntese prudente . . . 32
8.9 9. Validação científica mínima para o TCC . . . 33
8.10 10. Laboratório final . . . 33
8.11 11. Exercícios . . . 33

9 Estudo de caso integrado — Uma mudança de patamar em 12 UCs 34
9.1 1. Enredo . . . 34
9.2 2. Matrizes de observabilidade . . . 34
9.3 3. A definição temporal da UC . . . 34
9.4 4. Etapa 1 — comunicação . . . 34

9.5 5. Etapa 2 — CPD . . . 35
9.6 6. Etapa 3 — características do regime . . . 35
9.7 7. Etapa 4 — detecção estatística . . . 35
9.8 8. Etapa 5 — física e alarmes . . . 36
9.9 9. Etapa 6 — diagnóstico com evidências e pendências . . . 36
9.10 10. Três experimentos de validação . . . 36
9.11 11. Um pseudocódigo claro . . . 36
9.12 12. Perguntas de banca . . . 37
9.13 13. Checklist final — D21 . . . 37

10 Gabarito comentado — Semana 3 38
10.1 Dia 15 . . . 38
10.2 Dia 16 . . . 38
10.3 Dia 17 . . . 38
10.4 Dia 18 . . . 38
10.5 Dia 19 . . . 39
10.6 Dia 20 . . . 39
10.7 Dia 21 . . . 39

11 Respostas para autoavaliação oral 40

12 Apêndice A — Formulário técnico de consulta rápida 41
12.1 A.1 Estatística descritiva e escalas . . . 41
12.2 A.2 Dados e séries temporais . . . 41
12.3 A.3 CPD e regime . . . 41
12.4 A.4 Outlier detectors . . . 41
12.5 A.5 Classificação e qualidade elétrica . . . 42

13 Apêndice B — Tabela de referências por capítulo 42
13.1 Referências diretas de normas e APIs . . . 43

14 Apêndice C — Checklist de engenharia para refatoração 43
14.1 C.1 Contrato de features . . . 43
14.2 C.2 Contrato de score . . . 43
14.3 C.3 Testes contra erros clássicos . . . 43

15 Apêndice D — Matriz de aprendizagem 0 a 5 estrelas 44

16 Bibliografia consolidada — Semana 3 44

17 Apêndice E — Laboratórios Python completos 45
17.1 Como executar . . . 45
17.2 E.1 — D15: Anomalia contextual . . . 45
17.3 E.2 — D16: Isolation Forest . . . 45
17.4 E.3 — D17: Local Outlier Factor . . . 46
17.5 E.4 — D18: Ablation e PCA residual . . . 46
17.6 E.5 — D19: Qualidade de energia . . . 47
17.7 E.6 — D20: Avaliação supervisionada . . . 47
17.8 E.7 — D21: Integração com gating . . . 47
17.9 Protocolo de validação do laboratório . . . 48

1 Guia de entrada — Semana 3

Ponto de partida. A primeira semana ensinou a descrever dados, reconhecer dependências temporais e evitar vazamento. A segunda ensinou a distinguir comunicação de comportamento elétrico, construir features, encontrar pontos de mudança e comparar perfis semelhantes. Esta terceira semana fecha o ciclo: **o que constitui uma anomalia, o que cada detector mede e como transformar evidências em diagnósticos úteis sem extrapolar a física ou o conhecimento disponível**.

1.1 Em palavras simples

Imagine que você gerencia uma frota de carros. Um carro pode rodar menos porque sofreu uma falha, porque o proprietário está de férias, porque foi vendido ou porque seu sensor não transmitiu dados. Uma máquina que apenas informa "esse carro é estranho" não identifica a causa. Um sistema útil faz perguntas em sequência: os registros são confiáveis? Houve mudança real? O comportamento é incomum para veículos parecidos? Há outros sinais físicos? Vários carros da mesma rua mudaram juntos? O mesmo raciocínio vale para os medidores inteligentes.

> **Tese central:** o sistema deve produzir **evidência rastreável, qualificada por confiabilidade**. Um score alto não é prova de fraude, defeito, geração distribuída irregular ou violação regulatória.

1.2 Objetivos verificáveis

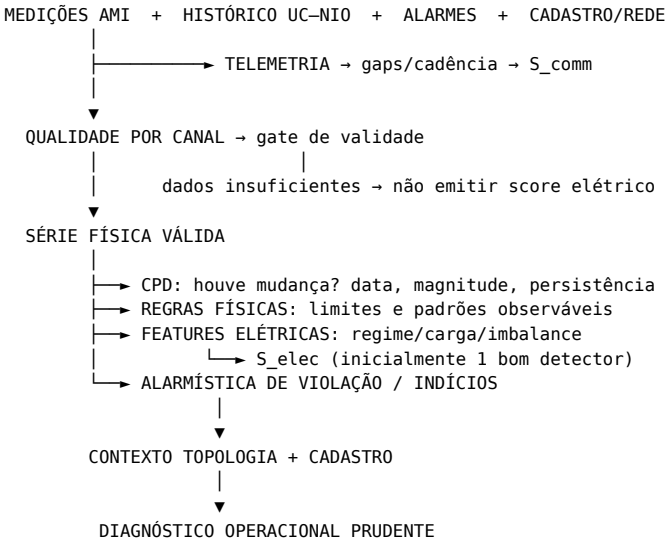
1. Explicar anomalia *global*, *local*, *contextual* e *coletiva*; separar anomalia pontual de **mudança de regime**.
2. Entender o mecanismo matemático do Isolation Forest; conhecer diferença entre `score_samples`, `decision_function`, `predict` e `contamination`.
3. Derivar o conceito de densidade local do LOF e diferenciar **detecção no conjunto treinado** de *novelty detection*.
4. Investigar o efeito de alta dimensionalidade, redundância e escala; fazer ablação e conferir semântica dos scores antes de qualquer ensemble.
5. Interpretar grandezas elétricas e qualidade de energia dentro da resolução temporal efetiva da AMI; diferenciar **triagem física** de **conformidade regulatória**.
6. Explicar de onde vêm rótulos de distúrbios, medir precisão/recall, impedir circularidade de rótulos e evitar validação temporal incorreta.
7. Desenhar o diagnóstico multivisão completo (`S_comm`, CPD, `S_elec`, regras, alarmes, topologia) e listar quais saídas precisam ser nulas quando há dados insuficientes.

1.3 Mapa inicial: tópicos, fórmulas e lugar no pipeline

Dia	Conceito central	Equação-chave	Uso no TCC
15	Raridade e comparação contextual	$z_{rob} = 0,6745(x - \tilde{x})/MAD$	Definir "estranho" sem chamar de fraude
16	Isolation Forest	$s(x) = 2^{-E[h(x)]/c(\psi)}$	Detector-base estatístico
17	Local Outlier Factor	$LOF_k(p) = \frac{\sum_{o \in N_k(p)} lrd_k(o)/lrd_k(p)}{\lvert N_k(p)\rvert}$	Anomalia relativa à vizinhança
18	Reconstrução e ensemble	$r_i = \lVert x_i - \hat{x}_i \rVert_2^2$	Diagnóstico de redundância e ablação
19	Tensão em p.u.	$V_{pu} = V_{med}/V_{ref}$	Regras físicas e interpretação
20	Avaliação supervisionada	$P = TP/(TP + FP)$; $R = TP/(TP + FN)$	Validar classificadores e triagem
21	Decisão com dados incompletos	$S_{elec} = \text{NA}$ se $C < \tau$	Integração sem inventar evidência

Os parâmetros ψ, k e τ **não são constantes universais**. Requerem definição experimental e validação no contexto do conjunto de dados.

1.4 Macroarquitetura mínima



Premissa de pesquisa: modularidade não prova automaticamente melhora de desempenho. A contribuição só pode ser afirmada após benchmarks, ablação, validação temporal e análise de casos corroborados.

1.5 Pré-requisitos da Semana 2

Pré-requisito	Teste rápido
`X_elec` ⫫ `X_comm`	Explicar onde ficam gaps e completude
`UC × cutoff_date`	Identificar o que é uma linha analítica
Treino cronológico	Dizer por que o futuro não pode criar a baseline do passado
PCA	Explicar variância explicada e erro de reconstrução
CPD	Distinguir ponto de mudança e causa
K-Means/DBSCAN	Explicar distância, centróide e densidade

1.6 Método para cada dia

1. **Linguagem leiga:** explique o problema em uma frase.
2. **Mapa conceitual:** localize o bloco e suas dependências.
3. **Matemática:** escreva fórmula, símbolos e unidades.
4. **Exemplo à mão:** calcule antes de olhar a resposta.
5. **Laboratório:** execute um experimento sintético reproduzível.
6. **Crítica:** descreva como daria errado em dados reais AMI.
7. **Tracker:** marque leitura e entendimento em escalas separadas; 5 estrelas só após conseguir defender o método.

1.7 Referências do acervo recebido

- **AG:** Charu C. Aggarwal, *Outlier Analysis*, 2ª ed., Springer, 2017 — capítulos 1, 4, 5, 6, 9, 11, 12.
- **GE:** Aurélien Géron, *Hands-On Machine Learning with Scikit-Learn and PyTorch*, edição fornecida de 2025 — capítulos 2, 3, 6, 7, 8; cap. 18 como extensão opcional.
- **BG:** Math H. J. Bollen e Irene Yu-Hua Gu, *Signal Processing of Power Quality Disturbances*, Wiley-IEEE Press, 2006 — capítulos 1, 2, 5, 7, 8, 9.
- **BP:** Bollen e colaboradores, *Classification of Underlying Causes of Power Quality Disturbances: Deterministic versus Statistical Methods*, EURASIP Journal on Advances in Signal Processing, 2007 — artigo completo.
- **BI:** Christopher M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006 — capítulos 1, 9 e 14 como referência avançada.

- **Normas / documentação externa verificada:** ANEEL, PRODIST Módulo 8 (versão vigente via portal oficial) e documentação `scikit-learn` para IF/LOF. Links completos ao fim da apostila.

As explicações e exemplos foram escritos **originalmente** para o caso AMI. São sínteses autorais de conceitos discutidos nas fontes, não reprodução literal dos livros. Todos os números dos exemplos são **sintéticos** e não representam medidores reais nem validação de campo.

2 Dia 15 — O que é, afinal, uma anomalia?

Referência principal: AG, cap. 1, *An Introduction to Outlier Analysis*. Complemento: AG, cap. 9, anomalias em séries temporais. **Meta:** decidir **que pergunta estatística** se pretende fazer antes de escolher algoritmo.

2.1 1. Explicação sem matemática

Uma pessoa que compra 30 pães por dia é incomum numa casa com duas pessoas. Mas, numa padaria, 30 pães são poucos. O número absoluto não basta: é preciso saber **quem está sendo comparado com quem, quando e em que contexto**.

O mesmo medidor pode ter consumo baixo normal durante férias, consumo alto normal em época quente e consumo baixo estranho após uma mudança de instalação. Um valor pode ser raro na população inteira e normal para a própria UC; ou comum na população e raro para aquela UC.

Definição operacional: anomalia é um comportamento que se desvia de uma referência explicitamente definida. A referência pode ser histórica, populacional, local ou física. Ela **não é automaticamente uma irregularidade**.

2.2 2. Mapa: quatro perguntas diferentes

Tipo	Pergunta	Exemplo AMI	Risco de interpretação
Global	É incomum no conjunto todo?	Consumo diário extremamente alto	Indústria naturalmente maior que residência
Local	É incomum perto de UCs parecidas?	Padaria muito abaixo de outras padarias	Vizinhos inadequados ou variáveis mal escaladas
Contextual	É incomum dado o contexto?	Consumo zero em horário comercial usual	Férias, feriado ou manutenção
Coletiva	A sequência ou grupo é incomum?	12 dias de carga achatada	Comunicação ruim ou fechamento do imóvel

Um quinto conceito útil é **anomalia de mudança**, quando a forma ou o nível do regime muda. CPD estudado na Semana 2 é um mecanismo possível; não substitui todos os tipos de anomalia.

2.3 3. Uma observação não é necessariamente um ponto temporal

No dataset de modelagem, temos geralmente uma linha por `UC × cutoff_date`, contendo um vetor

$$\mathbf{x}_i = [\text{mediana}_{30d}(E),\ MAD_{30d}(E),\ \text{slope}_{30d}(E),\ \ldots].$$

Esse **ponto multivariado** já resume uma série. A sequência original contém informação adicional: mudanças abruptas, duração, horário, periodicidade. Dois históricos distintos podem apresentar mesma média e desvio-padrão; por isso não podemos usar agregados como substituto universal da análise temporal.

Exemplo: séries diárias A: $[10, 10, 10, 10, 10, 10]$ e B: $[5, 5, 5, 15, 15, 15]$. Ambas têm média 10 kWh/dia, mas a segunda contém um degrau. A variância ajuda a diferenciá-las; ainda assim, outras séries com a mesma distribuição e ordem distinta não seriam separadas por média/variância. **Ordem importa.**

2.4 4. Anomalia, mudança, distúrbio e fraude não são sinônimos

- **Anomalia estatística:** baixa frequência segundo o modelo ou grande desvio da referência.
- **Mudança de regime:** transição temporal entre estados com parâmetros diferentes.
- **Distúrbio físico:** fenômeno elétrico cuja definição depende das grandezas e da resolução observáveis.
- **Alarme de medidor:** evento registrado pelo equipamento/sistema; possui semântica e qualidade próprias.
- **Fraude confirmada:** exige evidência apropriada, muitas vezes fiscalização/registro de campo; **não deriva de score isolado**.

Uma comparação formal não pode ser construída invertendo as definições: "anormal porque tem score alto; score alto porque é anormal". É necessário uma **referência independente** para validar.

2.5 5. Univariado versus multivariado

Para uma variável x, uma regra robusta exploratória é

$$z_{rob}(x) = 0{,}6745\frac{x - \tilde{x}}{MAD}, \qquad MAD = \text{mediana}_i\, |x_i - \tilde{x}|.$$

- $\tilde{x}$: mediana do grupo de referência, em mesma unidade de x.
- MAD: dispersão robusta, também na unidade de x.
- $0{,}6745$: aproximação de escala para distribuição normal sob condições usuais.
- A fórmula **não é definida quando** $MAD = 0$; é obrigatório estabelecer política para essa situação.

Uma extensão multivariada simples usa distância de Mahalanobis:

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)}.$$

A covariância Σ considera correlações, mas a estimativa pode ser instável com poucas amostras, muitas features ou contaminação. Não é um detector universal. AG discute várias famílias justamente porque "anomalia" não possui uma geometria única.

2.6 6. Exemplo numérico — o que é raro depende da referência

Consumos diários de cinco UCs comparáveis: $[8, 9, 10, 11, 12]$ kWh. Mediana 10; desvios absolutos $[2, 1, 0, 1, 2]$; $MAD = 1$. Uma sexta UC mede 25 kWh:

$$z_{rob} = 0{,}6745\frac{25 - 10}{1} = 10{,}1175.$$

É extremo **em relação àquele grupo**. Se a UC fosse um pequeno restaurante comparado com residências, a conclusão seria um problema de *segmentação*, não necessariamente da UC. Mesmo para mesma classe, diferenças de número de moradores, horário de operação e equipamentos podem justificar a diferença.

2.7 7. Como escolher a população de referência

Antes de `fit`, registre:

1. **Entidade:** UC ou NIO? O medidor pode ser substituído; a UC permanece em muitos casos.
2. **Janela:** o histórico usa somente dados anteriores ao cutoff?
3. **Segmento:** classe, fase, demanda, região e/ou perfil? Existe tamanho suficiente?
4. **Qualidade:** amostras com cobertura baixa devem ser excluídas/qualificadas?
5. **Mudança de cadastro:** houve alteração de contrato, classe ou GD?
6. **Medição válida:** energia reversa foi medida, ausente ou não configurada?

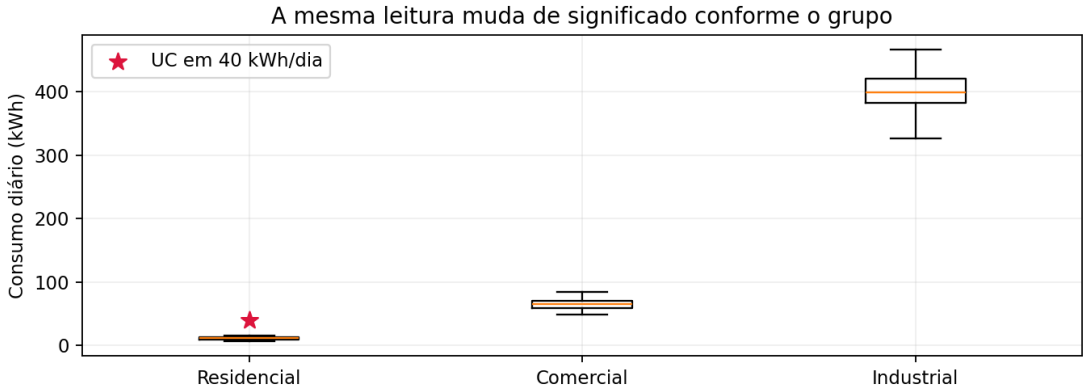


Figura 1: Comparação de escalas entre populações de UCs

Não agrupe indiscriminadamente residências, indústrias e UCs GD e depois trate os extremos como anomalias físicas.

2.8 8. O problema dos rótulos

Em detecção não supervisionada, o algoritmo **não aprende diretamente "fraude"**. Aprende uma noção de raridade/isolamento/densidade nos dados utilizados. Mesmo quando existem alarmes etiquetados como tamper, esses alarmes podem ser observações de suporte e não necessariamente *ground truth* de fraude confirmada.

Para avaliação, diferencie:

- rótulos de inspeção confirmada;
- eventos operacionalmente corroborados;
- rótulos criados por regras automáticas;
- suspeitas sem confirmação.

Esses quatro níveis **não devem ser misturados** em uma única variável `y__target_irregularity` sem proveniência.

2.9 9. Aplicação ao projeto

A primeira execução útil de `S_elec` não exige cinco detectores. Exige:

- definição de `X_elec` sem missingness/telecom;
- segmentação mínima de população;
- gate de observabilidade, com decisão não baseada em ML;
- baseline histórica válida;
- score com orientação definida (maior = mais raro?);
- critério de alerta documentado e revisável;
- exemplos contraditórios para verificar erros.

Critério de sucesso: conseguir justificar um ranking de UCs suspeitas com dados e limitações, mesmo sem rótulos de fraude.

2.10 10. Erros frequentes

Erro	Correção
"5% mais raras = 5% fraudulentas"	Percentil de score não estima prevalência de fraude
"Anomalia elétrica = violação PRODIST"	Regras regulatórias são um problema separado
"Sem leitura = consumo zero"	Missing não é zero físico
"Troca de medidor é mudança de consumo"	Rever intervalo de vigência UC–NIO

Erro	Correção
“Score 0,95 = 95% de fraude”	Scores de outlier não são probabilidades calibradas

2.11 11. Exercícios

1. Defina tipo de anomalia: uma UC de condomínio diminui 50% de consumo após mudança de morador. Há suspeita suficiente de fraude?
2. Determine mediana e MAD de $[4, 5, 5, 6, 20]$; calcule $z_{rob}(20)$.
3. Crie duas séries com mesma média e desvio-padrão populacional, mas diferente ordenação temporal. Explique por que CPD pode diferenciá-las.
4. Dê três variáveis contextuais que poderiam mudar a população de referência.
5. Escreva uma frase operacional válida para “score muito alto sem inspeção”.

2.12 12. Laboratório

Execute `lab/lab15_anomalias.py`. Ele constrói três populações com escalas diferentes, calcula escores robustos condicionados ao grupo e mostra o perigo de comparar todo mundo de forma global. A figura `fig/fig01_contexto.png` ilustra o fenômeno.

Checklist de domínio: consigo explicar em dois minutos uma anomalia sem usar a palavra fraude? Sei apontar população, janela, confiabilidade e tipo de raridade?

3 Dia 16 — Isolation Forest: entender antes de confiar

Fontes: AG, cap. 1 (famílias de outlier); GE, cap. 8 (técnicas não supervisionadas e detecção de anomalias); método original de Isolation Forest (Liu, Ting & Zhou). **Objetivo:** acompanhar `fit → score → threshold → alerta` e diagnosticar o cenário de "quase 100% anômalos".

3.1 1. Em palavras leigas

Imagine procurar uma casa muito isolada em uma cidade. Se você desenhar linhas aleatórias dividindo o mapa, essa casa tende a ficar sozinha depois de poucos cortes. Uma casa cercada por milhares de outras exige mais cortes. **Isolation Forest (IF) usa uma versão multivariada dessa ideia**: objetos fáceis de isolar são candidatos a anomalia.

Ele **não conhece leis de energia**, fraude, alarmes ou rede elétrica. Só enxerga as variáveis que entregamos. Se elas representarem majoritariamente ruído de comunicação, o modelo aprenderá raridade de comunicação — daí a importância de `X_elec` e `X_comm` separados.

3.2 2. O que o algoritmo realmente faz

Em cada árvore:

1. Sorteia uma subamostra de treinamento, tamanho ψ.
2. Em cada nó, escolhe aleatoriamente uma feature e um ponto de divisão entre mínimo e máximo observados.
3. Repete recursivamente até isolar amostras ou atingir limites de profundidade.
4. Mede **comprimento do caminho** $h(x)$ necessário para chegar à folha.

Uma floresta usa a média $E[h(x)]$ sobre várias árvores. Quando $E[h(x)]$ é pequeno em relação ao caminho esperado de uma amostra típica, a amostra tende a ser mais isolada.

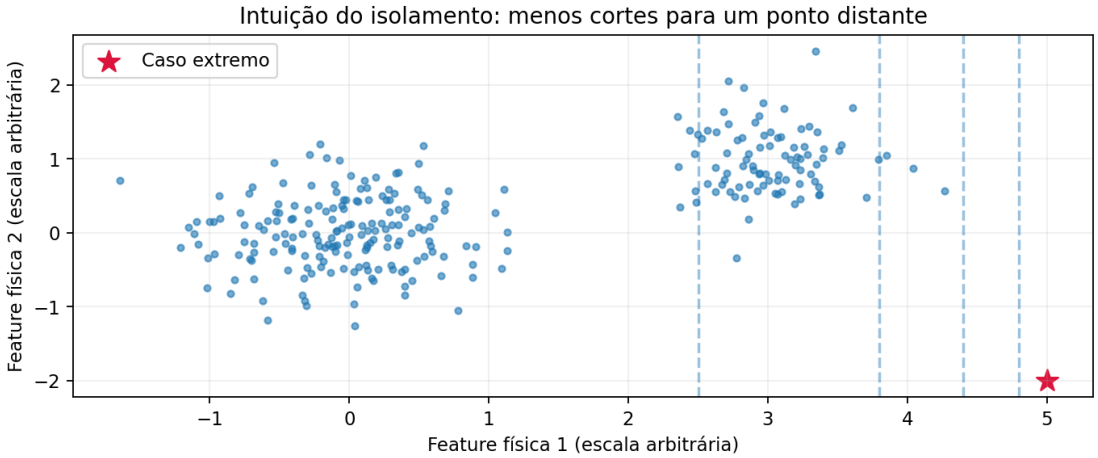


Figura 2: Isolamento de casos raros em uma população

3.3 3. Equação original e cuidado com implementações

Uma normalização usual emprega

$$c(\psi) = 2H(\psi - 1) - \frac{2(\psi - 1)}{\psi}, \quad H(m) = \sum_{i=1}^{m} \frac{1}{i}.$$

Para $\psi > 2$, o escore conceitual do artigo é

$$s(x, \psi) = 2^{-E[h(x)]/c(\psi)}.$$

- ψ: quantidade de amostras por árvore.
- $h(x)$: profundidade/caminho até isolamento, corrigido quando a folha contém várias amostras.
- $c(\psi)$: comprimento de referência.
- s próximo de 1: relativamente fácil de isolar; próximo de 0,5: comportamento próximo da média; menor: difícil de isolar. **Não é probabilidade de fraude**.

A API do scikit-learn não devolve exatamente essa notação com a mesma orientação. Consulte os atributos e verifique os sinais:

API	Interpretação operacional
`fit(X_train)`	Aprende floresta com amostras de treino
`score_samples(X)`	**Menor** valor significa mais anômalo na convenção do sklearn
`offset_`	Offset do limiar de decisão definido pelo método e por `contamination`
`decision_function(X)`	`score_samples(X) - offset_`; valores negativos são outliers
`predict(X)`	`-1` outlier, `+1` inlier

Correção indispensável: se o seu pipeline já converte o score invertendo o sinal ou normalizando de 0 a 1, documente esse passo. Não compare scores de bibliotecas sem verificar direção e escala.

3.4 4. Exemplo numérico do escore — cálculo ilustrativo

Admita $\psi = 8$. Então $H(7) = 1 + 1/2 + \cdots + 1/7 \approx 2{,}593$:

$$c(8) = 2(2{,}593) - \frac{14}{8} = 3{,}436.$$

Para amostra A, caminho médio $E[h] = 2$:

$$s_A = 2^{-2/3{,}436} \approx 0{,}668.$$

Para amostra B, caminho médio $E[h] = 4$:

$$s_B = 2^{-4/3{,}436} \approx 0{,}446.$$

A é mais facilmente isolável **segundo essa floresta**. Não podemos declarar que A é fraude, nem comparar numericamente esse escore com a saída bruta de uma implementação sem confirmar sua convenção.

3.5 5. Parâmetros que realmente importam

Parâmetro	Efeito	Risco
`n_estimators`	Quantidade de árvores; estabilidade do score	Computação desnecessária sem benefício
`max_samples`	ψ, tamanho de subamostra	Grupos pequenos podem ser mal representados
`max_features`	Features disponíveis por árvore	Variáveis pouco informativas podem dominar
`contamination`	Define **limiar**, não mecanismo de isolamento	`0.05` impõe aproximadamente 5% de treino abaixo do limiar, não prevalência real
`random_state`	Reprodutibilidade experimental	Comparações inválidas entre execuções sem semente

Uma floresta ajustada com `contamination=0.05` e pontuada **no próprio conjunto de treino** não deveria produzir 100% com `predict=-1`, exceto em circunstâncias anormais de implementação/uso. Esse sintoma exige revisar **semântica dos rótulos, limiar, dataset diferente na inferência, transformações e inversões de score** antes de ajustar mais hiperparâmetros.

3.6 6. Por que os modelos podem apontar tudo como anômalo?

Diagnóstico em ordem de economia:

1. **Labels invertidos?** `-1` = outlier; `1` = inlier, não o contrário.
2. **Score invertido duas vezes?** `decision_function<0` é outlier. Uma segunda condição `score>threshold` pode inverter o sentido.
3. **Threshold transferido de outro scaler/população?** O valor de referência pode não ser compatível.
4. **Treino e predição em populações distintas?** Contraste residencial vs industrial, família NIO, região, datas.
5. **Features incoerentes?** Unidade kWh vs Wh, tensão em V vs pu, razão RA/FA com denominador quase zero.
6. **Missingness no vetor elétrico?** Dados não transmitidos podem parecer queda física.
7. **Dados pós-cutoff?** Leakage/transformação ajustada no futuro.
8. **Amostras pontuadas não passaram pela mesma transformação `fit`?** Ordenação de colunas, colunas ausentes e encoding.

Experimento mínimo obrigatório: rode `predict(X_train)` logo após `fit`; registre contagem de `-1`, distribuição de `decision_function`, nome/ordem de features e número de amostras. Compare com a produção.

3.7 7. Observabilidade e gate

Se uma UC apresentou cobertura de 45% em 30 dias, o modelo pode ver estatísticas elétricas distorcidas. A saída recomendada é:

```
meta__data_quality = 0.45
is_reliable_elec = False
s_elec = null
is_elec_anomaly = null
reason = "cobertura insuficiente"
```

O limiar `0.70` mencionado na arquitetura é **hipótese de trabalho**. Deve ser validado por canal, fenômeno e janela. Uma cobertura geral de 70% não garante observabilidade de um evento específico; o horário das ausências também importa.

A regra impede inferência elétrica com dados ruins, mas não elimina viés de seleção: treinar apenas em medidores com boa comunicação pode criar uma população diferente da operação real.

3.8 8. Escore não equivale a probabilidade

Transformar `score_samples` linearmente para $[0, 1]$ torna uma escala conveniente, mas **não** cria $P(\text{fraude} \mid X)$. Uma distribuição de calibração pode converter scores em percentis empíricos:

$$\text{rank}(x) = \frac{\#\{i : s_i \leq s_x\}}{n},$$

com a direção do score explicitada. Isso expressa posição na **distribuição de referência**, não probabilidade causal. Se a referência mudar, o percentil também muda.

3.9 9. Laboratório e interpretação

Execute `lab/lab16_isolation_forest.py`. O script cria uma referência com três grandezas físicas sintéticas e dois casos extremos, ajusta um IF e imprime:

- pontuações `score_samples`, `decision_function` e `predict`;

- fração marcada no treino versus teste;
- os menores scores (mais incomuns) e o efeito de alterar a população de teste;
- a impossibilidade de chamar 0,05 de prevalência observada.

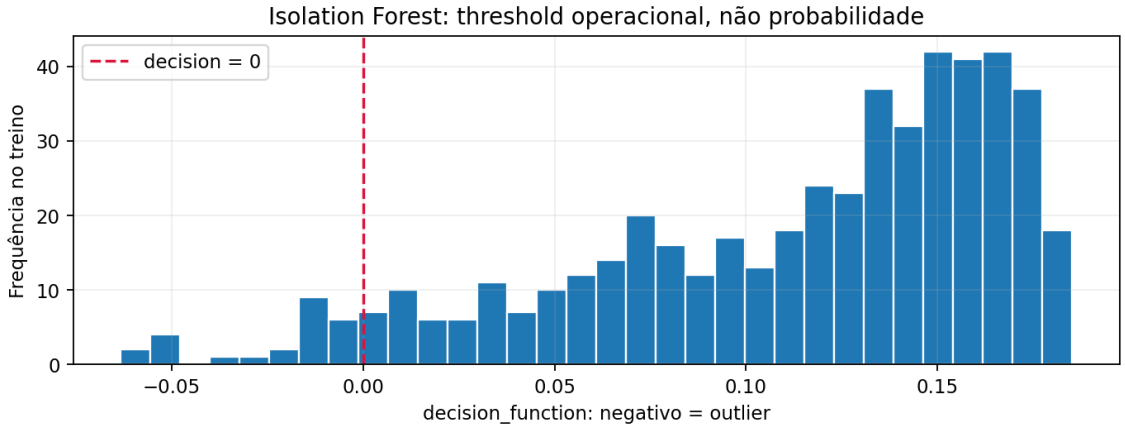


Figura 3: Scores, threshold e ranking do Isolation Forest

3.10 10. Exercícios

1. Calcule $c(4)$ e o score de uma observação com caminho médio 2.
2. Para `score_samples=[-0.3,-0.6]`, qual amostra é mais anômala no sklearn?
3. Com `decision_function=[0.05,-0.03,0]`, quais `predict` esperados?
4. Que informação mínima você registraria para reproduzir um score futuro?
5. `contamination=0.02` significa que 2% dos medidores são fraudulentos? Explique.
6. Explique dois motivos pelos quais o score de uma UC muda mesmo sem novo comportamento físico.

Domínio: consigo auditar o caminho `X → fit → score → offset → flag` e apontar um bug possível na lógica de threshold.

4 Dia 17 — LOF: estranho em relação aos vizinhos

Referência: AG cap. 4, *Proximity-Based Outlier Detection*, especialmente métodos baseados em densidade. API: scikit-learn `LocalOutlierFactor`. **Meta:** entender por que uma UC pode ser normal globalmente e anômala perto de pares realmente comparáveis.

4.1 1. Em palavras leigas

Uma casa no centro da cidade tem muitos vizinhos próximos. Uma casa isolada no campo tem poucos. Mas existe uma situação mais interessante: uma casa pode ficar relativamente afastada de um bairro muito compacto. **Local Outlier Factor (LOF)** pergunta se uma observação vive numa região de densidade menor que a de seus vizinhos.

Ao contrário de um limiar global de consumo, LOF **compara densidade local**, o que pode ajudar em populações com grupos de comportamentos distintos — desde que a proximidade no vetor de features tenha significado técnico.

4.2 2. Distância e vizinhança

Considere $x_i \in \mathbb{R}^p$. Distância euclidiana:

$$d(x_i, x_j) = \sqrt{\sum_{m=1}^{p} (x_{im} - x_{jm})^2}.$$

O conjunto $N_k(p)$ reúne os vizinhos até a k-distância do ponto, podendo conter mais de k amostras em caso de empate. k define escala local; não existe k universal. **Sem scaling apropriado**, kWh pode dominar desequilíbrio percentual e outros sinais.

O LOF calcula **distância de alcançabilidade**:

$$\text{reachdist}_k(p, o) = \max\{k\text{-distance}(o),\ d(p, o)\}.$$

Isso limita distâncias extremamente pequenas entre observações de um grupo denso, tornando o método mais estável.

4.3 3. Densidade local e razão LOF

A densidade de alcançabilidade local é inverso da distância média:

$$lrd_k(p) = \left(\frac{1}{|N_k(p)|} \sum_{o \in N_k(p)} \text{reachdist}_k(p, o) \right)^{-1}.$$

O fator de anomalia é

$$LOF_k(p) = \frac{1}{|N_k(p)|} \sum_{o \in N_k(p)} \frac{lrd_k(o)}{lrd_k(p)}.$$

- $LOF \approx 1$: densidade parecida com a dos vizinhos.
- $LOF > 1$: ponto menos denso que seus vizinhos, potencial anomalia local.
- $LOF \gg 1$: diferença local pronunciada (sem significado probabilístico automático).
- $LOF < 1$: ponto possivelmente mais denso que vizinhos.

Em casos degenerados de duplicatas/distâncias nulas, a implementação precisa de regularização numérica e atenção a ties.

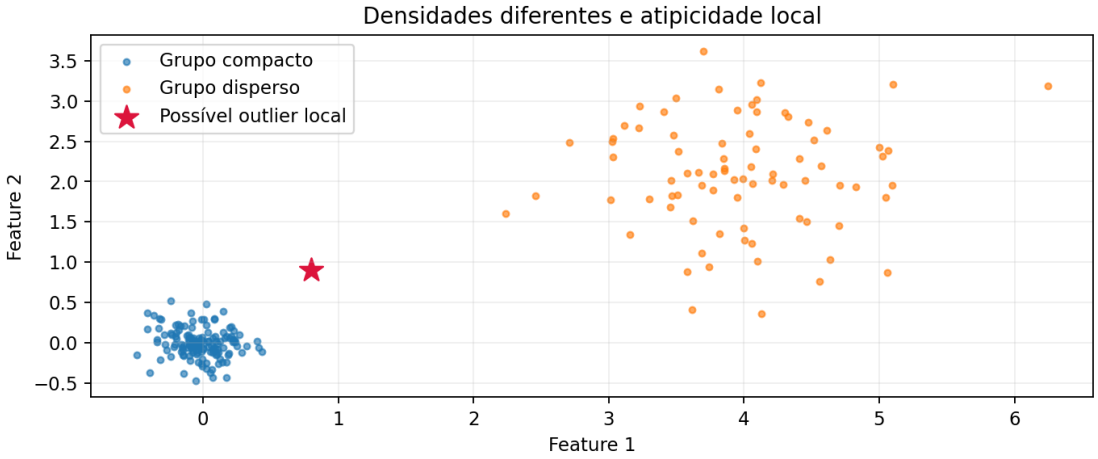


Figura 4: Ponto localmente isolado versus dois grupos normais

4.4 4. Exemplo numérico simplificado

Imagine que os dois vizinhos de p tenham densidades locais $lrd(o_1) = 2$ e $lrd(o_2) = 2{,}4$. O próprio ponto tem $lrd(p) = 0{,}5$. Logo,

$$LOF_2(p) = \frac{2/0{,}5 + 2{,}4/0{,}5}{2} = 4{,}4.$$

Esse valor sugere um ponto 4,4 vezes menos denso **no sentido da métrica LOF**, comparado com vizinhos. Não equivale a "4,4 vezes maior probabilidade de fraude". Numa região isolada composta inteiramente por perfis de grande consumo, LOF pode dar ~1 para todos porque eles têm densidade interna semelhante.

4.5 5. Duas operações distintas na biblioteca

A diferença prática mais importante do dia:

Cenário	Configuração	Como consultar
Outlier detection no conjunto ajustado	`novelty=False` (padrão)	`fit_predict(X_train)`; scores via `negative_outlier_factor_`
Novelty detection em novos pontos	`novelty=True`	`fit(X_train)` e depois `predict(X_new)` / `score_samples(X_new)`

A documentação oficial esclarece que **não se deve usar `predict(X_train)` com `novelty=True` como se fosse equivalente a `fit_predict(X_train)` em modo padrão**. O cálculo da vizinhança muda; `score_samples` no modo novidade foi pensado para novos pontos não presentes no treino.

A convenção da API usa **valores mais negativos para observações mais raras**. `negative_outlier_factor_` é o **negativo** do LOF no conjunto de treino.

4.6 6. Ajuste de k e interpretação

- k pequeno: capta microrregiões, mas fica mais sensível a ruído e poucos vizinhos.
- k alto: suaviza densidades, podendo perder contextos locais.
- Amostras de vários estratos misturados: vizinhos podem não ser comparáveis; avalie segmentação ou escalonamento cuidadoso.
- Features correlacionadas: mesma informação pode ser contada repetidas vezes na distância.
- Dimensões excessivas: distâncias entre pontos podem se tornar pouco discriminativas.

O parâmetro `contamination`, quando definido, também controla um limiar de decisão **no treino**; não muda o que é uma irregularidade real.

4.7 7. Quando LOF ajuda e quando não ajuda

Situação	IF	LOF
Ponto isolado no conjunto global	Frequentemente útil	Também pode identificar
Grupo de comportamento raro, mas coeso	Pode considerar conjunto raro	Pode dar LOF próximo de 1 internamente
População com grupos de densidades diferentes	Depende da geometria e projeções	Muitas vezes apropriado
Alta dimensão e muitas features redundantes	Pode sofrer com features irrelevantes	Distâncias podem perder significado
Inferência de novas UCs	Natural via `predict`	Exige `novelty=True` e cuidado

Nenhum desses efeitos é garantia universal: é preciso comparar na população real e nas situações sintéticas com verdade conhecida.

4.8 8. Aplicação AMI

Antes de aplicar LOF a `X_elec`, responda:

1. Cada ponto representa qual janela e tipo de medição?
2. Forma do consumo e magnitude estão misturadas indevidamente?
3. Cada UC vê pares de classe, fase e sazonalidade comparáveis?
4. Há amostras duplicadas da mesma UC em treino/teste, gerando vizinhos artificiais?
5. Há dados confiáveis e em unidades compatíveis?
6. A saída vai ser usada para histórico já conhecido ou UC nova em data futura?

Eu manteria LOF como **comparador experimental**, não como componente obrigatório de produção até mostrar ganho mensurável sobre o IF ou simples mudança pré/pós.

4.9 9. Laboratório

Execute `lab/lab17_lof.py`, que compara duas nuvens de densidades distintas e um ponto localmente isolado, primeiro em modo `fit_predict` e depois com `novelty=True` sobre amostra inédita. O código verifica as convenções das duas APIs sem misturá-las.

4.10 10. Exercícios

1. Calcule LOF se $lrd(p) = 1$ e as densidades de três vizinhos forem $1{,}1$, $1{,}2$ e $0{,}9$.
2. Por que `StandardScaler` pode mudar os vizinhos mesmo sem mudar a ordenação em cada feature?
3. Qual método você usaria para comparar uma UC de hoje com baseline histórico congelado?
4. Que tipo de outlier IF pode identificar e LOF pode ignorar num grupo pequeno mas coeso?
5. Uma classe cadastral precisa ser uma dimensão numérica da distância? Por quê?
6. Explique por que `$LOF=3$` não é `$P(fraude)=0,75$` ou `$0,03$`.

Domínio: sei distinguir densidade local, distância euclidiana, `novelty` e escore; consigo dizer quando não vale usar LOF.

5 Dia 18 — Alta dimensionalidade, PCA residual e ensembles: menos modelos, mais evidência

Fontes: AG, caps. 3, 5 e 6; GE, cap. 6 (ensembles), cap. 7 (PCA). **Meta:** demonstrar por experimento se uma feature ou detector adiciona informação real à investigação.

5.1 1. Em palavras leigas

Imagine pedir parecer sobre um mesmo fato a cinco pessoas. Se todas leram a mesma notícia e a repetiram, você não tem cinco fontes independentes: tem uma fonte ecoada cinco vezes. Um ensemble com IF, LOF, ECOD e PCA residual pode cometer o mesmo erro quando todos dependem de um conjunto de features pouco informativas ou redundantes.

Primeiro construa melhores dados e perguntas. Depois discuta a quantidade de modelos.

5.2 2. Maldição da dimensionalidade

Cada nova feature acrescenta um eixo. Se muitas features forem irrelevantes, ruidosas ou duplicadas, medidas de distância passam a dar peso aos mesmos processos repetidamente. Em espaços altos, distâncias para vizinhos próximos e distantes podem se concentrar, dependendo da distribuição dos dados.

Considere dois registros:

$$x_A = (10,0{,}02), \quad x_B = (11,0{,}05).$$

Se as colunas forem consumo kWh e desbalanceamento fracionário, a distância euclidiana bruta é

$$d(A,B) = \sqrt{1^2 + 0{,}03^2} \approx 1{,}00045.$$

A diferença de desbalanceamento praticamente desaparece no cálculo, embora possa ser fisicamente relevante. Já escalonar por desvio-padrão pode amplificar um canal com ruído instrumental muito pequeno. A solução não é “escalar tudo sempre”: é definir significado, transformação e população de referência.

5.2.1 Redundância explícita

Se `x__hist_fa_sum_median` e `x__hist_fa_sum_mean` são muito correlacionadas, ambas podem representar essencialmente nível de consumo. Incluir mais dez variações da mesma grandeza pode fazer o modelo valorizar exageradamente uma dimensão latente.

Use correlação e teste de ablação; mas não elimine automaticamente uma variável física relevante só porque ela se correlaciona com outra. Em regimes anômalos, relações previamente redundantes podem se romper.

5.3 3. PCA residual: o que mede?

Da Semana 2, dado X_c centralizado e componentes principais V_k:

$$Z = X_c V_k, \qquad \hat{X}_c = Z V_k^T.$$

O erro residual da linha i é

$$r_i = \|x_{c,i} - \hat{x}_{c,i}\|_2^2.$$

Se k e a transformação foram aprendidos **exclusivamente em dados de referência**, um valor alto significa que o registro tem componentes que o subespaço não reproduz bem. Não significa defeito

nem fraude: pequenas variações legítimas numa direção de baixa variância também podem ser muito enfatizadas.

Distinção: `PCA` na visualização gera coordenadas. `PCA residual` usa o que ficou *fora* dos componentes selecionados. A seleção de k afeta completamente o que é interpretado como anômalo.

5.4 4. Exemplo numérico — reconstrução

Considere $x = (2, 3)$ e baseline PCA de primeira componente horizontal $v_1 = (1, 0)$. Suponha dados já centralizados. A projeção é $z = 2$ e a reconstrução é $\hat{x} = (2, 0)$. Portanto,

$$r = \|(2, 3) - (2, 0)\|^2 = 3^2 = 9.$$

Para $x' = (100, 0{,}1)$, o resíduo seria $0{,}01$ apesar da magnitude muito maior. Esse exemplo mostra que PCA residual detecta **discordância com a direção aprendida**, não magnitude absoluta de consumo. O resultado real depende de centrar, escalar e ajustar v_1 com treinamento adequado.

5.5 5. O que é um ensemble?

Uma forma genérica de combinação aditiva é

$$S_i = \sum_{m=1}^{M} w_m \, g_m(s_{im}), \qquad w_m \geq 0, \quad \sum_m w_m = 1.$$

- s_{im}: score bruto do detector m para observação i.
- g_m: transformação para escala e direção comparáveis (por exemplo percentil na referência).
- w_m: peso documentado, escolhido por validação, não por aparência.

Um score grande de IF e um score grande de LOF **não são necessariamente comparáveis**. Some-los diretamente sem tratamento e sem medir dependência entre detectores é defeito metodológico.

A combinação também pode ser por ranking, consenso de flags ou regras condicionais. Não existe garantia de que o ensemble supere o melhor componente isolado.

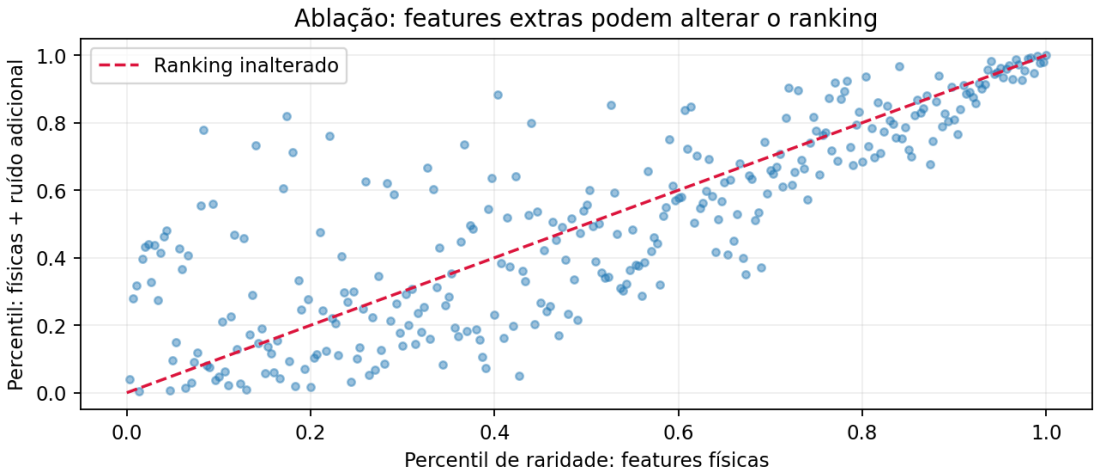


Figura 5: Efeito de features redundantes e ablação

5.6 6. Ablation study: o experimento mais valioso agora

Compare um conjunto fixo de casos, referências e cutoff dates:

Configuração	Features	Pergunta
M0	Mediana e MAD de consumo	Existe uma baseline útil?
M1	M0 + slope/CPD	A mudança de regime acrescenta evidência?
M2	M1 + tensão/corrente/reversa	As relações físicas acrescentam evidência?
M3	M2 + `data_quality` indevidamente em X	A missingness domina o detector?
M4	M2 com gate externo de qualidade	Há redução de falsos alertas de baixa confiabilidade?
M5	M4 + outro detector	O ensemble melhora algo de forma consistente?

M3 é **controle experimental negativo**, não a arquitetura de produção. Se M3 piora drasticamente, isso apoia excluir missingness da entrada elétrica; não prova que o modelo final é ótimo.

Métricas: distribuição e estabilidade dos scores, taxa de alertas por população, correlação entre scores, sensibilidade por cenário sintético, validação em exemplos corroborados e distribuição temporal dos falsos alertas.

5.7 7. Normalizar scores: três possibilidades

Min-max: $(s - \min s)/(\max s - \min s)$. Sensível a novos extremos; requer referência fixa; não é probabilidade.

Z-score: $(s - \mu_s)/\sigma_s$. Útil para comparação, mas caudas e assimetria podem invalidar leitura intuitiva; se $\sigma_s = 0$, precisa fallback.

Percentil empírico: posição do score na distribuição de referência, orientada para "maior = mais anômalo". É geralmente mais interpretável, mas depende da referência e de ties. **Nunca ajuste o percentil usando todas as datas de teste**.

5.8 8. O que validar antes de declarar melhoria

1. Mesma população/cutoff/splits para cada variante.
2. Mesmo orçamento de hiperparâmetros e seeds reproduzíveis.
3. Treino com dados anteriores ao teste.
4. Nada de coluna `y` ou metadado futuro em `X`.
5. Política consistente para nulos e não inferência quando falta informação.
6. Abrir casos extremos, medianos e casos que mudam de ranking.
7. Separar simulação (sensibilidade conhecida) de casos reais corroborados.
8. Reportar custo computacional, memória, cobertura do gate e confiabilidade.

5.9 9. Colinearidade e PCA não curam leakage

PCA e redução de dimensão ajudam a representar dependência **aprendida do treino**, mas não eliminam vazamento temporal. Ajustar `StandardScaler` ou PCA com toda a série antes da divisão temporal transmite informação estatística do futuro ao treino.

Pipeline recomendado para validação: `split por tempo → fit preprocess no train → transform val/test → fit detector no train → score val/test`. Para múltiplas janelas da mesma UC, aplique um protocolo que evite reutilizar no teste valores de períodos significativamente sobrepostos com os de treino, quando isso comprometer a pergunta de generalização.

5.10 10. Laboratório

`lab/lab18_ablation.py` compara IF com features úteis, com uma feature sintética de comunicação inserida e com outra cópia altamente correlacionada. Também calcula um erro de reconstrução PCA simples. O resultado é um **experimento didático**, não afirma superioridade universal entre modelos.

5.11 11. Exercícios

1. O que ocorre com a distância euclidiana se duplicarmos uma feature numérica correlacionada?
2. Se $x = (2, 3)$ e o subespaço contém só o eixo x, calcule o resíduo quadrático.
3. Por que o percentil 99 de IF não é 99% de probabilidade de fraude?
4. Dois detectores têm correlação de Spearman 0,98 nos scores; isso justifica ensemble?
5. Proponha um ablation mínimo para testar a contribuição de `cpd_magnitude_delta`.
6. Que evidência precisa ser produzida para afirmar que M4 supera M3?

Domínio: consigo eliminar um detector redundante e justificar por dados, em vez de escolher mais modelos apenas porque existem em uma biblioteca.

6 Dia 19 — Qualidade de energia: o que a medição permite dizer

Fontes: BG caps. 1–2, 5, 7–9; PRODIST Módulo 8 vigente (ANEEL). **Meta:** transformar tensão, corrente e energia em regras físicas válidas sem prometer observação de transientes subciclados com AMI de 15 minutos.

6.1 1. Em palavras leigas

Imagine medir a temperatura de um forno a cada 15 minutos. Você consegue perceber que ele opera frio ao longo do dia, mas pode não perceber um pico de 3 segundos entre duas leituras. Com tensão elétrica ocorre algo semelhante: **a medição contém apenas o que sua cadência, intervalo de integração e tecnologia realmente registraram**.

Por isso, antes de aplicar qualquer norma, precisamos saber **qual grandeza foi medida, como foi calculada e de que período se refere**. Não é correto transformar uma leitura de 15 minutos em um oscilograma de alguns ciclos.

6.2 2. O mapa físico

Fenômeno	Escala típica de observação necessária	O que AMI de 15 min pode fazer
Tensão de regime permanente persistente	Leituras qualificadas, agregação regulamentada	Triagem preliminar, se a medição é adequada
Desbalanço entre fases	Magnitudes por fase; definição apropriada	Proxy se houver medidas simultâneas por fase
Distúrbio curto sag/swell	Alta resolução ou registrador de evento específico	Não caracterizar diretamente a duração de poucos ciclos
Interrupção	Registro temporal/eventos de duração correspondente	Detectar ausência sustentada **se houver evidência de tensão/alarme**, não por pacote faltante
Harmônicos/THD	Instrumentação apropriada ou campo THD medido	Não reconstruir harmônicos só de tensão média
Energia reversa	Canal de energia reversa válido	Observar exportação/fluxo reverso conforme semântica do registrador

A chave é a função de medição. `u_l1` pode significar valor médio, instantâneo, RMS integrado, registrador com timestamp de recebimento, ou medição agregada. A API/SQL não revela isso por si só.

6.3 3. Tensão por unidade (*per unit*)

$$V_{pu} = \frac{V_{med}}{V_{ref}}.$$

- V_{med}: tensão observada (V), com definição e instante válidos.
- V_{ref}: tensão correta para o ponto de conexão/fase analisado (V), de acordo com esquema monofásico/trifásico, fase-neutro/fase-fase e metadado vigente.

Exemplo: medição RMS de 121 V em um ponto com referência fase-neutro de 127 V:

$$V_{pu} = 121/127 \approx 0{,}953.$$

É correto dizer “observação equivalente a 0,953 p.u.”. Classificá-la como adequada/precária/crítica só é legítimo após determinar tabela e procedimento aplicável. Não use `0,93` ou `1,05` indiscriminadamente para todos os níveis de tensão e modalidades.

6.4 4. Desequilíbrio entre fases

Uma aproximação a partir de **magnitudes** é o *percent voltage unbalance ratio* (PVUR), frequentemente definido como:

$$PVUR = 100\frac{\max_k |V_k - \overline{V}|}{\overline{V}}, \quad \overline{V} = \frac{1}{m}\sum_{k=1}^{m} V_k.$$

Exemplo: três tensões entre fases simultâneas $[220, 218, 224]$ V; média $220{,}667$ V; maior desvio $3{,}333$ V:

$$PVUR \approx 100\frac{3{,}333}{220{,}667} \approx 1{,}51\%.$$

Esse índice é um **proxy** baseado em magnitudes. Ele **não é** o fator de desequilíbrio baseado em componentes simétricas do vetor fasorial:

$$FD \approx 100\frac{|V_2|}{|V_1|},$$

onde V_1 e V_2 são componentes de sequência positiva e negativa. Sem ângulos de fase (ou informação suficiente para reconstruí-los sob hipóteses justificadas), não podemos declarar equivalência plena entre PVUR e FD. Fases ausentes em uma UC monofásica não são “duas fases com tensão zero”.

6.5 5. O problema do timestamp

Uma medida com `RECEIVE_TIME=15:15` pode representar:

- RMS observado às 15:00;
- RMS médio do intervalo [15:00,15:15);
- registro publicado às 15:00 e recebido às 15:15;
- medição acumulada desde o último pacote.

As quatro interpretações geram séries diferentes. Procure a documentação do canal, fuso horário e carimbo correto do dispositivo antes de calcular limites ou duração.

6.6 6. PRODIST Módulo 8: como implementar sem criar norma fictícia

O **PRODIST** disciplina qualidade do fornecimento; a ANEEL mantém portal com módulo e versões vigentes. As faixas de classificação de **tensão em regime permanente** variam conforme o nível nominal de conexão e a tabela normativa correspondente. A avaliação regulatória envolve requisitos de medição e metodologia de agregação; não é mera aplicação de um `if V<limite` a toda observação AMI.

Procedimento seguro:

1. Identificar a tensão nominal/contratada e a tabela aplicável em **versão normativa registrada**.
2. Confirmar unidade, relação fase-neutro/fase-fase, grandeza e integração do canal.
3. Confirmar a admissibilidade das leituras para avaliação de conformidade.
4. Classificar cada leitura **válida** em adequada/precária/crítica usando a tabela pertinente.
5. Calcular indicadores conforme método previsto, exigindo quantidade/duração de leituras apropriadas.
6. Registrar versão da norma, tabela, data de vigência e limitações.

Os indicadores DRP/DRC são percentuais de leituras em faixas precária/crítica num procedimento específico. O critério de referência de 3% e 0,5% aparece na regulação, mas **não deve ser transposto sem as condições normativas** a uma série arbitrária de quinze minutos. O uso adequado do dataset é inicialmente **triagem de compatibilidade**, e não certificação formal de conformidade.

Fonte de verificação atual: https://www.gov.br/aneel/pt-br/centrais-de-conteudos/procedimentos-regulatorios/prodist. Conferir Módulo 8 vigente ao reproduzir os resultados.

6.7 7. Quando um pacote ausente não é interrupção

Se não houver leitura para L1 às 14:15, isso pode resultar de falha do canal ou telemetria. Não inferir `V=0`. Quando o medidor comunica três tensões explicitamente próximas de zero, a hipótese de ausência de tensão é mais forte, mas exige verificar confiabilidade, modo do equipamento, fase ativa e eventual desligamento programado.

Zero real, **missing**, **fase inexistente**, **registrador indisponível** e **tensão abaixo de resolução** devem possuir estados distintos no processamento. O `x__ratio_null_phases` descreve disponibilidade de telemetria, portanto não deve ser interpretado como prova física de queda de fase.

6.8 8. Fluxo reverso e GD

Energia reversa medida (`RA`) é evidência de exportação no registrador apropriado; pode indicar GD, mudança de fluxo, configuração, ligação ou outros eventos operacionais. **RA presente não prova GD irregular**. É indispensável cruzar registro de GD, tipo de medidor, canal configurado, vigência e eventual intervenção.

Razão RA/FA exige defesa numérica. Com $FA \approx 0$, ela pode explodir sem que exista uma mudança física proporcional. Use denominador mínimo documentado ou mantenha numerador/denominador separados, e nunca interprete valores indefinidos como grandes anomalias automaticamente.

6.9 9. Regras físicas e regras regulatórias são camadas diferentes

Física: relação energia-potência ($P \approx \Delta E/\Delta t$ sob definição adequada), limites instrumentais, consistência por fase e relação com alarmes.

Norma: faixa específica, modalidade de medição e interpretação regulatória. Não se pode presumir que todo limite físico seja limite PRODIST, ou que uma violação instantânea seja desconformidade formal do período.

Estatística: desvios relativos à referência e mudança de regime. Uma variação de consumo anômala pode ocorrer com tensão plenamente adequada.

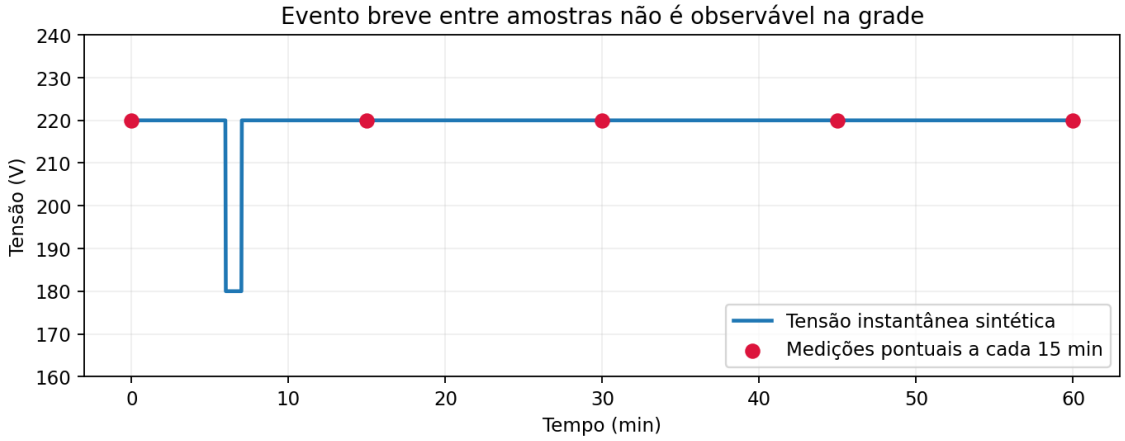


Figura 6: Medição média e fenômeno curto não observável na grade AMI

6.10 10. Laboratório e exercícios

Execute `lab/lab19_pq.py`. Ele calcula tensão em p.u., proxy PVUR e verifica como um evento breve pode não ser capturado por amostragem pontual espaçada. O código **não implementa classificação formal PRODIST**; limita-se a triagem didática com referências configuradas.

1. Para $V_{med} = 209$ V e $V_{ref} = 220$ V, encontre V_{pu}.
2. Para tensões de linha $[220, 218, 224]$ V, encontre PVUR aproximado.
3. Por que $V_{L2} =$ null não significa queda de fase?
4. O que seria necessário para calcular o fator de desequilíbrio por componentes simétricas?
5. O que podemos concluir de `RA>0` quando a UC não possui GD cadastrada?
6. Explique por que 96 amostras pontuais/dia não identificam um sag de 4 ciclos ocorrido entre elas.
7. Quais três metadados precisam existir antes de classificar tensão conforme norma?

Domínio: consigo dizer o que é verdade física, o que é hipótese operacional e o que requer instrumento e procedimento normativo específico.

7 Dia 20 — Regras físicas, modelos supervisionados e atribuição de causa

Fontes: BP, artigo de 2007 sobre classificadores determinísticos versus estatísticos; BG cap. 9 (*Classification of Power Quality Disturbances*); GE cap. 3 (classificação), cap. 6 (Random Forest e boosting).
Meta: saber quando usar regra, quando treinar e como medir erros com consequências operacionais.

7.1 1. Em palavras leigas

Considere um detector de fumaça. Ele pode perceber fumaça sem saber se houve incêndio, churrasco, poeira ou vapor. **Detectar um sinal** não é o mesmo que **explicar sua causa**. Em medidores inteligentes, queda de consumo, mudança de corrente ou inversão de fluxo descrevem comportamentos observáveis; diagnóstico de by-pass, GD irregular ou defeito envolve hipóteses e informação externa.

Por isso o pipeline faz primeiro detecção de evento/candidato e depois **caracterização compatível com causas possíveis**, sem converter toda associação em certeza.

7.2 2. Determinístico versus estatístico

Regra determinística: uma condição explícita baseada em definição física/operacional. Ex.: "para medidor trifásico com três canais configurados e válidos, reportar grande assimetria entre magnitudes de corrente". Essa regra é interpretável, mas depende de medir corretamente e de limiar justificado.

Modelo supervisionado: aprende relações $X \mapsto y$ a partir de exemplos rotulados. Pode combinar múltiplas variáveis não linearmente, mas a qualidade dos rótulos limita o significado da saída.

Modelo não supervisionado: estima raridade/estrutura sem rótulos de classe. É útil para triagem, mas não cria sozinho a etiqueta de causa.

Bollen e colaboradores discutem a combinação de conhecimento especialista, segmentação, extração de características e classificadores. A adaptação para dados AMI de 15 minutos é nossa e **não transfere automaticamente a capacidade dos métodos desenvolvidos para formas de onda de alta resolução**.

7.3 3. Perigo da circularidade de rótulos

Imagine criar rótulo `SUBTENSAO=1` sempre que $V_{pu} < 0{,}9$ e treinar Random Forest usando o próprio V_{pu} como entrada. Se o modelo acerta quase tudo, não descobriu uma relação profunda; apenas **aproximou a regra usada na rotulação**.

Esse treinamento pode ter valor operacional (compressão, integração, inferência quando só existem proxies, ruído de medição), mas não demonstra que ML seja melhor que aplicar a regra original. A avaliação apropriada compara desempenho, custo e generalização frente à própria regra, e, quando possível, usa rótulos independentes.

Regra prática: quando uma classe é definida exatamente por thresholds disponíveis nas features, implemente primeiro regra determinística. Modelos aprendidos exigem motivo adicional e avaliação comparativa honesta.

7.4 4. Classificação e matriz de confusão

Para um evento de interesse, a matriz contém:

	Evento verdadeiro	Evento ausente
Alerta positivo	TP	FP
Alerta negativo	FN	TN

Métricas:

$$\text{Precisão} = \frac{TP}{TP+FP}, \qquad \text{Recall} = \frac{TP}{TP+FN}.$$

$$\text{FPR} = \frac{FP}{FP+TN}, \qquad F_1 = \frac{2PR}{P+R}.$$

Exemplo: 1000 casos; 20 irregularidades de referência confirmadas; modelo alertou 50, dos quais 15 confirmados. Então TP=15, FP=35, FN=5 e TN=945.

$$P = 15/50 = 0{,}30, \quad R = 15/20 = 0{,}75, \quad FPR = 35/980 \approx 0{,}0357.$$

Acurácia seria $(15 + 945)/1000 = 96\%$: parece excelente, mas o valor de precisão é **30%**. Se fiscalizar 50 casos, apenas 15 são positivos na referência; contexto de seleção, custos e qualidade dos rótulos precisam ser considerados.

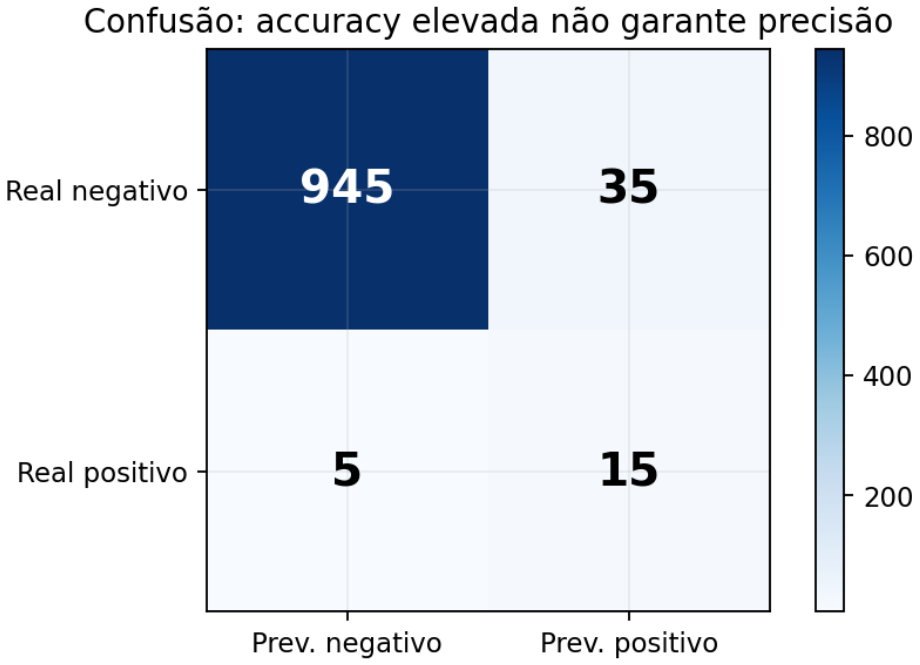


Figura 7: Matriz de confusão e efeito de classe rara

7.5 5. Precision-recall e custo operacional

Se há poucos casos confirmados, curvas PR e precisão nos top-K alertas costumam ser mais úteis que accuracy isolada. AUC-ROC pode dar visão complementar, mas sua interpretação não substitui custo de investigação.

Precision@K é a fração de eventos confirmados entre os K primeiros candidatos:

$$Precision@K = \frac{\#\text{confirmados no top-}K}{K}.$$

Se a concessionária tem capacidade mensal para investigar 100 UCs, `Precision@100` e cobertura de casos relevantes são métricas com significado direto. Mas requerem **rótulos confiáveis e amostragem de verificação**: se só os próprios alertas são inspecionados, a estimativa de precisão pode sofrer viés de seleção.

7.6 6. Random Forest e boosting, sem pular etapas

Árvore de decisão: divide o espaço de features por regras sequenciais (`V_pu < a`, `cpd_delta < b` etc.). É interpretável até certo ponto, mas pode superajustar.

Random Forest: ajusta muitas árvores sobre amostras e subsets de features, agrega votos/probabilidades. Ajuda a reduzir variância e modelar interações, mas não resolve rótulos ruins ou leakage.

Gradient Boosting / LightGBM: constrói árvores sequencialmente para corrigir erros do conjunto; pode capturar relações complexas e exige atenção a hiperparâmetros, calibração e drift.

Para classificação de causa por eventos, **só adote supervisionado quando houver rótulos externos suficientemente confiáveis e representativos**; caso contrário use regras de compatibilidade + ranking de investigação, sem fabricar certeza causal.

7.7 7. Como validar com dados UC × tempo

`GroupKFold` por UC impede que a mesma UC apareça em treino e teste **quando os grupos são UCs**, mas não garante automaticamente que o modelo nunca enxergou dados futuros de outras UCs. Um split cronológico impede treino futuro, mas pode compartilhar a mesma UC e janelas históricas muito sobrepostas.

Precisamos definir a pergunta de generalização:

- **Nova data para UCs conhecidas:** split temporal rigoroso; definir intervalo de purga quando janelas de features se sobrepõem.
- **Novas UCs:** separar grupos UC; validação temporal adicional se houver efeito calendário.
- **Novo alimentador/município:** separar a hierarquia correspondente quando o teste exige generalização geográfica.
- **Mesma região sob intervenção sistêmica:** impedir que o mesmo evento seja dividido entre treino e teste via medidores distintos.

Não existe um único `GroupKFold` que garanta todas as formas de generalização.

7.8 8. Evidência e causas — linguagem controlada

Evidência observada	Hipóteses compatíveis	Não concluir automaticamente
FA desce + RA sobe durante dia	GD, mudança de fluxo, cadastro desatualizado	“GD clandestina confirmada”
FA despenca + desbalanceamento sobe	defeito/medição, alteração da carga, intervenção	“by-pass confirmado”
FA cai a zero + tensão continua válida	carga ausente, UC fechada, circuito a jusante desligado	“imóvel desocupado”
Muitos vizinhos com queda de tensão simultânea	evento sistêmico, alimentador/trafo, clima	“fraude de todas as UCs”
Alarme de tampa + mudança de FA	evento de integridade, possível intervenção	“fraude comprovada”

Sugestão de saída: `evidences=[...]`, `compatible_hypotheses=[...]`, `confidence_level=...` quando existirem critérios explícitos de confiança; `requires_investigation=True`. Evite `fraud_probability` sem estimativa e calibração próprias.

7.9 9. Filtro espacial: atenção ao que não devemos descartar

Se várias UCs no mesmo trafo exibem variações de tensão simultâneas, aumenta plausibilidade de uma causa comum. Porém, isso **não torna o evento espúrio**: pode ser um problema real de rede e de interesse operacional. O papel do `SpuriousFilter` deve ser **reclassificar/qualificar a causa provável e a prioridade**, nunca apagar automaticamente todos os sinais compartilhados.

AG, caps. 11–12, fornece arcabouço para outliers espaciais e em grafos. Conectividade elétrica deve vir da topologia vigente, não apenas distância geográfica.

7.10 10. Laboratório

`lab/lab20_classificacao.py` cria um cenário didático de classe rara e compara regras e Random Forest usando dois conjuntos de rótulos: um construído pela própria regra e outro gerado por cenário independente. O objetivo é evidenciar circularidade e diferença entre accuracy, precision e recall.

7.11 11. Exercícios

1. Recalcule matriz de confusão do exemplo com TP=15, FP=35, FN=5, TN=945.
2. Por que 96% de accuracy é potencialmente enganoso nessa população?
3. Se `y` nasce exclusivamente da regra $V_{pu} < 0{,}9$, que contribuição adicional um ML precisa demonstrar?
4. Proponha protocolo para nova UC, nova data e novo alimentador.
5. Uma mesma falha aparece em 30 medidores vizinhos: suprimir alertas? Justifique.
6. Redija diagnóstico prudente para “RA sobe e FA cai após CPD”.

Domínio: sei dizer o que uma matriz de confusão mede, o que uma regra normativa significa e por que atribuir causa sem rótulo confiável é um erro.

8 Dia 21 — Integração do TCC: de scores a uma evidência operacional

Fontes: síntese dos sete dias; AG cap. 6 (ensembles), caps. 11–12 (espacial/grafos); BI cap. 14 (combinação de modelos e conditional mixtures, apenas leitura avançada). **Meta:** desenho end-to-end, contrato de dados e plano mínimo de validação experimental.

8.1 1. Em palavras leigas

Um médico não usa um único exame para concluir um diagnóstico complexo. Antes de interpretar, verifica se a coleta deu certo; observa histórico; compara exames; diferencia sintomas compartilhados por um surto de sintomas individuais. O pipeline AMI deve fazer o mesmo: **cada módulo responde uma pergunta e preserva sua limitação**.

Não precisamos chamar toda agregação de "MoE". Um roteamento com pesos definidos por tamanho de amostra é uma mistura ponderada heurística; **Mixture of Experts aprendido** geralmente envolve especialistas e função de gating treinada ou formulada probabilisticamente. Se o `MoERouter` atual apenas interpola feeder/município/global, descreva isso com precisão.

8.2 2. Os seis contratos de saída

Componente	Entrada	Saída	O que NÃO afirma
`S_comm`	gaps/cadência/alarmes de telecom	grau de atipicidade comunicacional	que faltou energia
Gate de qualidade	cobertura por canal/janela	elegível, inelegível, razões	que o medidor é regular
CPD	série validada e referência	data candidata, magnitude, persistência	causa da mudança
`S_elec`	exclusivamente features físicas	raridade elétrica, score ou nulo	fraude comprovada
Regras/eventos	tensão/corrente/RA e alarmes válidos	evidência semântica	conformidade regulatória automática
Contexto/topologia	cadastro vigente e vizinhança	correlação de eventos/hipóteses	que sinais coletivos são irrelevantes

O requisito mais importante é a **semântica de ausência de output**: `null` (não avaliado) não é `0` (baixa anomalia) nem `False` (avaliação negativa).

8.3 3. Grain e contrato de fonte

A camada analítica final pode usar `UC × cutoff_date`. A ingestão, entretanto, possui várias entidades:

- amostras intervalares: `NIO × timestamp × channel`;
- alarmes: `NIO × event_id × tempo`;
- histórico da instalação: `UC × NIO × [t_install,t_remove)`;
- cadastro: `UC × [vigência)`;
- topologia: `UC/trafo/alimentador × vigência`.

O join temporal é condição necessária: alarme do NIO antigo **não** pertence ao medidor novo da mesma UC após a substituição. Se houver lacunas ou inconsistências entre intervalos, registrar ambiguidade; não alocar eventos por conveniência.

Os nomes abaixo são contrato **proposto**. Não afirmam disponibilidade física no banco até verificação de extração.

```
id__uc_id: string
meta__cutoff_date: date
meta__window_days: int
```

```
meta__nio_at_cutoff: string
meta__data_quality: float
meta__channel_coverage: map
meta__eligible_elec: bool
meta__reason_not_evaluated: string|null
x__hist_fa_sum_median: float|null
x__hist_fa_sum_mad: float|null
x__trend_fa_slope: float|null
x__hist_load_factor_mean: float|null
x__hist_ra_reversal_days: int|null
x__hist_voltage_imbalance_max: float|null
cpd__change_date: date|null
cpd__magnitude: float|null
cpd__persistence_days: int|null
s_comm: float|null
s_elec: float|null
s_tamper: float|null
is_elec_anomaly: bool|null
operational_diagnosis: string
source_version: string
model_version: string
```

Se `s_tamper` é resultado de heurística, descreva-o como **índice heurístico de priorização**, não probabilidade calibrada.

8.4 4. Regra de gating e três estados

A lógica operacional básica:

$$S_{elec}(u,t) = \begin{cases} \text{NA}, & C_{u,t} < \tau \text{ ou canal crítico inválido,} \\ f_\theta(X_{elec}(u,t)), & \text{observabilidade adequada.} \end{cases}$$

Defina três estados para um veredito binário:

- `True`: avaliado e acima do limiar de anomalia;
- `False`: avaliado e abaixo do limiar;
- `null`: **não avaliado** ou avaliação inconclusiva.

Não use `False` para todos os medidores com baixa completude. Isso produz falsa taxa de “normais” e dilui os denominadores.

Exemplo: 100 UCs, 70 elegíveis. Das elegíveis, 7 alertas. Taxa condicional = 7/70 = 10%. Taxa de alertas por população total = 7/100 = 7%. Ambas podem ser reportadas, desde que o denominador e os 30 casos não avaliados apareçam. A “taxa real de anomalia em todas as UCs” permanece desconhecida.

8.5 5. Consenso espacial: hipótese, não exclusão

Defina vizinhos topológicos $N(u,t)$ no **mesmo trafo** ou alimentador vigente. Para eventos datados, use janela de coincidência Δ e só inclua medidores observáveis:

$$R_{neighbor}(u,t) = \frac{\sum_{v \in N(u,t)} \mathbf{1}\{\text{evento em } v \text{ próximo de } t\}}{\#\{v \in N(u,t) \text{ válidos}\}}.$$

Se 9 de 10 vizinhos válidos sofreram variação de tensão no mesmo horário, uma explicação sistêmica ganha plausibilidade. Esse indicador não confirma evento sistêmico sozinho, nem implica que a UC investigada esteja normal. Também existe dependência comum de comunicação: uma queda simultânea de telemetria pode resultar de rede de dados, não rede elétrica.

8.6 6. Orquestrador simples, evitando MoE prematuro

Se houver referências global, municipal e do alimentador, uma média ponderada convexa seria

$$\hat{s} = w_f s_f + w_m s_m + w_g s_g, \quad w_f + w_m + w_g = 1, \quad w_j \geq 0.$$

Problema de escala: se os scores foram ajustados por modelos diferentes, suas distribuições podem não ser comparáveis. Pesos por tamanho amostral e penetração GD são heurísticas com premissas a validar.

Minha versão MVP: não agregue ainda scores hierárquicos. Apresente score elétrico, cluster, baseline/cenário e contexto separadamente. Só implemente roteamento adaptativo depois de benchmark com amostras suficientes por grupo, fallback explícito e medidas de generalização.

8.7 7. Diagnóstico operacional: ordem de precedência

1. **Validação de dados:** verificar vigência NIO, canal, timestamp, unidade, completude.
2. **Segurança de interpretação:** se insuficiente, `SEM_DADOS_SUFICIENTES` e não emitir `S_elec`.
3. **CPD e evidência física:** se válidos, gerar caracterização de transição.
4. **Anomalia estatística:** registrar score, referência e percentil — nunca "fraude confirmada".
5. **Alarmística:** adicionar eventos, data, latência e semântica confiável.
6. **Topologia:** marcar coincidência temporal com vizinhos e distinguir telecom de tensão.
7. **Síntese:** priorizar investigação e registrar hipóteses compatíveis.

Estados sugeridos: `DADO_INSUFICIENTE`, `INSTABILIDADE_COMUNICACAO`, `MUDANCA_DE_REGIME`, `ANOMALIA_ELETRICA`, `EVENTO_FISICO_OBSERVADO`, `EVIDENCIAS_CONVERGENTES_PARA_INVESTIGACAO`. Esses estados podem coexistir: prefira múltiplas tags e justificativas a um diagnóstico mutuamente exclusivo excessivamente simplificador.

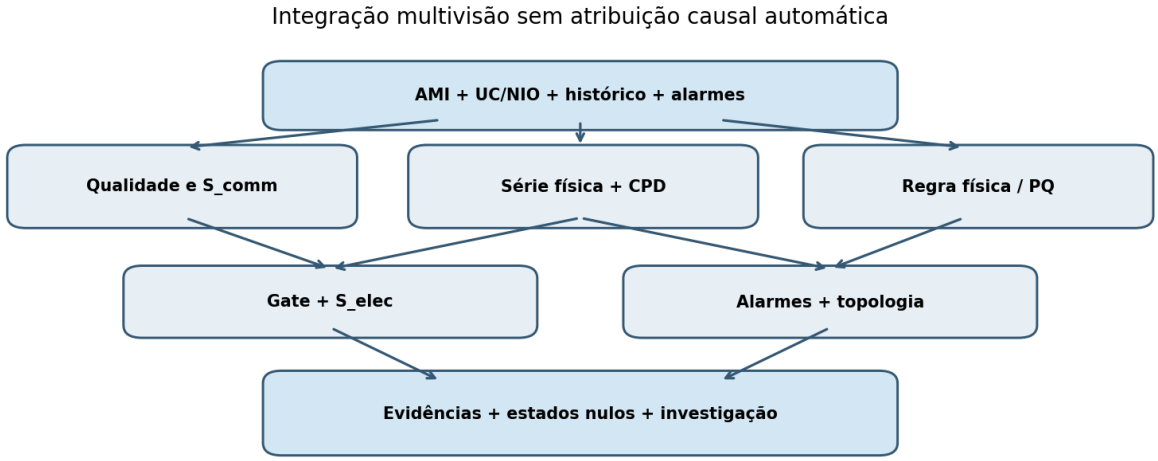


Figura 8: Camadas de evidência e decisão operacional

8.8 8. Exemplo numérico — síntese prudente

Uma UC possui cobertura intervalar válida de 92% em 30 dias; consumo diário médio pré-evento de 16 kWh, pós-evento de 9 kWh; dia candidato de mudança t^* localizado pelo CPD; energia reversa aumentou; registro de GD ainda não foi consultado.

$$\Delta E = 9 - 16 = -7\,\text{kWh/dia}; \quad \Delta\% = \frac{-7}{16} \cdot 100 = -43{,}75\%.$$

Saída correta:

> "Mudança persistente de patamar de consumo, estimada em -43,75% no conjunto de janelas selecionadas, associada a aumento de energia reversa. Padrão compatível com mudança de fluxo/geração, sujeito à verificação de cadastro, sem atribuição causal conclusiva. Cobertura elétrica de 92% no período utilizado."

Não é correto dizer "fraude de GD com 90% de confiança" sem rótulos independentes e calibração causal.

8.9 9. Validação científica mínima para o TCC

8.9.1 Nível 1 — testes de integridade

- precisão do join UC–NIO por vigência;
- ausência de duplicação temporal e registros fora de janela;
- unidade de energia/potência e base nominal de tensão;
- cobertura por canal e censura do final da janela;
- colunas de `X_elec` sem telemetria/missingness e metadados futuros;
- sem `NaN` convertido a zero físico.

8.9.2 Nível 2 — cenários sintéticos conhecidos

Injete mudanças de patamar, variações sazonais, falhas de transmissão e eventos comuns de vizinhança. Meça sensibilidade e falsos alertas em controles negativos.

8.9.3 Nível 3 — casos reais corroborados

Use inspeções, intervenções e alarmes confirmados com proveniência; documente viés de amostragem e limites dos rótulos. Relate precisão em top-K e custo operacional quando isso for mensurável.

8.9.4 Nível 4 — comparação e ablação

Baseline simples `CPD` vs `IF` vs `CPD + IF` vs `CPD + IF + contexto`; evidência de ganho, intervalo temporal e generalização. Reporte tempo de execução e taxa de medidores **não avaliados**.

Sem esses níveis, apresentar arquitetura como resultado comprovado seria incorreto.

8.10 10. Laboratório final

O script `lab/lab21_pipeline.py` executa um protótipo mínimo com dados sintéticos: qualidade por UC gate mudança pré/pós IF sobre features físicas regra de interpretação emissão de saída com nulos quando não avaliada. Não inclui inferência causal automática nem links a dados reais.

8.11 11. Exercícios

1. De 200 UCs, 150 elegíveis e 30 alertas: calcule taxa condicional de alertas e taxa por população.
2. Liste quais outputs devem ser nulos quando a cobertura física não permite pontuação confiável.
3. Explique a diferença entre correlação espacial de telecom e de tensão.
4. Que experimentos compararam `S_elec` com e sem `cpd_magnitude_delta`?
5. Escreva diagnóstico de uma UC com FA caindo 43,75%, RA crescente e cadastro GD desconhecido.
6. Um modelo hierárquico com pesos fixados por tamanho amostral é MoE treinado? Justifique.

Domínio: consigo defender cada seta da arquitetura e dizer: fonte, cálculo, hipótese, limitação, evidência e comportamento diante de dados inválidos.

9 Estudo de caso integrado — Uma mudança de patamar em 12 UCs

Objetivo: acompanhar do primeiro pacote até a decisão operacional, usando os conceitos de D15–D21. Todos os valores deste caso são **sintéticos**. Nenhuma conclusão aqui representa constatação de campo.

9.1 1. Enredo

Um alimentador atende um transformador com doze UCs. O sistema registra três ocorrências numa mesma semana:

- **UC A:** queda de consumo diário de aproximadamente 16 para 9 kWh/dia, persistente; aumentou energia reversa durante as horas solares.
- **UC B:** dados de corrente apresentam muitos gaps; consumo agregado parece cair, mas apenas 48% das medições previstas chegaram.
- **UC C:** várias UCs do mesmo transformador exibem simultaneamente queda de tensão validamente medida; outros medidores apresentam alarmes correlatos.

Queremos responder: quais eventos são candidatos a mudança elétrica? Onde a falta de dados impede análise? Que hipóteses são compatíveis com os fatos? Como não somar três evidências que derivam da mesma fonte?

9.2 2. Matrizes de observabilidade

UC	C_{30d} energia	C_{30d} tensão	Histórico NIO válido?	Elegível elétrica?
A	0,92	0,95	Sim	Sim, sujeito a regras adicionais
B	0,48	0,55	Sim	**Não** (gate ilustrativo 0,70)
C	0,97	0,96	Sim	Sim

A cobertura geral acima é apenas um *resumo*. A decisão real considera canal, horário, duração de gap e tipo de feature. Para A, a diferença de energia reversa depende também da cobertura do registrador RA, que **não está tabulada**: a hipótese de GD permanece condicionada a essa checagem.

9.3 3. A definição temporal da UC

Em t_0, a UC A usa NIO 1234. Um mês antes, usava NIO 9876. Se o pipeline juntar alarmes de NIO 9876 ao evento posterior só por UC, pode atribuir uma ação do equipamento antigo ao atual.

O join correto exige:

$$t_{install} \leq t_{event} < t_{remove}$$

ou uma regra equivalente de intervalos fechados/abertos consistente com o banco. O período após remoção não pertence ao NIO antigo. Carimbos de medição/evento e recebimento devem ser distinguíveis.

9.4 4. Etapa 1 — comunicação

Para B, 48% de cobertura com lacunas longas significa:

```
S_comm = avaliado (se há amostras de telemetria suficientes)
S_elec = null
is_reliable_elec = false
operational_tags = ["DADO_INSUFICIENTE", "FALHA_TELEMETRIA"]
```

Por que não `S_elec=0`? Porque zero seria interpretado como baixa raridade elétrica comprovada. A hipótese elétrica continua não avaliada.

Pergunta para pesquisa: é falha de comunicação ou desligamento real? Para responder, correlacionar alarmes de modem/offline, timestamp de origem/recebimento, canais de energia, eventos de tensão e outros medidores do mesmo concentrador. Gaps sozinhos não provam interrupção de fornecimento.

9.5 5. Etapa 2 — CPD

Para A, histórico diário pré-evento $[15, 16, 16, 17, 16]$ e pós-evento $[9, 9, 10, 8, 9]$.

Médias:

$$\bar{E}_{pre} = 16, \qquad \bar{E}_{post} = 9 \,\text{kWh/dia}.$$

Delta absoluto: $\Delta E = -7$ kWh/dia. Delta relativo: $-43,75\%$.

Uma forma robusta de explorar o patamar usa medianas (16 e 9), chegando ao mesmo delta neste exemplo. A data de mudança precisa ser estimada com o método escolhido, e o problema de sazonalidade deve ser controlado. Se A for comércio fechado às segundas, janelas de cinco dias não são necessariamente comparáveis sem condicionar por dia da semana.

Experimento negativo: simular uma sequência com a mesma média antes/depois, mas mudanças na variância. Detector só de mudança de média pode não marcar; isso não significa ausência de mudança estatística.

9.6 6. Etapa 3 — características do regime

Para A, as features candidatas na janela pós-evento incluem:

Feature	Exemplo	Leitura prudente
`cpd__magnitude`	-7 kWh/dia	Queda persistente no patamar
`cpd__relative_change`	-43,75%	Escala normalizada pela baseline
`x__hist_fa_sum_mad`	0–1 kWh/dia	Regime pós-evento relativamente estável
`x__hist_ra_reversal_days`	3 dias elegíveis	Exportação registrada, verificar canal
`x__hist_voltage_imbalance_max`	1,5% proxy	Magnitudes distintas, sem causalidade automática
`meta__data_quality`	0,92	Gate de observabilidade, **não X_elec**

Advertência: se a série RA era indisponível e depois passou a estar configurada, a mudança de `RA` pode representar alteração instrumental e não física. O catálogo de fontes deve registrar vigência e semântica.

9.7 7. Etapa 4 — detecção estatística

Um IF ajustado em histórico elegível e UCs comparáveis atribui um score orientado. Para ilustração, suponha que A está no percentil 98 de raridade relativa, B não é avaliada e C fica no percentil 76:

```
A: percentile_anomaly = 0.98 (hipotético)
B: percentile_anomaly = null
C: percentile_anomaly = 0.76 (hipotético)
```

O valor 0,98 indica posição na distribuição de score de referência, **não 98% de fraude**. O próprio ranking precisa ser recalculado se a referência ou a transformação mudar.

Se aplicar LOF adicional, verifique se A é rara **entre UCs de classe e padrão comparáveis**. Um IF alto e LOF baixo podem ocorrer quando A pertence a um pequeno grupo homogêneo, mas globalmente raro. Isso demanda interpretação, não média cega.

9.8 8. Etapa 5 — física e alarmes

A: exportação de energia durante o dia pode ser compatível com geração local. Precisamos de cadastro GD e eventos de instalação. Uma queda de FA não implica manipulação. Um alarme de tamper teria que ser lido com código/taxonomia, origem, horário de evento, horário de recebimento e NIO vigente. O mesmo alarme operacional repetido não equivale automaticamente a múltiplos incidentes independentes.

C: tensões de vários medidores caem simultaneamente. O dado sugere **evento comum**, mas não podemos apagar os registros como "falsos positivos". Pode ser uma ocorrência de qualidade de energia real, útil à manutenção de rede. A hipótese de problema individual de medidor fica menos exclusiva, mas não é eliminada por regra simplista.

9.9 9. Etapa 6 — diagnóstico com evidências e pendências

UC	Diagnóstico operacional	Evidências	Pendências
A	MUDANÇA_REGIME + INVESTIGAR_FLUXO_REVERSO	CPD, FA reduzida, RA possivelmente presente	Cadastro GD, validade RA, medidor/troca
B	DADO_INSUFICIENTE + TELEMETRIA_INSTAVEL	Cobertura baixa, gaps	Alarmes, rede telecom, reprocessamento
C	EVENTO_FISICO_COLETIVO_POSSIVEL	Queda de tensão em vizinhos validamente observada	Confirmar topologia, timing e instrumento

Em um dashboard, as três UCs aparecem por **razões diferentes**. Não há uma pontuação única obrigatória nem rótulo "fraude".

9.10 10. Três experimentos de validação

E1 — corte de comunicação: remova artificialmente 50% dos pontos de energia de uma UC normal. O gate deve reconhecer cobertura insuficiente e bloquear `S_elec` se estiver abaixo de critério definido. `S_comm` pode gerar alerta. O modelo não deve concluir "consumo zero".

E2 — degrau real: adicione redução persistente de 40% a uma série completa, controlando sazonalidade. Compare CPD isolado, IF isolado e combinação; registre atraso de detecção e falsos alarmes.

E3 — evento coletivo: reduza simultaneamente tensão de 10 de 12 UCs no mesmo trafo com timestamps válidos. Teste se o pós-processamento altera a **hipótese operacional** sem apagar a existência do evento.

9.11 11. Um pseudocódigo claro

```
for uc_cutoff in dataset:
    context = resolve_meter_and_grid_at_cutoff(uc_cutoff)
    telemetry = compute_coverage_by_channel(uc_cutoff, context)
    comm = score_communication(telemetry)

    if not eligible_electrical(telemetry, context):
        electrical = None
        change = None  # quando a série necessária também é insuficiente
        tags = ["DADO_INSUFICIENTE"]
    else:
        electrical_series = build_valid_electrical_series(uc_cutoff)
        change = score_change_points(electrical_series)
        features = physical_features_only(electrical_series)
        electrical = score_electrical(features)
        tags = physical_rules(electrical_series, context)

    alarms = resolve_alarms_by_meter_validity(uc_cutoff)
    neighbors = topological_context(uc_cutoff)
```

```
    save_evidence(uc_cutoff, comm, change, electrical,
                  alarms, neighbors, tags, provenance=True)
```

Esse pseudocódigo não é cópia da implementação real. Ele explicita decisões que precisam ser verificadas/implementadas durante a refatoração.

9.12 12. Perguntas de banca

1. Por que a ausência de medição não é energia zero?
2. Como impedir leakage em um conjunto UC × cutoff_date?
3. O Isolation Forest aprende fraude? Qual a interpretação matemática do score?
4. Qual diferença entre isolamento, densidade local e reconstrução PCA?
5. Como demonstra que CPD melhora o pipeline? Que baseline?
6. Como o método lida com uma mudança já consolidada há seis meses?
7. Como não confundir um defeito de telecom com um evento coletivo de rede?
8. Seu classificador PQ foi validado com rótulos independentes da regra?
9. Quais fenômenos elétricos são impossíveis de observar em 15 min?
10. Como escolha de limiar modifica o custo de investigação?
11. Por que não usar MoE agora? O que precisaria comprovar?
12. Quais casos são “não avaliados” e como entram no denominador dos indicadores?

9.13 13. Checklist final — D21

- ☐ Todos os canais têm cadência esperada e validade documentadas.
- ☐ Histórico UC–NIO resolvido temporalmente.
- ☐ `X_comm` e `X_elec` não compartilham variáveis de missingness no X elétrico.
- ☐ Escalonamento, PCA e thresholds ajustados somente no treino.
- ☐ IF/LOF têm convenção de score e API documentadas.
- ☐ CPD diferencia online e offline, com tratamento da sazonalidade.
- ☐ Qualidade de energia não reivindica inferências não observáveis.
- ☐ Scores são rankeamento, não probabilidade de fraude.
- ☐ Nulos significam não avaliados, não normais.
- ☐ Há registro de versão das fontes, features, modelo e norma.
- ☐ Há testes de integridade, cenários sintéticos e plano de validação real.

10 Gabarito comentado — Semana 3

As respostas são **padrões esperados de raciocínio** e não justificam concluir irregularidade de medidor real.

10.1 Dia 15

1. Mudança contextual/temporal de patamar; a troca de morador é explicação plausível. Não há conclusão de fraude, mesmo que CPD detecte uma quebra.

2. Série $[4, 5, 5, 6, 20]$: mediana 5; desvios $[1, 0, 0, 1, 15]$; MAD 1. Para 20, $z_{rob} = 0{,}6745 \cdot (20 - 5)/1 = 10{,}1175$.

3. Duas sequências como $[0, 0, 0, 2, 2, 2]$ e $[0, 2, 0, 2, 0, 2]$ têm mesmos valores, mesma média e variância, mas organização temporal diferente. Um modelo de mudança de patamar persistente pode identificar a primeira e não a segunda, dependendo do custo e penalização.

4. Classe, fase e perfil horário; também região, potência de transformador, clima e cadastro GD, quando confiáveis e disponíveis ao cutoff.

5. "UC apresenta padrão estatisticamente incomum para a referência escolhida e deve ser priorizada para análise contextual; não há confirmação causal."

10.2 Dia 16

1. Para $\psi = 4$, $H(3) = 1 + 1/2 + 1/3 = 11/6$; $c(4) = 2(11/6) - 2(3/4) = 13/6 \approx 2{,}1667$. Para $E[h] = 2$, $s = 2^{-2/(13/6)} = 2^{-12/13} \approx 0{,}527$.

2. `-0.6` é mais anômalo na convenção de `score_samples` do sklearn.

3. `decision_function<0` implica `-1`. Valores $0{,}05$ e 0 são inliers (+1), e $-0{,}03$ é outlier (-1).

4. Hash/versão de dataset, corte temporal, IDs amostrados, lista e ordem de features, transformadores/scalers, modelo/seed/hiperparâmetros, offset, versão sklearn e convenção de score.

5. Não. Controla o limiar e a fração nominal marcada no treino, não a prevalência física.

6. Mudança de população de referência ou de threshold/scaler; troca de modelo; inclusão de outra janela; mudança de codificação de feature.

10.3 Dia 17

1. $LOF = (1{,}1 + 1{,}2 + 0{,}9)/(3 \cdot 1) = 3{,}2/3 \approx 1{,}067$.

2. Escalonamento altera pesos relativos dos eixos na distância multidimensional; portanto muda a ordem dos vizinhos.

3. `LocalOutlierFactor(novelty=True)` com `fit` num histórico de referência e `predict/score_samples` apenas em novas observações, ou outro detector com interface própria de inferência futura.

4. Um grupo globalmente raro, mas internamente muito coeso, pode ser isolado como raro globalmente e apresentar LOF ~1 em cada membro.

5. Não. Categoria sem ordenação natural não deve ser representada por número arbitrário como distância métrica; estratificação/encoding deliberado podem ser opções.

6. LOF é razão de densidades locais; probabilidades de fraude dependem de rótulos, calibração e prevalência.

10.4 Dia 18

1. Duplicar a mesma feature acrescenta seu quadrado de diferença uma vez mais à soma de distâncias, sobreponderando aquele fenômeno.

2. Reconstrução $(2, 0)$; resíduo $(0, 3)$; erro 9.

3. Percentil 99 indica raridade relativa no conjunto de referência, não probabilidade posterior de uma causa.

4. Forte correlação sugere redundância potencial; comparar diferentes erros, cobertura, custo e ganho em casos independentes antes de fusionar.

5. Comparar mesmo IF, treino, splits e hiperparâmetros em `X_base` e `X_base + cpd_magnitude_delta`; medir estabilidade, casos confirmados, sensibilidade sintética e falsos alarmes.

6. Benchmark no mesmo conjunto temporal e com verdades/controles independentes, métricas e intervalos de incerteza, além da taxa de não avaliados.

10.5 Dia 19

1. $209/220 = 0{,}95$ p.u.

2. Média $220{,}6667$ V; maior desvio $3{,}3333$ V; PVUR $\approx 1{,}5106\%$.

3. Null descreve ausência de dado/registrador ou fase não configurada; não mede tensão zero.

4. Magnitudes e ângulos fasoriais apropriados ou instrumentação capaz de fornecer componentes simétricas de forma válida, com referência consistente.

5. Pode motivar confronto cadastral, mas registro GD ausente pode ser erro/atraso cadastral; não comprova geração irregular.

6. A duração de 4 ciclos é muito inferior à cadência; uma amostra pontual pode ocorrer antes/depois do evento, e uma média integra o fenômeno sem preservar duração/forma.

7. Tensão nominal e modalidade, semântica temporal/grandeza do canal, procedimento/tabela normativa vigente; adicionalmente validade de fase, pontos de leitura e condições de agregação.

10.6 Dia 20

1. P=15/(15+35)=0,30; R=15/(15+5)=0,75; FPR=35/(35+945)=0,035714; accuracy=(15+945)/1000=0,96.

2. A classe negativa é massiva; um modelo que nunca alerta teria 98% de accuracy nesse exemplo, mas recall 0 e valor operacional ruim para encontrar eventos.

3. Demonstrar ganho além de reproduzir limiar: robustez a ruído, proxies quando tensão não está disponível, custo, generalização; usar rótulos externos quando alegar detecção de causa.

4. Nova UC: split por grupo com data controlada; nova data: split temporal com purga quando necessário; novo alimentador: holdout topológico, checando eventos correlacionados.

5. Não suprimir. Evento coletivo pode indicar problema real de rede; requalificar causa e prioridade, preservando evidência.

6. “Queda persistente de FA e aumento de RA, compatíveis com alteração de fluxo/geração; requer validação de cadastro e canal de energia reversa.”

10.7 Dia 21

1. 30/150=20% entre elegíveis; 30/200=15% no total; 50/200=25% não avaliados. Não inferir prevalência em todos.

2. `s_elec`, `is_elec_anomaly`, características físicas derivadas cuja qualidade é insuficiente; `reason_not_evaluated` deve estar preenchido. `s_comm` pode permanecer avaliado quando há informação de telemetria suficiente.

3. Telecom correlata: modem/concentrador/backhaul; tensão correlata: circuito/trafo/alimentador. Sem instrumento independente, podem coexistir ou se confundir.

4. Ablation controlada com vs sem CPD em mesmas UCs/datas e split temporal, comparando false alerts e sensibilidade a rupturas sintéticas/casos corroborados.

5. “Mudança de regime de -43,75% e RA crescente; compatível com alteração de fluxo; cadastro GD/medição RA pendentes; não há determinação causal.”

6. Não necessariamente. Pesos heurísticos por N sem treino de gating não constituem por si um MoE estatisticamente aprendido.

---

11 Respostas para autoavaliação oral

Para alcançar **5 estrelas** no tracker, o aluno deve conseguir derivar ao menos as equações principais, explicar limitações e reproduzir um laboratório sintético sem consultar a apostila. **4 estrelas:** aplica corretamente com consulta pontual. **3 estrelas:** explica método e lê resultados, mas não implementa sozinho. **2 estrelas:** reconhece termos. **1 estrela:** apenas viu o conceito. **0 estrelas:** não estudou.

11.0.1 Perguntas transversais recomendadas

- Se apenas 70% das UCs são elegíveis, qual denominador é usado nas métricas? Qual viés isso pode gerar?
- Se `S_comm` e `S_elec` são ambos altos, o que descartar antes de atribuir a um evento físico?
- Se o IF pontua 100% como anomalia, qual primeiro teste de sanidade de `predict` e `decision_function`?
- Se LOF produz ruído mas IF não, quais diferenças de noção de raridade podem explicar?
- Como uma norma específica e sua versão devem ser citadas e codificadas?
- O que um teste offline usando janela futura prova e não prova para alerta em tempo real?

12 Apêndice A — Formulário técnico de consulta rápida

Este formulário distingue **definição matemática**, **interpretação operacional** e **limites do uso**. A mesma notação pode mudar entre livros e bibliotecas; a convenção deve ser registrada junto ao modelo.

12.1 A.1 Estatística descritiva e escalas

Símbolo / fórmula	Definição	Uso / alerta
$\bar{x} = \sum x_i/n$	média	Sensível a valores extremos
$\tilde{x} = \text{median}(x)$	mediana	Resistente a alguns extremos
$MAD = \text{median}\,\lvert x_i - \tilde{x}\rvert$	desvio absoluto mediano	Escala robusta; pode ser zero
$IQR = Q_{0,75} - Q_{0,25}$	amplitude interquartílica	Dispersão robusta
$z = (x - \mu)/\sigma$	padronização	μ, σ somente do treino
$z_{rob} = 0{,}6745(x - \tilde{x})/MAD$	z-score robusto	Requer MAD não nulo
$r_{xy} = \text{cov}(x, y)/(\sigma_x \sigma_y)$	correlação linear	Não implica causalidade

12.2 A.2 Dados e séries temporais

Fórmula	Significado	Risco
$C = N_{obs}/N_{esp}$	completude da janela/canal	Denominador exige cadência vigente
$\Delta E = E_{post} - E_{pre}$	alteração absoluta de consumo	Janelas precisam ser comparáveis
$\Delta\% = 100\Delta E/E_{pre}$	variação relativa	Indefinida com $E_{pre} = 0$
$z_t = (x_t - b_t)/s_t$	resíduo normalizado	Baseline b_t deve ser causal
$\rho_k = \text{corr}(x_t, x_{t-k})$	autocorrelação em lag k	k é número de passos, não dias
$C_{daynight} = E_{day}/E_{night}$	razão dia/noite	Denominador zero e definição horária

12.3 A.3 CPD e regime

Fórmula	Leitura
$S_t^+ = \max(0, S_{t-1}^+ + z_t - k)$	acumulado de desvios positivos acima de referência
$S_t^- = \max(0, S_{t-1}^- - z_t - k)$	acumulado de desvios negativos
Alerta se $S_t^{\pm} > h$	limiar depende de falsa taxa e atraso aceitos
$\min_\tau \sum_j c(y_{\tau_j:\tau_{j+1}}) + \beta m$	segmentação offline penalizada
$\text{KS} = \sup_x \lvert F_A(x) - F_B(x)\rvert$	discrepância entre ECDFs
$W_1(P, Q) = \int_0^1 \lvert F_P^{-1}(u) - F_Q^{-1}(u)\rvert\, du$	Wasserstein unidimensional

Essas fórmulas vêm da Semana 2; estão aqui para permitir consulta durante classificação e integração.

12.4 A.4 Outlier detectors

Fórmula	Leitura
$s_{IF} = 2^{-E[h]/c(\psi)}$	score conceitual de isolamento do artigo
$c(\psi) = 2H(\psi - 1) - 2(\psi - 1)/\psi$	comprimento esperado de referência

Fórmula	Leitura
$lrd_k(p) = [\lvert N_k\rvert^{-1} \sum_o \text{reachdist}_k(p,o)]^{-1}$	densidade de alcançabilidade local
$LOF_k(p) = \lvert N_k\rvert^{-1} \sum_o lrd_k(o)/lrd_k(p)$	raridade local por razão de densidades
$r_i = \lVert x_i - \hat{x}_i\rVert^2$	erro residual PCA na escala do ajuste
$S_i = \sum_m w_m g_m(s_{im})$	combinação de scores; requer escalas compatíveis

12.5 A.5 Classificação e qualidade elétrica

Fórmula	Leitura
$V_{pu} = V_{med}/V_{ref}$	tensão relativa à base pertinente
$PVUR = 100 \max_k \lvert V_k - \bar{V}\rvert/\bar{V}$	proxy de desequilíbrio por magnitudes
$FD \simeq 100\lvert V_2\rvert/\lvert V_1\rvert$	fator por componentes simétricas, definição distinta
$P = TP/(TP+FP)$	precisão dos alertas
$R = TP/(TP+FN)$	recall/sensibilidade
$FPR = FP/(FP+TN)$	taxa de falsos alarmes sobre negativos
$F_1 = 2PR/(P+R)$	média harmônica de precisão e recall
$Precision@K = TP@K/K$	produtividade entre os K alertas priorizados

Não existe fórmula genérica `score=probabilidade de fraude`. Atribuições probabilísticas só podem ser feitas sob modelo, rótulos, calibração e população definidos.

---

13 Apêndice B — Tabela de referências por capítulo

Código	Fonte	Capítulos/seções	Ligação principal
AG1	Aggarwal (2017)	Cap. 1	Tipos/modelos de outliers, dependência do modelo de dados
AG4	Aggarwal (2017)	Cap. 4	Proximidade e LOF
AG3	Aggarwal (2017)	Cap. 3	Subespaços lineares e PCA residual
AG5	Aggarwal (2017)	Cap. 5	Alta dimensionalidade
AG6	Aggarwal (2017)	Cap. 6	Outlier ensembles
AG9	Aggarwal (2017)	Cap. 9	Anomalia em série temporal
AG11–12	Aggarwal (2017)	Caps. 11–12	Espaço e grafos
GE3	Géron (2025)	Cap. 3	Classificação e métricas
GE6	Géron (2025)	Cap. 6	Forest, boosting e ensembles
GE7	Géron (2025)	Cap. 7	PCA/redução de dimensão
GE8	Géron (2025)	Cap. 8	Clusters, misturas, detecção de outliers
BG1–2	Bollen & Gu (2006)	Caps. 1–2	fenômenos de PQ
BG5	Bollen & Gu (2006)	Cap. 5	agregação de dados e indicadores
BG7–9	Bollen & Gu (2006)	Caps. 7–9	segmentação, caracterização e classificação

Código	Fonte	Capítulos/seções	Ligação principal
BP	Bollen et al. (2007)	Artigo completo	Determinístico vs estatístico
BI14	Bishop (2006)	Cap. 14	Combinação de modelos; seção de conditional mixtures

13.1 Referências diretas de normas e APIs

- ANEEL — PRODIST e links para versão vigente: https://www.gov.br/aneel/pt-br/centrais-de-conteudos/procedimentos-regulatorios/prodist.
- ANEEL — exemplo do Módulo 8 com faixas dependentes do nível de conexão: https://www2.aneel.gov.br/cedoc/aren2021956_prodist_modulo_8_v13.pdf. **Consultar portal para confirmar se esta é a versão aplicável ao estudo.**
- scikit-learn — `IsolationForest`: https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html.
- scikit-learn — `LocalOutlierFactor`: https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.LocalOutlierFactor.html.
- scikit-learn — visão conceitual: https://scikit-learn.org/stable/modules/outlier_detection.html.

---

14 Apêndice C — Checklist de engenharia para refatoração

14.1 C.1 Contrato de features

Campo	Definir antes do modelo
Entidade	UC ou NIO, regra temporal de vinculação
Janela	corte, início inclusivo, fim exclusivo
Cadência	esperada por canal e data, mudança no tempo
Unidade	kWh, kW, V, A, %, adimensional
Fonte	sistema/tabela, versão e transformação
Agregação	soma/média/máximo/mediana sobre qual intervalo
Null	ausência legítima, indisponibilidade, valor inválido
Leakage	qualquer informação posterior ao corte?
Qualidade	cobertura exigida por feature; exceções documentadas
Modelo	S_comm, S_elec, contexto ou diagnóstico

14.2 C.2 Contrato de score

Campo	Pergunta de auditoria
`model_name`	Qual versão e quais algoritmos?
`training_period`	Qual baseline temporal?
`population_id`	Segmento global, município, feeder ou cluster?
`score_raw`	Qual orientação? Maior = mais raro?
`offset`	Qual limiar e por quê?
`score_percentile`	Qual referência empírica e versão?
`eligibility`	Avaliado, não avaliado ou indeterminado?
`cause`	Há evidência externa independente?
`provenance`	É possível reproduzir o registro?

14.3 C.3 Testes contra erros clássicos

☐ `predict(X_train)` após IF com contamination conhecido não marca quase 100%.

- ☐ `score_samples` e `decision_function` têm sinais esperados.
- ☐ LOF `novelty=True` é aplicado somente em `X_new`.
- ☐ ID UC, NIO e timestamp não entram como números em `X`.
- ☐ Ausência de RA não vira RA=0.
- ☐ Fases não instaladas não viram tensão=0.
- ☐ `data_quality` não entra em `X_elec`.
- ☐ Referência por segmento é suficiente em tamanho e comparabilidade.
- ☐ Sem leak de `cutoff_date`, threshold ou scaler ajustado no teste.
- ☐ Não há score elétrico emitido em regime de qualidade insuficiente.
- ☐ Normas e tabelas regulatórias têm versão e âmbito explícitos.
- ☐ Alarmes de NIO trocado respeitam vigência temporal.
- ☐ Eventos compartilhados de rede são preservados e recontextualizados.

---

15 Apêndice D — Matriz de aprendizagem 0 a 5 estrelas

Estrelas	Condição prática	Exemplo para Isolation Forest
0	Nunca estudou	Não sabe o que é IF
1	Reconhece termos	Sabe que é método de outlier
2	Explica informalmente	Descreve isolamento por árvores
3	Explica matemática e API	Entende comprimento de caminho, score e offset
4	Implementa e avalia	Executa pipeline sem leakage e diagnostica threshold
5	Defende criticamente	Explica failure modes, evidência, baseline, ablação e limitações

Sugestão de entrega por dia no Textual: cap. concluído (check independente), conceito com estrelas, nota própria, resultado de laboratório e uma pergunta ainda sem resposta. A conclusão de um capítulo não deve preencher automaticamente as estrelas dos seus conceitos.

---

16 Bibliografia consolidada — Semana 3

1. AGGARWAL, Charu C. *Outlier Analysis*. 2nd ed. Springer, 2017. DOI: 10.1007/978-3-319-47578-3.
2. GÉRON, Aurélien. *Hands-On Machine Learning with Scikit-Learn and PyTorch*. O'Reilly, edição digital fornecida, 2025.
3. BOLLEN, Math H. J.; GU, Irene Yu-Hua. *Signal Processing of Power Quality Disturbances*. Wiley-IEEE Press, 2006.
4. BOLLEN, Math H. J. et al. Classification of Underlying Causes of Power Quality Disturbances: Deterministic versus Statistical Methods. *EURASIP Journal on Advances in Signal Processing*, 2007. DOI: 10.1155/2007/79747.
5. BISHOP, Christopher M. *Pattern Recognition and Machine Learning*. Springer, 2006.
6. LIU, Fei Tony; TING, Kai Ming; ZHOU, Zhi-Hua. Isolation Forest. *IEEE ICDM*, 2008. Referência conceitual do método; texto original não fazia parte do conjunto principal enviado.
7. BREUNIG, Markus M. et al. LOF: Identifying Density-Based Local Outliers. *ACM SIGMOD*, 2000. Referência conceitual do LOF; texto original não fazia parte do conjunto principal enviado.
8. ANEEL. *Procedimentos de Distribuição de Energia Elétrica no Sistema Elétrico Nacional — PRODIST*, Módulo 8, versão vigente. Consulta ao portal oficial.

9. SCIKIT-LEARN DEVELOPERS. Documentação de `IsolationForest`, `LocalOutlierFactor` e Outlier Detection. Consulta à documentação oficial.

Critério final de completude: conseguir explicar ao examinador a diferença entre "evento detectado", "atipicidade estatística", "regra física/operacional" e "causa confirmada". Essa separação delimita o alcance científico do projeto.

17 Apêndice E — Laboratórios Python completos

Os scripts deste apêndice reproduzem casos **sintéticos**, não acessam Oracle, MongoDB ou BigQuery e não incorporam resultados de fiscalização. Dependências: `numpy`, `scipy`, `scikit-learn` e `matplotlib` (as figuras são geradas por script adicional).

17.1 Como executar

```
uv sync
uv run python lab\lab15_anomalias.py
uv run python lab\lab16_isolation_forest.py
uv run python lab\lab17_lof.py
uv run python lab\lab18_ablation.py
uv run python lab\lab19_pq.py
uv run python lab\lab20_classificacao.py
uv run python lab\lab21_pipeline.py
```

Advertência: alguns laboratórios usam `contamination` como parâmetro experimental, jamais como taxa conhecida de irregularidades. Os scores são indicadores de raridade.

17.2 E.1 — D15: Anomalia contextual

Arquivo: `lab/lab15_anomalias.py`

```python
"""Dia 15: raridade global e local em três populações sintéticas."""
import numpy as np
from sklearn.ensemble import IsolationForest

rng = np.random.default_rng(15)
residential = rng.normal(11, 2, 120)
commercial = rng.normal(65, 8, 100)
industrial = rng.normal(400, 25, 65)
values = np.concatenate([residential, commercial, industrial])
groups = np.concatenate([np.zeros(120), np.ones(100), np.full(65, 2)]).astype(int)
values[5] = 40.0  # estranho em residencial; comum em alguma outra escala

def robust_z(x: np.ndarray, ref: np.ndarray) -> float:
    center = np.median(ref)
    mad = np.median(np.abs(ref - center))
    return 0.6745 * (float(x) - center) / mad if mad > 1e-10 else float('nan')

print('UC residencial com consumo 40 kWh/dia')
print('z robusto GLOBAL: ', round(robust_z(values[5], values), 3))
print('z robusto LOCAL:  ', round(robust_z(values[5], values[groups == 0]), 3))
assert abs(robust_z(values[5], values[groups == 0])) > abs(robust_z(values[5], values))
print('Um único número pode ser comum globalmente e extremo localmente.')
```

17.3 E.2 — D16: Isolation Forest

Arquivo: `lab/lab16_isolation_forest.py`

```python
"""Dia 16: Isolation Forest; convenção de score e sanity check de treino."""
import numpy as np
from sklearn.ensemble import IsolationForest

rng = np.random.default_rng(16)
train = np.column_stack([rng.normal(15, 2, 500), rng.normal(.5, .07, 500), rng.normal(1.5, .4, 500)])
test = np.vstack([rng.normal([15, .5, 1.5], [2, .07, .4], size=(60, 3)), [[40, 3.0, 9.0], [1, .01, .03]]])
model = IsolationForest(n_estimators=200, contamination=.05, random_state=16)
model.fit(train)
train_flag = model.predict(train)
test_flag = model.predict(test)
```

```
raw = model.score_samples(test)
decision = model.decision_function(test)
assert np.allclose(decision, raw - model.offset_)
assert 0.03 <= np.mean(train_flag == -1) <= 0.07
assert test_flag[-1] == -1 and test_flag[-2] == -1
print('treino -1 =', int((train_flag == -1).sum()), 'de', len(train))
print('teste -1 =', int((test_flag == -1).sum()), 'de', len(test))
print('offset =', model.offset_)
for i in np.argsort(raw)[:4]:
    print('teste', int(i), 'score_samples=', round(raw[i], 4), 'decision=', round(decision[i], 4), 'predict=',
    ↪  test_flag[i])
print('Scores não são probabilidades de fraude.')
```

17.4 E.3 — D17: Local Outlier Factor

Arquivo: `lab/lab17_lof.py`

```
"""Dia 17: comparar LOF de conjunto e novidade em amostras inéditas."""
import numpy as np
from sklearn.neighbors import LocalOutlierFactor
from sklearn.preprocessing import StandardScaler

rng = np.random.default_rng(17)
cluster1 = rng.normal([0, 0], .15, size=(120, 2))
cluster2 = rng.normal([4, 2], .65, size=(80, 2))
train = np.vstack([cluster1, cluster2, [[.7, .7]]])
scaler = StandardScaler().fit(train)
X = scaler.transform(train)
lof = LocalOutlierFactor(n_neighbors=20, contamination=.05)
flags = lof.fit_predict(X)
assert lof.negative_outlier_factor_.shape == (201,)
print('modo outlier: amostras detectadas', int(np.sum(flags == -1)))
print('ponto testado no train:', round(float(lof.negative_outlier_factor_[-1]), 3))
novelty = LocalOutlierFactor(n_neighbors=20, novelty=True, contamination=.05)
novelty.fit(X)
new = scaler.transform([[.9, .9], [0., 0.], [4., 2.]])
score = novelty.score_samples(new)
print('modo novidade (novas amostras):', np.round(score, 3))
assert score[0] < score[1]
print('Não usar predict(X_train) em novelty=True como equivalência a fit_predict.')
```

17.5 E.4 — D18: Ablation e PCA residual

Arquivo: `lab/lab18_ablation.py`

```
"""Dia 18: ablação, redundância e PCA residual em features sintéticas."""
import numpy as np
from sklearn.decomposition import PCA
from sklearn.ensemble import IsolationForest
from sklearn.preprocessing import StandardScaler
from scipy.stats import spearmanr

rng = np.random.default_rng(18)
n = 400
fa = rng.normal(15, 2, n)
imb = rng.normal(2, .5, n)
quality_noise = rng.uniform(0, 1, n)
Xbase = np.c_[fa, imb]
Xduplicated = np.c_[fa, imb, fa + rng.normal(0, .01, n)]
Xquality = np.c_[fa, imb, quality_noise]

def fit_scores(X):
    sc = StandardScaler().fit(X)
    z = sc.transform(X)
    model = IsolationForest(n_estimators=120, random_state=18, contamination=.05).fit(z)
    return -model.score_samples(z), z

sbase, z = fit_scores(Xbase)
sdup, _ = fit_scores(Xduplicated)
squal, _ = fit_scores(Xquality)
pca = PCA(n_components=1).fit(z)
rec = pca.inverse_transform(pca.transform(z))
residual = ((z-rec)**2).sum(axis=1)
print('Spearman base vs duplicada:', round(float(spearmanr(sbase, sdup).statistic), 3))
print('Spearman base vs qualidade:', round(float(spearmanr(sbase, squal).statistic), 3))
print('PCA residual médio:', round(float(residual.mean()), 4))
```

```
assert np.all(residual >= 0)
print('Interpretação: diferenças de ranking exigem investigar características e utilidade.')
```

17.6 E.5 — D19: Qualidade de energia

Arquivo: `lab/lab19_pq.py`

```
"""Dia 19: p.u., proxy PVUR e limite de observabilidade da grade temporal."""
import numpy as np

V = 121.0; Vref = 127.0
vpu = V/Vref
lines = np.array([220., 218., 224.])
mean = lines.mean()
pvur = 100*np.max(np.abs(lines - mean))/mean
print('V_pu =', round(vpu, 4), 'PVUR proxy (%) =', round(float(pvur), 4))
assert abs(vpu - 121/127) < 1e-12
assert abs(pvur - 1.51057) < .002
# Grade pontual cada 15 min: evento breve em 6–7 minutos não é observado.
samples_min = np.arange(0, 61, 15)
event = lambda t: 180 if 6 <= t <= 7 else 220
observed = [event(t) for t in samples_min]
print('leituras 15min =', observed, 'evento curto em 6-7min foi invisível')
assert all(v == 220 for v in observed)
print('Este laboratório NÃO classifica conformidade regulatória.')
```

17.7 E.6 — D20: Avaliação supervisionada

Arquivo: `lab/lab20_classificacao.py`

```
"""Dia 20: classe rara, baseline de regra e circularidade de rótulos."""
import numpy as np
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, confusion_matrix
from sklearn.model_selection import train_test_split

rng = np.random.default_rng(20)
n = 1200
vpu = rng.normal(1, .035, n)
imb = rng.exponential(.02, n)
X = np.c_[vpu, imb]
# Exemplo de label sintético derivado de regra explícita.
y_rule = (vpu < .90).astype(int)
Xtr, Xte, ytr, yte = train_test_split(X, y_rule, test_size=.35, random_state=20, stratify=y_rule)
model = RandomForestClassifier(n_estimators=100, random_state=20, min_samples_leaf=3).fit(Xtr, ytr)
pred = model.predict(Xte)
print('Classe rara (regra):', round(float(y_rule.mean()), 4))
print('matriz de confusão:', confusion_matrix(yte, pred).tolist())
print('accuracy', round(float(accuracy_score(yte, pred)), 3), 'precision', round(float(precision_score(yte, pred,
↪  zero_division=0)), 3), 'recall', round(float(recall_score(yte, pred)), 3))
assert len(yte) > 0
# Proposta: comparar com a regra original, que define o target e portanto tem 100% de concordância consigo.
rule_baseline = (Xte[:, 0] < .90).astype(int)
assert np.array_equal(rule_baseline, yte)
print('A regra original já define integralmente este y sintético. Não confundir reprodutibilidade com descoberta
↪  física.')
```

17.8 E.7 — D21: Integração com gating

Arquivo: `lab/lab21_pipeline.py`

```
"""Dia 21: protótipo sintético de integração; gate, CPD simples e IF."""
import numpy as np
from sklearn.ensemble import IsolationForest
from sklearn.preprocessing import StandardScaler

rng = np.random.default_rng(21)
# Referência física de UCs com telemetria elegível.
ref = np.c_[rng.normal(15, 2, 250), rng.normal(1.5, .3, 250), rng.normal(0, .8, 250)]
scaler = StandardScaler().fit(ref)
model = IsolationForest(contamination=.05, n_estimators=120, random_state=21).fit(scaler.transform(ref))
rows = [
    {'uc':'A','coverage':.92,'before':16.,'after':9.,'imb':1.5,'trend':-7.},
    {'uc':'B','coverage':.48,'before':12.,'after':5.,'imb':1.0,'trend':-7.},
    {'uc':'C','coverage':.97,'before':14.,'after':13.,'imb':1.3,'trend':-1.},
```

```
]
output=[]
for row in rows:
    eligible = row['coverage'] >= .70  # parâmetro didático, não padrão universal
    if not eligible:
        result = {'uc':row['uc'], 'eligible':False, 's_elec':None, 'is_anomaly':None,
                  'reason':'cobertura insuficiente'}
    else:
        feat=np.array([[row['after'],row['imb'],row['trend']]])
        z=scaler.transform(feat)
        result={'uc':row['uc'], 'eligible':True,
                's_elec':round(float(-model.score_samples(z)[0]),4),
                'is_anomaly':bool(model.predict(z)[0] == -1),
                'delta_pct':100*(row['after']-row['before'])/row['before']}
    output.append(result)
for row in output: print(row)
assert output[1]['s_elec'] is None and output[1]['is_anomaly'] is None
assert output[0]['eligible'] and output[2]['eligible']
print('Exemplo pedagógico: não há dados reais, CPD aprendido ou diagnóstico causal.')
```

17.9 Protocolo de validação do laboratório

1. Leia antes as premissas do capítulo correspondente.
2. Execute o arquivo sem editar os números. Confirme `assert` e saídas.
3. Altere um único parâmetro: população, `contamination`, `k`, escala ou cobertura.
4. Registre o que mudou, o que permaneceu igual e qual hipótese foi posta à prova.
5. Anote no tracker o resultado e a limitação mais importante.

Uma saída compatível com o exercício não significa validação de inferência em dados de concessionária.